Daftar Bimbingan Tugas Akhir Mahasiswa

Nama : PETER YUDHISTIRA
NRP : C14190067
Dosen Wali : Ir. KARTIKA GUNADI, M.T.
Judul TA : Topic Modelling dan Clustering untuk Anomaly Detection pada Transkrip Diskusi Komunitas

Fakultas : TEKNOLOGI INDUSTRI
Jurusan : INFORMATIKA

Tanggal	Dosen Pembimbing	Bimbingan	Topik Bimbingan	Setuju?
25-01-2023	Dr. GREGORIUS SATIA BUDHI, S.T., M.T.	1	Perubahan Fokus Topik Skripsi	
25-01-2023	ALVIN NATHANIEL TJONDROWIGUNO, S.Kom., M.T.	2	Perubahan Fokus Topik Skripsi	☑
03-02-2023	ALVIN NATHANIEL TJONDROWIGUNO, S.Kom., M.T.	3	Pembahasan Alur Eksperimen	☑
09-02-2023	ALVIN NATHANIEL TJONDROWIGUNO, S.Kom., M.T.	4	Preprocessing dan Feature Extraction Awal	☑
14-02-2023	Dr. GREGORIUS SATIA BUDHI, S.T., M.T.	5	Laporan progress pipeline eksperimen	
16-02-2023	ALVIN NATHANIEL TJONDROWIGUNO, S.Kom., M.T.	6	Laporan progress pipeline eksperimen	☑
24-02-2023	ALVIN NATHANIEL TJONDROWIGUNO, S.Kom., M.T.	7	Laporan progress pipeline eksperimen	☑
03-03-2023	ALVIN NATHANIEL TJONDROWIGUNO, S.Kom., M.T.	8	Weighted Averaging menghasilkan cluster yang baik	☑
10-03-2023	ALVIN NATHANIEL TJONDROWIGUNO, S.Kom., M.T.	9	Percobaan parameter DBSCAN	☑
23-03-2023	Dr. GREGORIUS SATIA BUDHI, S.T., M.T.	10	Laporan penemuan dan perubahan pipeline eksperimen	
29-03-2023	ALVIN NATHANIEL TJONDROWIGUNO, S.Kom., M.T.	11	Laporan penemuan dan perubahan pipeline eksperimen	☑

Mengetahui
Pembimbing 1

Dr. GREGORIUS SATIA BUDHI, S.T., M.T.

Mengetahui
Pembimbing 2

ALVIN NATHANIEL TJONDROWIGUNO, S.Kom., M.T.

DENSITY-BASED CLUSTERING UNTUK *ANOMALY DETECTION* PADA TRANSKRIP DISKUSI TERARAH KOMUNITAS

SKRIPSI

Diajukan untuk memenuhi persyaratan penyelesaian program S-1
Jurusan Informatika Fakultas Teknologi Industri
Universitas Kristen Petra

Oleh :
Peter Yudhistira
NRP : C14190067

PROGRAM STUDI INFORMATIKA

FAKULTAS TEKNOLOGI INDUSTRI
UNIVERSITAS KRISTEN PETRA
SURABAYA
2023

COVER

SKRIPSI

Oleh :
Peter Yudhistira NRP : C14190067

Diterima Oleh :

Program Studi Informatika
Fakultas Teknologi Industri
Universitas Kristen Petra

Surabaya, 29 Maret 2023

Pembimbing 1	Pembimbing 2
Dr. Gregorius Satiabudhi	Alvin Nathaniel T., S.Kom., M.T.
NIP: 02-030	NIP: 21-011

Ketua Tim Penguji :

Henry Novianus Palit, Ph.D.
NIP: 14-001

Ketua Program Studi :

Henry Novianus Palit, Ph.D.
NIP: 14-001

DAFTAR ISI

DAFTAR TABEL

DAFTAR GAMBAR

DAFTAR RUMUS

DAFTAR SEGMEN KODE

1. PENDAHULUAN

1.1. Latar Belakang Masalah

Sebuah forum adalah sebuah pertemuan atau medium yang memungkinkan para pesertanya bertukar pendapat dan gagasan akan sebuah permasalahan ("Forum", 2022). Forum yang diselenggarakan oleh sekelompok orang yang memiliki ketertarikan pada bidang yang sama disebut forum komunitas. Dalam sebuah forum komunitas, terjadi diskusi dan pertukaran pendapat antar anggota mengenai sebuah topik yang ada dalam bidang yang dimengerti oleh anggota-anggota komunitas tersebut. Sebuah diskusi harus melibatkan peran seorang fasilitator dan moderator – seorang fasilitator membantu dan menginspirasi proses-proses komunikasi untuk membangun pengetahuan, dan seorang moderator bertugas untuk menggabungkan kontribusi-kontribusi para peserta diskusi dengan cara mengambil pernyataan-pernyataan yang dilontarkan peserta dan mengaitkannya dengan topik dan teori dalam diskusi (Kienle & Ritterskamp, 2007). Pada Komunitas X yang diikuti penulis, terdapat sebuah forum yang diselenggarakan secara daring melalui *platform* Zoom Meetings. Diskusi-diskusi yang terjadi dalam forum ini dibantu dengan adanya fasilitator yang mengarahkan diskusi ke topik yang diinginkan, dan moderator yang memastikan koherensi pendapat setiap peserta diskusi. Selama berlangsungnya sebuah diskusi, seorang moderator juga berperan sebagai notulis yang mencatat pernyataan-pernyataan yang dikeluarkan oleh peserta diskusi. Catatan notulen ini akan dievaluasi untuk menilai kontribusi setiap peserta pada diskusi, serta sebagai dasar pengambilan keputusan untuk topik diskusi selanjutnya. Khususnya, catatan notulen digunakan untuk mengidentifikasikan pendapat-pendapat peserta yang tidak sesuai dengan topik diskusi.

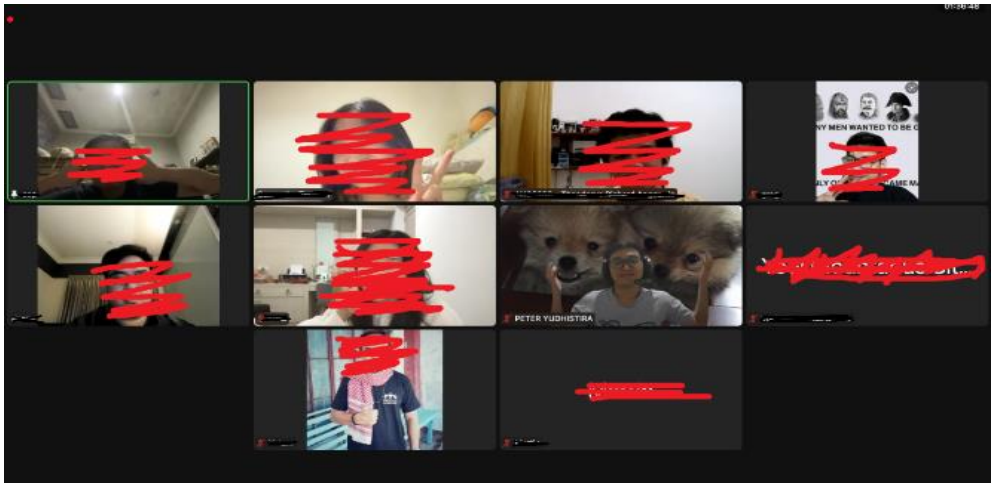

Gambar 1.1 Dokumentasi Pertemuan Diskusi

Untuk menghargai hak privasi setiap anggota peserta diskusi, pihak penyelenggara diskusi tidak menggunakan fitur rekaman yang disediakan oleh platform Zoom Meeting. Oleh karena itu, dokumentasi berupa notulen dibuat oleh moderator atau seorang penyelenggara secara *real-time*. Notulis mencatat secara langsung pernyataan yang dikeluarkan oleh peserta diskusi, baik secara lisan maupun melalui fitur *chat* yang disediakan oleh platform *Zoom Meeting*. Notulis juga melakukan *filtering* pada pernyataan-pernyataan yang dicatatnya, yaitu melakukan sensor terhadap perkataan-perkataan yang kasar atau tidak berkenan, serta melakukan peringkasan terhadap pernyataan-pernyataan yang panjang. Pada akhir pernyataan, moderator menyampaikan ulang pendapat peserta yang baru saja dicatat secara lebih ringkas sebagai bentuk konfirmasi ketepatan catatan.

Trigger	Respond
Opinion : Jesus lives again vs it is all in their minds vs Jesus fainted vs Jesus was stolen	Ce Sam : I agree that [Jesus is stolen] makes sense. It COULD have happened. Ko Ricky : I agree that [Jesus is stolen] makes sense. They could have stolen jesus' body in order to 'fulfill the prophecy'. When i heard that theory, while i don't know exactly, i agree that that theory is plausible. Greg : Historically, I think that jesus' family wasn't poor. Nazareth is no small town. They COULD have bribed the guards because they had the money. Sam : @Greg How do you believe something, but also are open to the possibility of the opposite being true? Ricky : I am open to possibilities. Whichever is true, so be it. Greg : Elements of the theories might be present, but ultimately I believe that Jesus lives again. Audrey : The bribe theory is implausible. Judas who betrayed Jesus received money. Everybody hated Jesus.

Gambar 1.2 Contoh Notulen Diskusi

Namun, terdapat beberapa kendala dalam sistem pencatatan dan evaluasi yang diterapkan oleh penyelenggara diskusi dalam Komunitas X. Pembuatan keputusan dan penilaian yang dilakukan secara terus menerus dapat menurunkan fungsi eksekutif dan sumber daya mental seseorang (Danziger, Levav, & Avnaim-Pesso, 2011). Karena panjangnya pendapat beberapa peserta, notulis bisa kehilangan fokus dan tidak mendokumentasikan pendapat peserta dengan baik. Seringkali notulis harus melakukan parafrase yang berdasarkan sumber yang tidak lengkap. Akibatnya, data yang dicatat tidak mencerminkan secara akurat pernyataan yang dikeluarkan oleh pembicara, dan mungkin mengandung bias, sehingga menghambat proses evaluasi. Selain itu, karena besarnya volume teks yang harus dievaluasi dan terbatasnya waktu kerja, komite penyelenggara diskusi mengalami kesulitan untuk mengidentifikasikan pendapat-pendapat peserta diskusi yang melenceng dari topik.

Oleh karena itu, diperlukan sebuah metode untuk mendapatkan transkrip diskusi, merepresentasikan fitur-fitur dari pendapat setiap peserta diskusi dan mendeteksi pendapat-pendapat yang melenceng dari topik diskusi. Untuk tujuan ini, akan digunakan metode *clustering* dan *topic modelling* untuk melakukan *anomaly detection* pada dataset transkrip diskusi Komunitas X. Hasil dari penelitian akan dievaluasi oleh komite penyelenggara diskusi di Komunitas X dan akan diterapkan dalam bentuk program untuk membantu proses diskusi.

Studi yang dilakukan oleh (Curiskis & al., 2019) mengevaluasi *clustering* dan *topic modelling* pada media sosial Twitter dan Reddit. Dalam studi tersebut, dikumpulkan dataset dari media sosial Twitter dan Reddit yang direpresentasikan dalam empat representasi fitur, yaitu TF-IDF, word2vec dengan *weight*, word2vec tanpa *weight*, dan doc2vec. Dilakukan pula empat metode *clustering*, yaitu *K-means Clustering*, *K-medoids clustering*, *hierarchical agglomerative clustering*, dan *Non-negative matrix factorization*. Kesuksesan penelitian diukur dengan metrik evaluasi intrinsik Normalized Mutual Information (NMI), dan Adjusted Mutual Information (AMI), dan metric evaluasi ekstrinsik Adjusted Rand Index (ARI). Ditemukan bahwa representasi fitur word2vec dan metode *K-means clustering* membuahkan hasil terbaik dibandingkan kombinasi-kombinasi lainnya.

Penelitian yang dilakukan oleh Wiliams & Betak (Williams & Betak, 2019) membandingkan performa *topic modelling* Latent Dirichlet Allocation (LDA) dengan Latent Semantic Analysis (LSA) dan menemukan bahwa kedua algoritma tersebut menemukan beberapa topik yang sama, namun ada beberapa topik yang eksklusif satu sama lain. Penelitian lainnya dilakukan untuk membandingkan performa LDA dan LSA terhadap satu sama lain menggunakan dataset berita BBC dan ditemukan bahwa dalam kasus ini, *Accuracy* algoritma LDA pada nilai 82.57 lebih tinggi dari *Accuracy* algoritma LSA pada nilai 75.30 (Kalepalli, Tasneem, Phani Teja, & Manne, 2020). Algoritma LDA ditemukan memiliki nilai *divergence* yang lebih besar daripada LSA, dan direkomendasikan untuk dataset berukuran lebih kecil. Studi yang dilakukan terhadap data *e-books* menunjukkan bahwa LDA memiliki performa yang lebih baik daripada LSA (Mohammed & Al-augby, 2020). Dalam kasus terbaiknya, LDA dengan asumsi jumlah topik 20 memiliki *coherence value* sebesar 0.592179, dibandingkan LSA dengan asumsi jumlah topik 10 memiliki *coherence value* sebesar 0.577302.

Survei yang dilakukan oleh Chandola, Banerjee & Kumar (Chandola, Banerjee, & Kumar, 2009) menyatakan beberapa metode yang dapat dilakukan untuk melakukan *anomaly detection*, diantaranya adalah penerapan *density-based clustering* untuk mengelompokkan data dalam beberapa *cluster*. Poin-poin data yang menjadi *outlier* diidentifikasikan sebagai titik-titik anomali.

1.2. Perumusan Masalah

Berdasarkan latar belakang yang tertulis, dapat dirumuskan permasalahan sebagai berikut :

- Metode *feature extraction* manakah yang lebih baik untuk mencerminkan pendapat peserta diskusi sebagai acuan untuk *anomaly detection*?

- Kombinasi parameter dan *hyperparameter* seperti apakah yang dapat melakukan *anomaly detection* yang sesuai dengan kebutuhan penyelenggara diskusi?

1.3. Tujuan Penelitian

Tujuan skripsi ini adalah membandingkan *feature extraction* berbasis *embedding* dan *topic modelling* dengan LDA untuk melakukan *anomaly detection* pada transkrip diskusi Komunitas X dengan pendekatan *density-based clustering*. Pendekatan yang membuahkan hasil terbaik menurut evaluasi komite penyelenggara diskusi akan diterapkan dalam sebuah program yang dalam *pipeline*-nya mendapatkan transkrip diskusi, melakukan *pre-processing* dan vektorisasi, lalu mengidentifikasikan pendapat-pendapat yang tidak sesuai dengan topik bahasan diskusi.

1.4. Ruang Lingkup

Ruang lingkup dibatasi pada :

1. Menggunakan bahasa pemrograman *Python* dan *library-library* yang dibuat dalam bahasa *Python*.
2. Pembuatan dan uji coba algoritma akan dilakukan pada *IDE Visual Studio Code* dan *Jupyter Notebook*.
3. *Library* yang digunakan adalah *NLTK* dan *gensim* untuk *Natural Language Processing* dan *sklearn* untuk model-model *Machine Learning*. Digunakan pula beberapa *library* yang akan ditentukan untuk pembuatan GUI, sampling transkrip audio, dan integrasi komponen-komponen program.
4. Komponen-komponen berupa *speech-to-text* dan *translator* menggunakan API yang sudah ada.
5. Dataset berupa pernyataan yang tercatat dalam notulen diskusi. Satu rekor data berupa sebuah dokumen yang berisi pendapat seorang peserta diskusi yang dicatat pada satu kesempatan berbicara.
6. Untuk poin 5), dataset didapatkan dari proses transkripsi diskusi menggunakan program *speech-to-text* yang sudah ada.

7. Dataset penelitian untuk mengembangkan sistem *anomaly detection* didapatkan dari gabungan transkrip manual yang sudah dikumpulkan oleh tim penyelenggara dari sesi-sesi terdahulu.
8. Untuk poin 5), bahasa yang digunakan dalam diskusi dan pembuatan materi adalah Bahasa Inggris, dan respon-respon yang diberikan dalam Bahasa Indonesia atau bahasa campuran akan terlebih dahulu diterjemahkan ke Bahasa Inggris menggunakan API yang sudah ada.
9. Akan dilakukan *feature extraction* berupa *vectorization* melalui *word-* dan *sentence-embedding*, serta *topic modelling* untuk mengubah dokumen menjadi vektor numerik.
10. Akan juga diambil *term-document matrix* dengan metode TF-IDF sebagai metode *weighting* untuk pendekatan *vectorization* dan *topic modelling*.
11. Proses *anomaly detection* akan dilakukan dengan algoritma *Density-Based Spatial Clustering of Applications with Noise* (DBSCAN). *Outlier-outlier* yang terbentuk dari proses ini akan diidentifikasikan sebagai anomali dalam dataset.
12. Hasil penelitian ini berupa suatu program yang telah disetujui penggunaannya oleh penyelenggara diskusi Komunitas X sejak usulan ini dibuat, dan akan digunakan untuk membantu proses evaluasi diskusi dalam Komunitas X.

1.5. Metodologi Penelitian

Langkah-langkah dalam pengerjaan skripsi meliputi hal di bawah ini:

1.5.1. Studi Literatur

- Mempelajari prinsip-prinsip *Natural Language Processing* (NLP).
- Mempelajari *library-library* yang menerapkan proses-proses NLP, khususnya NLTK dan *gensim*.
- Mempelajari konsep dan teknik *vectorization* berupa *word-embedding* dan *sentence-embedding*.
- Mempelajari konsep, teknik, dan penerapan Latent Dirichlet Allocation sebagai metode *feature extraction*.
- Mempelajari konsep dan penerapan TF-IDF.
- Mempelajari definisi anomali dalam data dan mengeksplorasi metode-metode yang dapat digunakan untuk mencari anomali dalam data teks.
- Mempelajari konsep, teknik, dan penerapan metode-metode *clustering* yang ada, khususnya *density-based clustering*.

1.5.2. Pengumpulan Dataset Penelitian

- Pengumpulan dataset berupa notulen diskusi yang berupa teks.
- Pengambilan data berupa transkrip audio diskusi yang akan diolah untuk menghasilkan transkrip berupa teks.
- Penerjemahan data transkrip menjadi Bahasa Inggris untuk memudahkan proses-proses NLP.
- *Cataloging* dataset, dikelompokkan berdasarkan tanggal *event* dan peserta diskusi yang berbicara.

1.5.3. Perencanaan Penelitian dan Pengembangan Program

- Mengumpulkan data transkrip diskusi yang sudah ada, baik berupa teks atau transkrip audio.
- Mengubah data transkrip audio menjadi teks dengan API speech-to-text yang sudah ada, serta melakukan penerjemahan ke dalam Bahasa Inggris secara semi-manual dengan menggunakan bantuan API *translation* yang sudah ada.
- Menyusun data transkrip diskusi dengan struktur yang sesuai, dalam rekor-rekor yang memiliki identifikasi berupa nama peserta, identifikasi acara diskusi, dan pendapat peserta yang berbicara.
- Segmentasi data berdasarkan kategori-kategori yang ada sebagai variabel eksperimen. Akan dilakukan segmentasi teks sebagai berikut:
    - Kontribusi total peserta dalam sebuah diskusi. Satu poin data mewakili sebuah dokumen yang menggabungkan seluruh kontribusi tiap-tiap peserta dalam satu sesi diskusi.
    - Sesi berbicara. Setiap poin data mewakili transkrip yang didapatkan dari satu kesempatan seorang peserta berbicara dalam sebuah sesi diskusi.
    - Sesi berbicara dan kalimat. Setiap poin data mewakili transkrip yang didapatkan dari satu kesempatan seorang peserta berbicara dalam sebuah sesi diskusi, tapi dipisahkan per kalimat. Segmentasi ini dilakukan untuk mengubah matriks TF-IDF.
- Melakukan *preprocessing* pada data transkrip berupa *case folding*, *tokenizing*, *lemmatizing*, dan *stop-words removal*. Akan diuji kombinasi-kombinasi dari teknik *preprocessing* untuk menentukan kombinasi *preprocessing* yang menghasilkan *corpus* yang paling baik performanya.
- *Word-tokenizing* untuk mendapatkan *corpus* yang akan menjadi basis eksperimen.

- *Feature extraction* dengan pendekatan *vectorization* melalui *word embedding* dan *sentence embedding*. Akan dilakukan pengujian terhadap beberapa variabel untuk menentukan kombinasi dan parameter seperti apa yang menghasilkan fitur-fitur data yang baik performanya.
- *Feature extraction* dengan pendekatan *topic modelling*, yaitu dengan metode *Latent Dirichlet Allocation* (LDA). Akan dilakukan eksperimen dengan parameter jumlah topik yang diinferensikan untuk mencapai komposisi paling baik.
- Menerapkan *density-based clustering* untuk mendapatkan *cluster-cluster* data, dan mengidentifikasikan *outlier* pada data.
- Menggabungkan elemen-elemen yang sudah disebutkan diatas dalam sebuah data *pipeline* yang menerima data transkrip berupa teks dan mengidentifikasikan anomali-anomali yang ada dalam transkrip tersebut.
- Mengintegrasikan API-API *speech-to-text* dan *translation* yang ada untuk mengubah transkrip audio menjadi teks.
- Mendesain *use case*, *database*, dan *UI* program.

1.5.4. Pengujian Program

- Menguji penggunaan program pada beberapa transkrip audio diskusi.
- Mengumpulkan 6 penyelenggara diskusi komunitas untuk mengevaluasi anomali yang diidentifikasikan oleh program pada transkrip-transkrip diskusi yang dipakai.

1.5.5. Pengambilan Kesimpulan

- Membuat kesimpulan dari keputusan-keputusan yang dibuat oleh para penyelenggara diskusi komunitas.
- Merumuskan saran apa yang bisa dilakukan untuk penelitian berikutnya.
- Mengidentifikasikan kelemahan pada komponen-komponen program, bila ada, dan merumuskan alternatif yang mungkin memberikan performa lebih baik.

1.6. Sistematika Penulisan

Penulisan laporan skripsi ini dibagi menjadi beberapa bab, yaitu :

- Bab I : Pendahuluan

Bab ini berisikan judul, latar belakang, perumusan masalah, ruang lingkup, tujuan skripsi, dan metodologi penelitian yang akan digunakan dalam skripsi ini.

- Bab II : Landasan Teori

Bab ini berisikan teori-teori yang digunakan dan diterapkan dalam skripsi ini.

- Bab III : Analisa Dan Desain Sistem

Menjelaskan analisa masalah yang dihadapi dan perencanaan pembuatan keseluruhan sistem dalam aplikasi yang akan dibuat.

- Bab IV : Implementasi Sistem

Bab ini berisikan tentang implementasi sistem berdasarkan desain.

- Bab V : Pengujian Sistem

Bab ini berisi tentang hasil pengujian yang dilakukan terhadap aplikasi yang telah dibuat berdasarkan implementasi pada sistem yang telah dirancang dan dibuat pada Bab IV.

- Bab VI : Kesimpulan Dan Saran

Bab ini berisikan kesimpulan yang dapat diambil terhadap hasil yang dicapai, dan saran-saran yang berguna bagi pengembangan selanjutnya.

2. LANDASAN TEORI

2.1. Tinjauan Pustaka

Pada bab ini akan dijelaskan mengenai teori-teori yang akan digunakan dalam penulisan skripsi dan pembuatan aplikasi.

2.1.1. Natural Language Processing (NLP)

Natural Language Processing (NLP) adalah sebuah bidang dalam ilmu komputer dan ilmu bahasa yang mempelajari interaksi antara komputer dan bahasa natural manusia (Kumar, 2013). NLP mencakup studi dalam berbagai tingkatan dalam bahasa manusia, yaitu fonologi, morfologi, leksikon, sintaktik, semantik, pembicaraan, dan pragmatik (Ribeiro, 2021). Penerapan-penerapan NLP dapat berupa Word Processing, pengecekan dan perbaikan ejaan, Information Retrieval (IR), Information Extraction, Information Categorization, penjawaban pertanyaan, Information Summarization, dan Machine Translation (Chowdhary, 2020). Dalam penelitian ini, teknik-teknik NLP dipakai untuk memroses data transkrip yang didapatkan dari sebuah diskusi melalui program *speech-to-text*.

2.1.2. Text Preprocessing

Dalam NLP, *Text Preprocessing* adalah teknik yang digunakan untuk mempersiapkan teks yang tidak terstruktur menjadi data yang baik dan siap untuk diolah (Katryn, 2020). *Preprocessing* penting untuk dilakukan untuk mengurangi ukuran file teks dokumen yang akan dianalisa (Kannan, Gurusamy, Vijayarani, Ilamathi, & Nithya, 2014). Penggunaan teknik-teknik preprocessing dilakukan sesuai dengan karakteristik data teks dan kebutuhan penelitian. Teknik-teknik yang digunakan dalam penelitian ini antara lain *tokenization*, *stemming, lemmatization*, dan *stop word removal*.

Tokenization adalah sebuah proses memecah sebuah dokumen menjadi kumpulan kata, frasa, simbol, atau elemen-elemen lainnya yang disebut token (Kannan, Gurusamy, Vijayarani, Ilamathi, & Nithya, 2014). Secara umum, ada tiga tipe token yang bisa didapatkan dari sebuah dokumen, yaitu *word*, *character*, dan *subword* (Pai, 2020). Token bertipe *word* memecah sebuah dokumen menjadi sekumpulan kata, dan *subword* memecah sebuah dokumen menjadi sekumpulan kata yang dipecah ke bentuk dasar dan imbuhannya. Untuk penelitian ini, dilakukan *word-tokenization*, yaitu pemecahan dokumen menjadi kumpulan kata-kata yang akan

direpresentasikan dalam vektor pada proses selanjutnya. Proses *word-tokenization* ini juga dilakukan untuk mempermudah *lemmatizing* dan *stemming* yang akan dilakukan sebagai bagian dari *preprocessing*.

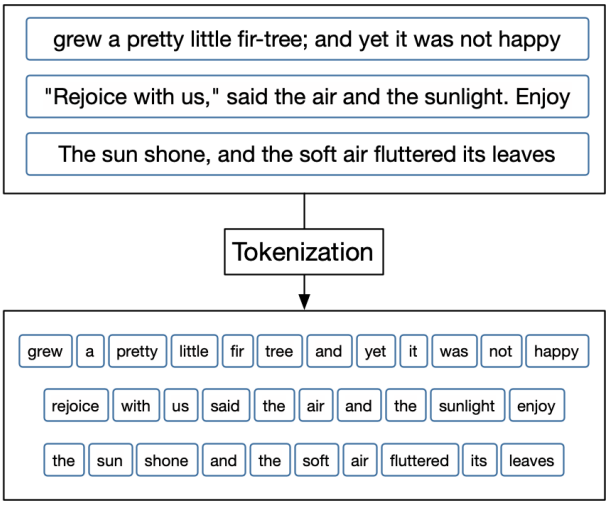

Gambar 2.1 Ilustrasi *word tokenization* (Hvitfeld & Silge, 2022)

Stemming adalah sebuah proses mengubah varian sebuah kata menjadi kata dasarnya, yang disebut *stem* atau batang (Kannan, Gurusamy, Vijayarani, Ilamathi, & Nithya, 2014). Teknik ini dilakukan untuk generalisasi kata kerja, supaya kata-kata kerja dalam bentuk bentuk berbeda tidak dianggap token-token yang berbeda. Dalam penelitian yang diajukan, karena keseluruhan data transkrip ada dalam Bahasa Inggris, dapat diterapkan algoritma Porter Stemming yang diterapkan oleh Martin Porter. Algoritma ini memanfaatkan beberapa prinsip dan aturan untuk menghilangkan *suffix* (akhiran) pada setiap kata untuk mendapatkan stem dari kata tersebut. Algoritma ini dimaksudkan untuk meningkatkan kinerja *information retrieval* dan mungkin memproduksi sebuah *stem* yang sama untuk dua kata dengan makna yang berbeda (Porter, 1980).

Lemmatization adalah proses pengelompokan bentuk-bentuk terinfleksi dari sebuah kata menjadi satu bentuk dasar (*lemma*) (Dictionary, n.d.). Tidak seperti *stemming* yang menggunakan pendekatan berdasarkan karakter, pendekatan reduksi dengan *lemmatization* bergantung pada pengetahuan tata bahasa yang bersangkutan untuk mengenali *lemma* sebuah kata infleksi. Oleh karena itu, proses ini membutuhkan proses *POS tagging* untuk mengenali bentuk kata (contohnya: “working” sebagai kata kerja atau sebagai kata sifat –tergantung konteks kalimat) untuk melakukan klasifikasi dengan benar. Dengan pendekatan ini, makna kata dapat dipertahankan dan tidak ambigu dengan *lemma* lainnya. Dalam penelitian yang akan

dijalankan, akan diuji pendekatan *stemming* dan *lemmatization* secara terpisah untuk mendapatkan hasil yang lebih baik.

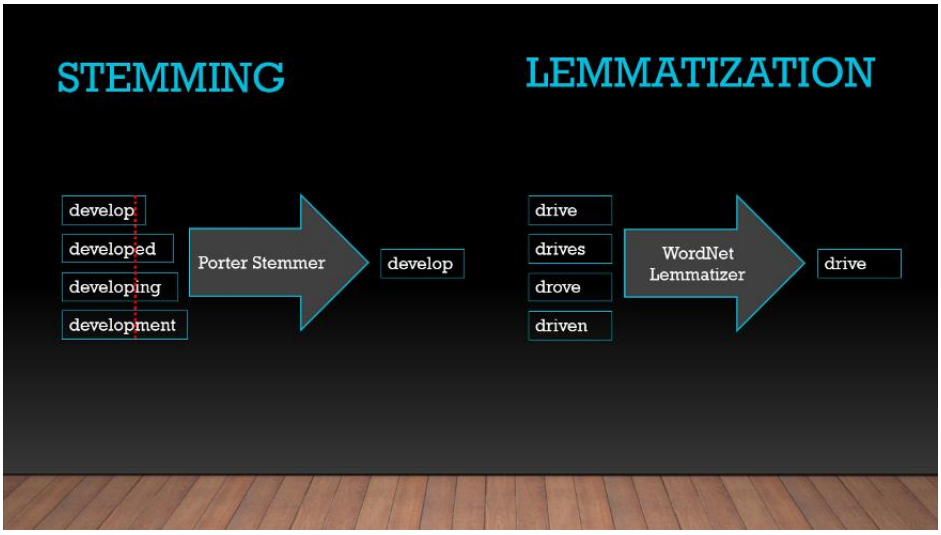

Gambar 2.2 Perbandingan pendekatan *stemming* dan *lemmatization* (Aghammadzada, 2020).

Stop word removal adalah sebuah proses penghapusan kata-kata yang frekuensi kemunculannya tinggi, namun tidak memberikan makna yang signifikan pada dokumen. *Stop word* dalam Bahasa Inggris dapat mencapai 20 hingga 30 persen jumlah kata total dalam sebuah teks dokumen (Kannan, Gurusamy, Vijayarani, Ilamathi, & Nithya, 2014). Penghapusan *stop-words* pada sebuah korpus bertujuan untuk mengurangi *noise* dan token-token kata yang redundan.

Sample text with Stop Words	Without Stop Words
GeeksforGeeks – A Computer Science Portal for Geeks	GeeksforGeeks , Computer Science, Portal ,Geeks
Can listening be exhausting?	Listening, Exhausting
I like reading, so I read	Like, Reading, read

Gambar 2.3 *Stop word removal* pada sejumlah kalimat Bahasa Inggris (GeekForGeeks, 2022)

2.1.3. Density-Based Clustering

Clustering atau *cluster analysis* adalah sebuah metode *unsupervised machine learning* yang bertujuan untuk menemukan hubungan dan pengelompokan yang sudah ada pada data (Brownlee, 2020). Metode ini disebut *unsupervised* karena tidak membutuhkan label pada data; *clustering* berfungsi untuk mengelompokkan data dan menarik kesimpulan berdasarkan kemiripan-kemiripan fitur data tersebut. Ada beberapa pendekatan yang bisa diambil untuk

melakukan *clustering*, diantaranya *centroid-based clustering*, *density-based clustering*, *distribution-based clustering*, dan *hierarchical clustering* (Google, 2022). Masing-masing pendekatan tersebut. Konsep fundamental *clustering* adalah mengidentifikasikan kelompok-kelompok yang terbentuk dari kemiripan antar rekor data. Terutama untuk data kuantitatif, digunakan fungsi yang menentukan jarak antar poin data yang dimiliki (Xu & Tian, 2015). Terdapat beberapa algoritma untuk menentukan jarak yang dipakai dalam *machine learning*, diantaranya adalah Euclidian Distance, Cosine Distance, dan Mahalanobis Distance.

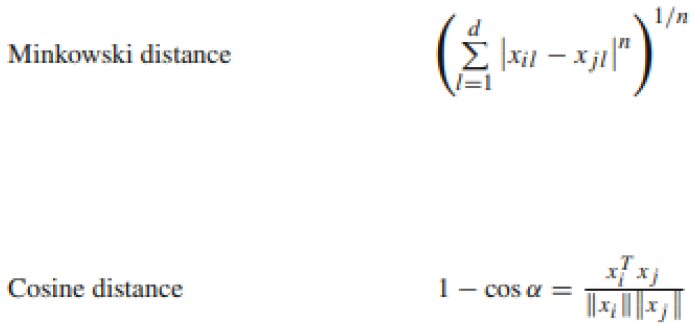

Gambar 2.4 Beberapa fungsi jarak (Xu & Tian, 2015)

Pendekatan yang diambil untuk suatu kasus tertentu harus sesuai dengan kebutuhan penelitian dan sifat dari dataset yang dimiliki, dan oleh *tools* yang tersedia untuk melakukan *clustering* (Witten, Frank, Hall, & Pal, 2016). Dalam penelitian yang diajukan, akan dilakukan *anomaly detection* dengan mengidentifikasikan outlier pada data. Oleh karena itu, *density-based clustering* akan digunakan karena tidak memasukkan *outlier* ke *cluster* manapun. (Google, 2022), dan menentukan cluster-cluster berdasarkan kedekatan relatif antar poin data. Untuk tujuan ini, akan digunakan metode DBSCAN (Density Based Spatial Clustering of Applications with Noise) untuk memproduksi *cluster-cluster* pada dataset, dengan harapan ditemukannya poin-poin data yang tidak tergabung dalam cluster manapun sebagai *outlier.* Adapun akan diuji secara paralel fungsi-fungsi jarak yang ada untuk menentukan pendekatan yang paling efektif dan sesuai dengan kebutuhan penelitian.

2.1.4. *Density-Based Spatial Clustering of Applications with Noise* (DBSCAN)

DBSCAN adalah sebuah algoritma *density-based clustering* yang membuat *cluster-cluster* pada poin-poin data yang tidak berlabel berdasarkan kedekatannya. Algoritma ini dibuat sebagai realisasi pendekatan intuitif yang dapat disimpulkan ketika mengevaluasi poin-poin data

yang memiliki kedekatan (density) tertentu yang dapat memisahkan sebuah *cluster* dengan *noise* (Ester, Kriegel, Sander, & Xu, 1996).

Algoritma DBSCAN menerima dua parameter yang ditentukan oleh pengguna, yaitu *MinPts* dan *ε* (eps; epsilon).

Adapun poin-poin data dikategorikan berdasarkan parameter yang ada sebagai berikut:

- *Core point*, jika ada *MinPts* buah poin data yang terletak dalam radius *ε* di sekelilingnya.
- Poin data *p* dikatakan *directly density-reachable point* dari poin data *q*, jika poin data *p* memiliki jarak maksimum *ε* dari *q.*
- Poin data *p* dikatakan *density-reachable point* dari poin data *q*, jika ada sebuah jalur atau path di antara poin data *p* dan *q* berupa poin-poin data yang berjarak maksimum *ε* antar satu sama lain.
- *Outlier* atau *noise point*, jika poin data tersebut tidak reachable dari poin-poin data lainnya.

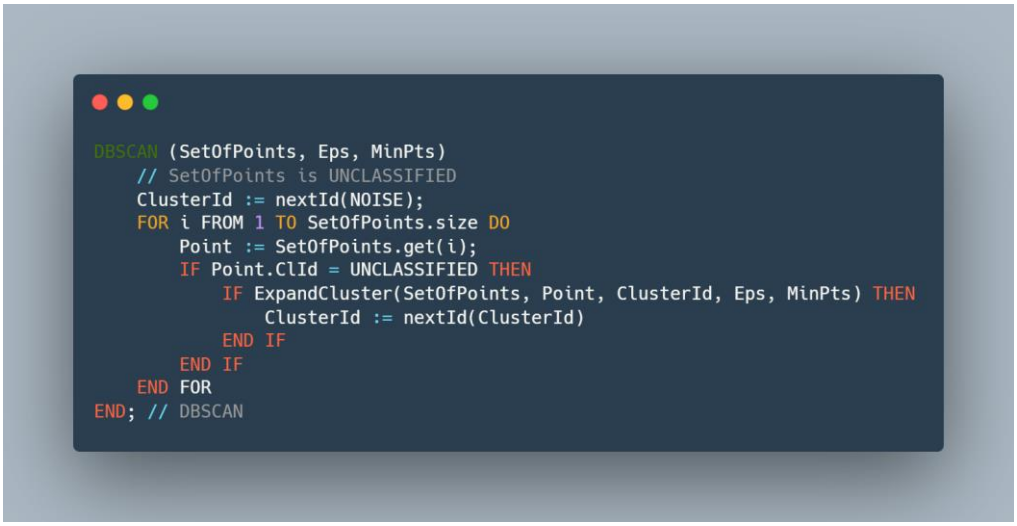

```
DBSCAN (SetOfPoints, Eps, MinPts)
    // SetOfPoints is UNCLASSIFIED
    ClusterId := nextId(NOISE);
    FOR i FROM 1 TO SetOfPoints.size DO
        Point := SetOfPoints.get(i);
        IF Point.ClId = UNCLASSIFIED THEN
            IF ExpandCluster(SetOfPoints, Point, ClusterId, Eps, MinPts) THEN
                ClusterId := nextId(ClusterId)
            END IF
        END IF
    END FOR
END; // DBSCAN
```

Gambar 2.5 Pseudocode Penerapan DBSCAN (Ester, Kriegel, Sander, & Xu, 1996)

```
ExpandCluster (SetOfPoints, Point, ClId, Eps,MinPts) : Boolean;
    seeds:=SetOfPoints.regionQuery(Point,Eps);
    IF seeds.size<MinPts THEN // no core point
        SetOfPoint.changeClId(Point,NOISE);
        RETURN False;
    ELSE    // all points in seeds are density-
            // reachable from Point
        SetOfPoints.changeClIds(seeds,ClId);
        seeds.delete(Point);
        WHILE seeds <> Empty DO
            currentP := seeds.first();
            result := SetOfPoints.regionQuery(currentP,Eps);
            IF result.size >= MinPts THEN
                FOR i FROM 1 TO result.size DO
                    resultP := result.get(i);
                        IF resultP.ClId IN {UNCLASSIFIED, NOISE} THEN
                            IF resultP.ClId = UNCLASSIFIED THEN
                                seeds.append(resultP);
                            END IF;
                            SetOfPoints.changeClId(resultP,ClId);
                        END IF; // UNCLASSIFIED or NOISE
                END FOR;
            END IF; // result.size >= MinPts
            seeds.delete(currentP);
        END WHILE; // seeds <> Empty
        RETURN True;
    END IF
END; // ExpandCluster
```

Gambar 2.6 Pseudocode Fungsi ExpandCluster() yang Dinyatakan dalam Pseudocode DBSCAN (Ester, Kriegel, Sander, & Xu, 1996).

DBSCAN diterapkan secara iteratif untuk setiap poin yang ada dalam dataset. Setiap iterasi menentukan apakah diperlukan adanya *cluster* baru atau tidak, dengan cara menghitung poin-poin yang berdekatan dengan poin data yang bersangkutan. Dalam Gambar 2.5., perhitungan dilakukan dengan menjalankan fungsi ExpandCluster() yang dijelaskan dalam Gambar 2.6. Dalam fungsi ExpandCluster(), akan dicari poin-poin yang merupakan *core point*s. Poin-poin tersebut akan diiterasi secara rekursif untuk mencari dan menandai *density-reachable points* yang ada di sekitarnya. Poin-poin yang tidak memenuhi kriteria akan ditandai sebagai *noise* atau *outlier.*

DBSCAN mendefinisikan sebuah *cluster* sebagai kumpulan poin-poin data yang *reachable* antar satu sama lain. *Outlier* adalah poin data yang tidak *reachable* dari poin-poin data lainnya. Oleh karena itu, DBSCAN akan digunakan dalam penelitian ini untuk mengidentifikasikan anomali dalam data berupa data point yang dianggap *noise* atau *outlier*.

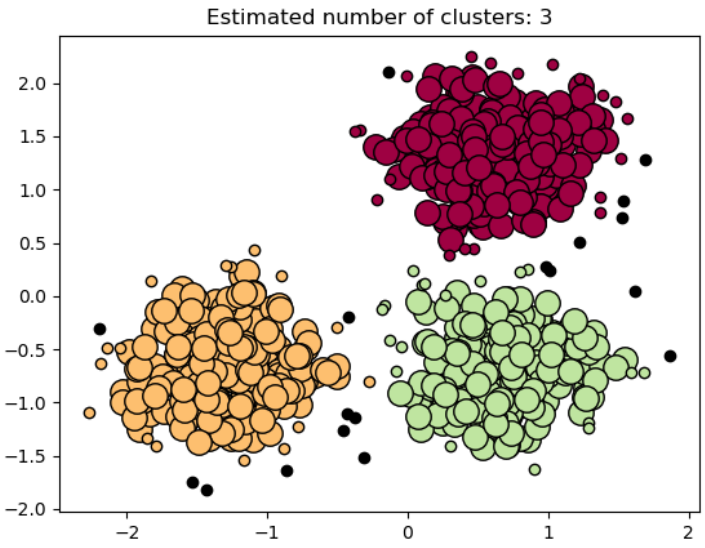

Gambar 2.7 Clustering dengan DBSCAN; poin-poin data hitam menunjukkan *outlier* (Scikit Learn).

2.1.5. Word Embedding

Word embedding adalah metode untuk menangkap makna semantik dan sintaktik kata-kata yang ada dalam sebuah korpus teks yang tidak dilabeli (Lai, Liu, He, & Zhao, 2016). Metode ini dilakukan untuk melakukan *encoding* setiap word token yang telah dikumpulkan menjadi sebuah vektor bilangan riil yang bisa direpresentasikan dalam sebuah dimensi tertentu. Vektor-vektor bilangan yang didapatkan dari hasil *embedding* dapat ditransformasikan menjadi vektor dengan dimensi lebih kecil melalui sebuah proses yang disebut *dimensionality reduction*.

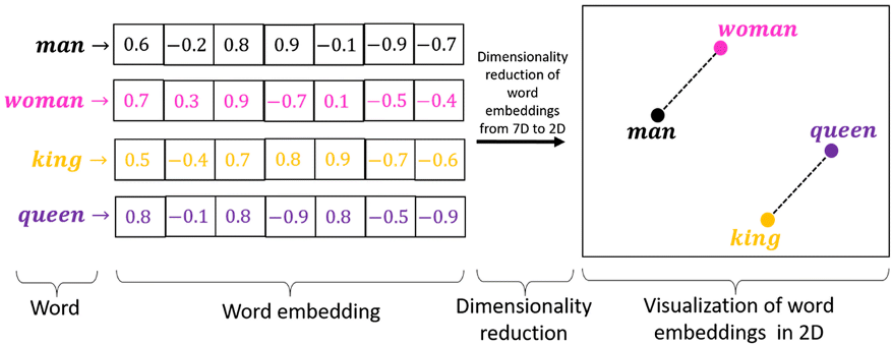

Gambar 2.8 Visualisasi *Word2Vec* (Gautam, 2020).

Word2Vec adalah suatu metode untuk membangun *Word Embedding* secara efisien berupa *neural network* yang terdiri dari dua *layer* untuk melakukan proses pengubahan teks menjadi vektor. *Word2Vec* memiliki 2 pilihan arsitektur yaitu *CBOW* (*Continuous Bag of words*) dan *Skip-Gram*.

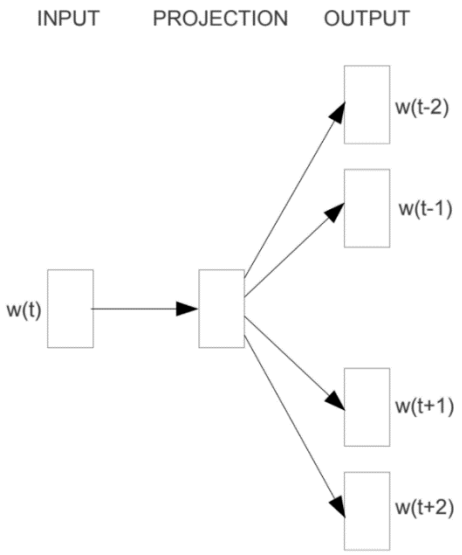

Gambar 2.9 Arsitektur *skip-gram Word2Vec* (Firdaus, 2019)

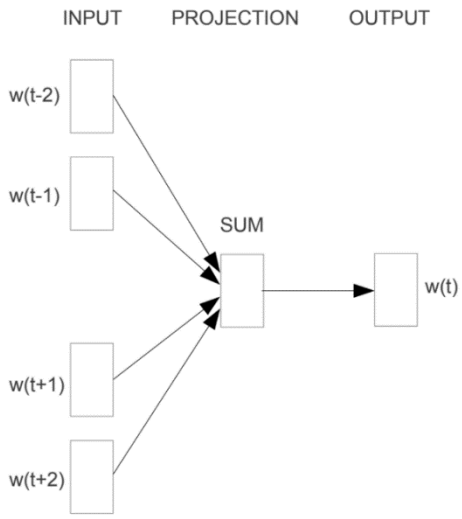

Gambar 2.10 Arsitektur CBOW *Word2Vec* (Firdaus, 2019)**.**

Arsitektur *skip-gram* memprediksi kata-kata konteks yang ada di sekitar kata utama. Sebaliknya, arsitektur *CBOW* mencoba memprediksi *encoding* sebuah kata berdasarkan kata-kata konteks di sekitarnya. Dengan arsitektur-arsitektur ini, *Word2Vec* memprediksi konteks sebuah word token dalam korpus berdasarkan sejumlah kata-kata konteks yang berdekatan dengan kata pilihan; banyaknya kata yang diambil sebagai konteks disebut dengan istilah *window*. Dalam proses *training*, pendekatan ini akan berusaha mengatur *weight* dari setiap kata sedekat mungkin dengan makna aslinya. Kata-kata yang dekat maknanya akan memiliki vektor representasi yang berdekatan dalam *embedding Word2Vec* (Firdaus, 2019). Dalam studi yang akan dilakukan, sebuah dokumen terdiri dari kumpulan *word-token*. Akan dilakukan *sentence-*

embedding untuk mengagregasikan word-embedding untuk setiap token dan mendapatkan sebuah vektor n-dimensi yang merepresentasikan sebuah dokumen.

2.1.6. *Topic Modelling*

Topic Modelling adalah sebuah algoritma yang mengidentifikasikan pola-pola tersemat dalam kata-kata dalam sekumpulan dokumen (Jacobi, van Atteveldt, & Welbers, 2015). Proses ini merupakan sebuah penerapan *unsupervised machine learning* yang digunakan untuk memodelkan topik-topik yang terkandung dalam sebuah dokumen secara probabilistik. Salah satu *topic modelling* yang populer adalah *Latent Dirichlet Allocation* (LDA). Dalam penelitian yang diajukan ini, distribusi topik per dokumen yang didapatkan dari proses *topic modelling* dengan LDA akan dianggap sebagai fitur-fitur data.

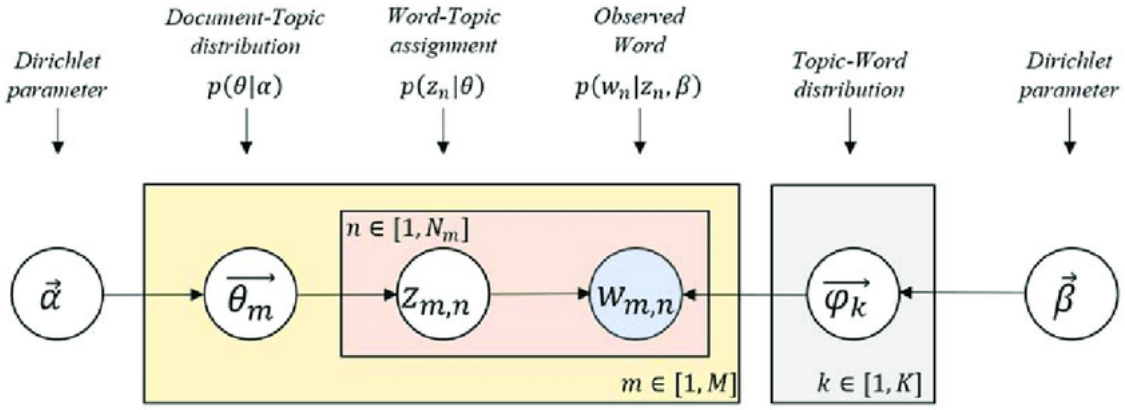

Gambar 2.11 Diagram Model LDA (Lee & et.al., 2018)

Keterangan:

- α, β : distribusi Dirichlet
- m : dokumen ke-m dalam M buah dokumen
- M : jumlah total dokumen
- n : kata ke-n dalam N buah kata
- N : jumlah total kata
- k : topik ke-k dalam K buah topik
- K : jumlah total topik
- θ_m : distribusi topik dalam dokumen ke-m
- ϕ_k : distribusi kata dalam topik ke-K
- $z_{m,n}$: topik yang didapatkan dari θ_m yang diberikan ke kata ke-n
- $w_{m,n}$: kata ke-n dalam dokumen ke-m

LDA adalah sebuah model statistika generatif yang dibuat untuk mengekstraksi variabel-variabel yang tersemat untuk mencari kemiripan dalam data. Metode ini dilakukan dengan mengambil secara stokastik sampel-sampel topik dari kumpulan topik per dokumen serta kata dari kumpulan kata per dokumen, lalu menggabungkannya dalam sebuah dokumen baru yang mengandung kata-kata dan topik yang mencerminkan dokumen awalnya (Blei, Ng, & Jordan, 2001). Dalam satu iterasi untuk generasi topik LDA, akan dicari distribusi kata-kata untuk tiap topik pada kumpulan topik K, dengan memperhatikan distribusi Dirichlet β. Akan juga dicari distribusi topik-topik untuk tiap dokumen pada kumpulan dokumen M dengan memperhatikan distribusi Dirichlet α. Untuk setiap dokumen m pada kumpulan dokumen M, akan diberikan sebuah topik yang dihasilkan dari distribusi dokumen-topik sebelumnya, dan sebuah kata yang didapatkan dari distribusi topik-kata sebelumnya, untuk menginferensikan distribusi topik per dokumen.

Proses ini akan diiterasi sebanyak yang diinginkan, untuk menghasilkan konvergensi statistika. Dalam penelitian yang akan dilakukan, akan diuji variasi jumlah topik yang akan menghasilkan distribusi topik dengan dimensi yang berbeda-beda. Diharapkan ditemukan jumlah topik yang optimal, sehingga menciptakan vektor fitur yang reflektif atas setiap dokumen.

2.1.7. TF-IDF

Term Frequency—Inverse Document Frequency (TF-IDF) adalah sebuah metode untuk memberikan *weight* sebuah kata dalam sebuah dokumen dalam sebuah korpus. Metode ini menggabungkan nilai *Term Frequency* (TF) yang mengevaluasi seberapa sering sebuah kata muncul dalam sebuah dokumen dibandingkan kata-kata lainnya, dan nilai *Inverse Document Frequency* (IDF) yang mengekspresikan perbandingan terbalik (inverse) jumlah dokumen dimana *term* atau kata tertentu muncul (Salton & Buckley, 1988).

TF dinyatakan dalam rumus sebagai berikut :

$$TF_{(t,d)} = \frac{f_{(t,d)}}{\sum_{(t\prime,d)} f_{(t\prime,d)}}$$

Rumus 2.1 *Term Frequency*

Dimana:

- t adalah *term* atau kata tertentu
- d adalah dokumen tertentu
- $TF_{(t,d)}$ adalah *term frequency* kata t dalam dokumen d.

- $f_{(t,d)}$ adalah jumlah iterasi kata t dalam dokumen d
- $\sum_{(t',d)} f_{(t',d)}$ adalah jumlah seluruh kata yang ada dalam dokumen d

IDF dinyatakan dalam rumus sebagai berikut:

$$IDF_{(t,D)} = log \frac{N}{|\{d \in D : t \in d\}|}$$

Rumus 2.2 *Inverse Document Frequency*

Dimana :

- $IDF_{(t,D)}$ adalah *inverse document frequency* kata t dalam kumpulan dokumen D
- N adalah jumlah dokumen dalam korpus
- $|\{d \in D : t \in D\}|$ adalah jumlah cacah dokumen d dalam kumpulan dokumen D, dimana kata t ada dalam dokumen d

TF-IDF dinyatakan dalam matriks hasil *dot-product* sebagai berikut:

$$TFIDF_{(t,d)} = TF_{(t,d)} \cdot IDF_{(t,D)}$$

Rumus 2.3 TF-IDF

Dalam penelitian yang akan dilakukan, *term-document matrix* yang dihasilkan dari proses TF-IDF untuk *corpus* yang akan dikumpulkan berfungsi sebagai augmentasi untuk *feature extraction*. *Term-document matrix* akan digunakan sebagai *weight* untuk proses agregasi kumpulan *word-embedding* dalam sebuah dokumen untuk menghasilkan sebuah *sentence-embedding* yang mewakili dokumen tersebut. Dalam LDA, *term-document* matrix akan digunakan sebagai input inisial yang akan mempengaruhi distribusi dan sampling untuk *topic-document matrix* dan *word-topic matrix*.

2.2. Tinjauan Studi

Berikut merupakan penelitian yang telah dilakukan sebelumnya :

2.2.1. An evaluation of document clustering and topic modelling in two online social networks: Twitter and Reddit (Curiskis & al., 2019)

Penelitian sebelumnya yang dilakukan oleh (Curiskis & al., 2019) melakukan perbandingan *clustering* dan *topic modelling* pada data *tweet* dari media sosial Twitter dan *thread* dari media sosial Reddit. Dataset direpresentasikan dalam empat representasi fitur, yaitu *TF-IDF*, *word2vec* dengan *weight*, word2vec tanpa *weight*, dan *doc2vec.* Dilakukan teknik *clustering* pada data dengan empat metode, yaitu *K-means Clustering*, *K-medoids clustering*,

hierarchical agglomerative clustering, dan *Non-negative matrix factorization*. Kesuksesan hasil *clustering* dalam penelitian ini diukur dengan NMI, AMI, dan ARI. Ditemukan bahwa performa paling baik didapatkan oleh representasi fitur dengan *word2vec* dan metode *k-means clustering*.

Penelitian yang diajukan memiliki beberapa perbedaan dengan penelitian yang dilakukan oleh (Curiskis & al., 2019). Pada penelitian yang diajukan, setiap rekor data berupa pernyataan peserta diskusi yang mungkin berisi lebih dari satu kalimat, sedangkan sebuah rekor data *tweet* pada *Twitter* tidak melebihi 255 karakter. Oleh karena itu, diatas *word-embedding word2vec*, perlu juga dilakukan *sentence embedding*. Dalam penelitian yang akan dilakukan akan dicoba dua variasi feature extraction, yaitu *word-* dan *sentence-embedding*, serta *topic modelling* dengan LDA. Fitur-fitur data akan menjadi input algoritma *density-based clustering* dengan asumsi pengetahuan dalam *domain* yang mencukupi, dan dengan harapan bahwa hasil *clustering* akan mencerminkan cluster-cluster yang ada dalam data dan memproduksi *outlier*. Selain itu, karena dataset yang tersedia dan yang akan dikumpulkan dalam penelitian ini tidak memiliki label, tidak ada asumsi *ground truth*. Oleh karena itu, pengukuran kesuksesan *clustering* akan dilakukan dengan validasi oleh pengguna.

2.2.2. A Comparison of LSA and LDA for the Analysis of Railroad Accident (Williams & Betak, 2019)

Penelitian selanjutnya (Williams & Betak, 2019) membandingkan performa *topic modelling* LDA dengan LSA, dan menemukan bahwa kedua metode menemukan beberapa topik yang eksklusif satu sama lain. Penelitian ini juga menyatakan bahwa algoritma LDA direkomendasikan untuk dataset yang berukuran lebih kecil. Dalam penelitian yang akan diajukan, LDA akan digunakan untuk mengekstraksi topik dari setiap dokumen yang berupa pendapat peserta diskusi. Distribusi topik dalam tiap dokumen akan dianggap sebagai fitur-fitur data yang menjadi basis density-based clustering untuk mencari poin-poin data yang merupakan *outlier*.

2.2.3. Anomaly Detection: A Survey (Chandola, Banerjee, & Kumar, Anomaly Detection: A Survey, 2009)

Survei yang dilakukan oleh Chandola, Banerjee & Kumar (Chandola, Banerjee, & Kumar, Anomaly Detection: A Survey, 2009) menyatakan beberapa metode yang dapat dilakukan untuk melakukan *anomaly detection*, diantaranya adalah penerapan *density-based clustering* untuk mengelompokkan data dalam beberapa *cluster*. Poin-poin data yang menjadi *outlier*

diidentifikasikan sebagai titik-titik anomali. Dalam penelitian yang diajukan, akan dilakukan *density-based clustering* pada vektor-vektor fitur data yang telah didapatkan dari fase *feature extraction* yang telah dilakukan. *Outlier-outlier* yang terbentuk oleh *clustering* yang dilakukan akan diidentifikasikan sebagai anomali dalam data dan diuji validitasnya.

3. ANALISA DAN DESAIN SISTEM

Pada bab ini akan lebih dibahas lebih lanjut mengenai analisa dan desain dan rancangan sistem yang digunakan untuk mendeteksi.

3.1. Analisa Permasalahan

Diskusi terstruktur adalah sebuah proses dimana sekelompok orang berkumpul untuk berbagi informasi, gagasan, dan mengkaji sebuah topik menurut sebuah format yang telah ditentukan. Dalam sebuah diskusi terstruktur, terdapat sebuah rangkaian acara yang didesain untuk menggiring jalannya diskusi terhadap topik yang telah dipilih agar mencapai hasil yang diinginkan. Dalam Komunitas X yang merupakan komunitas multi-agama dengan mayoritas beragama Kristen, dilakukan diskusi terstruktur secara rutin mengenai topik-topik yang berkenaan dengan agama, moralitas, dan etika. Diskusi-diskusi terstruktur yang diadakan oleh Komunitas X mengharapkan para pesertanya mengikuti rangkaian dan peraturan-peraturan yang telah ditentukan oleh penyelenggara, meliputi giliran berbicara, kesesuaian dengan topik, kesopanan dalam menyampaikan kontribusi, dan larangan untuk melakukan interupsi.

Diskusi terstruktur dalam Komunitas X dipimpin oleh seorang fasilitator, dan diawasi oleh seorang moderator. Fasilitator bertugas untuk melakukan eksposisi terhadap topik yang diambil untuk sesi diskusi tersebut, dan menyampaikan pemicu diskusi menurut rincian subtopik diskusi yang telah dipersiapkan sebelumnya. Adapun moderator bertugas untuk menjembatani kontribusi-kontribusi peserta diskusi dengan topik yang sedang dibahas, serta menyaring dan menegur peserta jika kontribusi yang ditawarkan tidak sesuai dengan peraturan dan pedoman diskusi. Moderator juga bertugas untuk membuat notulen diskusi untuk mencatat kontribusi setiap peserta dalam sebuah sesi diskusi. Notulen diskusi ini akan dievaluasi pada pertemuan mingguan untuk menilai apakah kontribusi setiap peserta sesuai dengan harapan, atau malah melenceng dari pertanyaan-pertanyaan pemicu dan tidak menghasilkan input sesuai harapan.

Terdapat beberapa kendala dalam sistem pencatatan dan evaluasi yang diterapkan oleh penyelenggara diskusi dalam Komunitas X, baik pada waktu sesi diskusi maupun rapat evaluasi. Pada sebuah sesi diskusi, moderator menjalankan tugasnya sembari merangkap menjadi notulis. Seringkali, panjangnya kontribusi seorang peserta membuat moderator harus melakukan parafrase agar dapat mencatatnya tepat waktu. Akibatnya, data yang dicatat mungkin mengandung bias moderator dan tidak mencerminkan pendapat peserta yang sebenarnya, dan

akan berpengaruh pada proses evaluasi. Pada rapat evaluasi, terdapat kesulitan untuk mengidentifikasikan pendapat-pendapat yang tidak sesuai dengan topik karena data notulen yang terparafrase dengan bias moderator atau kontribusi peserta tertentu yang panjang sehingga sulit untuk dicari esensinya.

Keperluan yang perlu untuk ditangani adalah deteksi kontribusi peserta yang bersifat ganjil (*anomalous*). Anomali atau keganjilan yang diamati berupa ketidaksesuaian konten pendapat peserta diskusi dengan subtopik yang ditawarkan dalam sebuah sesi diskusi. Asumsi didasarkan oleh pengamatan bahwa kontribusi-kontribusi yang ganjil umumnya berasal dari sejumlah kecil individu yang menyatakan pendapat yang melebar dari topik, dan sebagian besar anggota diskusi umumnya menawarkan kontribusi yang sesuai dengan topik dan pertanyaan-pertanyaan pemicu yang diajukan. Oleh karena itu, akan dilakukan *unsupervised learning* untuk mendeteksi kecenderungan *cluster* yang ada dalam data transkrip diskusi.

Studi yang akan dilakukan bertujuan untuk menciptakan sebuah *pipeline* data yang melakukan transkripsi kontribusi setiap peserta, menerjemahkannya ke Bahasa Inggris, melakukan *preprocessing* yang sesuai, lalu mengekstraksi fitur dengan pendekatan *word-* dan *sentence-embedding,* serta *topic modelling*. Setelah fitur-fitur berhasil diekstraksi, akan dilakukan pendekatan *density-based clustering* untuk mengamati kecenderungan *cluster* yang terbentuk dari kontribusi-kontribusi peserta dalam sebuah sesi, dan mengidentifikasikan *outlier*. Studi diadakan untuk menguji apakah pendekatan yang dilakukan dengan komponen-komponen yang digabungkan dapat menghasilkan *outlier* yang mencerminkan anomali data yang diharapkan oleh penyelenggara.

3.2. Desain Eksperimen

Secara garis besar, eksperimen yang akan dilakukan bertujuan untuk membuat sebuah *pipeline* inti yang menggabungkan komponen-komponen *preprocessing*, *feature extraction*, dan *density-based clustering* serta *hyperparameter*-nya untuk mengelompokkan data transkrip ke dalam *cluster-cluster* yang mencerminkan kedekatan setiap kontribusi peserta dalam sebuah sesi diskusi. Setelah itu, akan diidentifikasikan *outlier-outlier* pada dataset sebagai anomali – kontribusi peserta diskusi yang ganjil dan melenceng dari bahasan topik. Eksperimen yang akan dilakukan akan berfokus pada *feature extraction –vectorization* dengan *word-* dan *sentence-embedding*, dan *topic modelling* dengan LDA, serta pencarian *hyperparameter-hyperparameter* yang tepat pada LDA dan DBSCAN. Dalam eksperimen yang dilakukan, diharapkan dapat dicari

range parameter yang dapat mengidentifikasikan *outlier* yang sesuai dengan definisi yang diharapkan oleh penyelenggara diskusi dalam komunitas.

3.2.1. Corpus Data Tranksrip

Data transkrip yang digunakan untuk menjalankan eksperimen tersusun dari data teks notulen dari beberapa sesi diskusi, serta transkrip audio dari beberapa diskusi yang telah diadakan. Transkrip audio akan diubah menjadi transkrip teks dengan menggunakan API Google Speech-to-text. Bagian-bagian yang berbahasa Indonesia akan diterjemahkan dengan menggunakan API penerjemahan DeepL. Adapun data transkrip yang sudah berupa teks akan disimpan dengan format yang sudah ditentukan. Berikut sebuah tabel yang berisi beberapa rekor data:

Tabel 3.1 Struktur Penyimpanan Data

No	Question	Answer	Event	Speaker
1	How did we come to exist?	Everybody should believe that they are creations, made by a creator. It is a prerequisite to believing anything else that comes after.	19-Feb	P
2	How did we come to exist?	We came from evolution. This is undeniable, and the Charles Darwin's evolution model is the most widely accepted theory to this. We evolved from unicellular bacteriae, to fish, to amphibious creatures, to mammals, to apes, then all the way to humans.	19-Feb	G
4	Do you think you need to exist?	I don't think we need to exist. As Peter said, everything would just go on as usual, regardless of your existence or not.	19-Feb	Je
39	What is the difference between a mistake and a sin?	If a man does wicked things while not being sane, he also sins.	26-Feb	G
46	What sin leads to hell?	I think there are no sins that are greater or lesser than others, all sin leads to hell.	26-Feb	P
69	We see from our side that maybe they are miserable. But how do we get the right to decide who lives and who doesn't?	Is it wrong to regret life? That is the right of the individual. The fetus is special because of the human species, even though it may have the same abilities as a chimpanzee. Life goes on, no matter how bad it is.	2-Jul	G

70	We see from our side that maybe they are miserable. But how do we get the right to decide who lives and who doesn't?	Actually, we humans are well aware that life is really difficult. Only he will know what his difficulties and limitations are. It is precisely because we know life is difficult. Science is not based on morals, while we humans have moral standards. Can everything that is presented with standards and data refer to justice? Everything has a consequence. Does that consequence make it better or worse? Not prolife and prochoice but what is from God is what is lived.	2-Jul	Yot

Legenda tabel:

- Kolom “No” menyatakan nomor rekor data, dan akan digunakan untuk mengidentifikasikan dokumen pada eksperimen yang akan dilakukan.
- Kolom “Question” menyatakan pertanyaan pemicu yang menghasilkan kontribusi yang tercatat, dan akan digunakan untuk kategorisasi dokumen pada eksperimen yang akan dilakukan.
- Kolom “Answer” berisi kontribusi peserta diskusi terhadap pertanyaan (question) yang menjadi pemicu. Konten dari kolom ini dianggap sebagai dokumen yang akan digunakan sebagai bahan utama eksperimen.
- Kolom “Event” menandakan kode sesi diskusi dimana rekor data dicatat. Kolom ini akan digunakan untuk kategorisasi dokumen pada eksperimen yang akan dilakukan.
- Kolom “Speaker” digunakan untuk mengidentifikasi peserta diskusi yang menghasilkan kontribusi yang tercatat. Identitas peserta diskusi disamarkan untuk menjaga privasi. Kode yang tercatat bisa ditafsirkan oleh penyelenggara diskusi.

3.2.1.1.1. Pengumpulan Data

Penyelenggara diskusi di Komunitas X menyimpan notulen-notulen diskusi yang telah dilakukan dalam bentuk teks. Terhitung ada 14 sesi diskusi yang telah tercatat dalam notulen diskusi. Kontribusi-kontribusi peserta yang tercatat dalam notulen-notulen diskusi ini akan digunakan sebagai bahan eksperimen. Selain itu, terhitung sejak 31 Maret 2023, telah terkumpul

dua transkrip audio dari diskusi yang dilakukan oleh Komunitas X. Transkrip-transkrip audio disimpan dalam file *.ogg*, dan akan diubah menjadi transkrip teks terlebih dahulu sebelum diolah lebih lanjut.

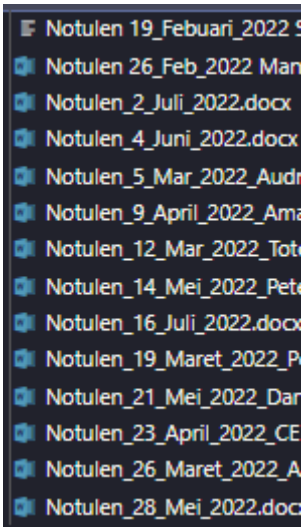

Gambar 3.1 Notulen diskusi yang telah terkumpul, disimpan dalam 14 *file*.

Dataset berupa notulen akan dipilah dan dimasukkan ke dalam tabel dengan struktur yang telah dijelaskan pada Tabel 3.1, sesuai dengan pertanyaan pemicu, sesi diskusi, dan kode pembicara. Beberapa notulen yang berisi parafrase singkat dikembangkan berdasarkan gagasan-gagasan yang telah ditulis sehingga membentuk kalimat-kalimat yang koheren dan sedekat mungkin dengan gagasan parafrase yang ditulis. Adapun untuk data yang berupa transkrip audio, akan dilakukan dua kali proses transkripsi: secara manual dan dengan menggunakan API Speech-to-text Google. Hasil dari kedua transkripsi akan diterjemahkan dengan bantuan API DeepL ke dalam Bahasa Inggris dan akan dibandingkan dalam kerangka eksperimen yang sama.

Dengan menganggap kolom “Answer” dari setiap rekor data sebagai sebuah dokumen, terbentuklah sebuah *corpus* teks yang terdiri dari kumpulan kontribusi peserta diskusi terhadap pertanyaan pemicu (kolom “Question”). *Preprocessing*, *feature extraction*, dan *clustering* akan dilakukan terhadap *corpus* yang terbentuk.

3.2.2. Text Preprocessing

Text Preprocessing dilakukan untuk mempersiapkan data teks yang tidak terstruktur untuk diolah (Katryn, 2020). Dalam penelitian ini, akan digunakan teknik-teknik *preprocessing* yang mempersiapkan data teks untuk *feature extraction* dengan pendekatan *word-embedding*, *sentence-embedding*, *TF-IDF*, dan *topic modelling*. Oleh karena itu, preprocessing yang dilakukan

berfokus pada upaya mengurangi *noise* dan redundansi pada data untuk menghasilkan token-token yang berkualitas.

3.2.2.1.1. Case-Folding

Pada data teks akan dilakukan *case-folding*, yaitu pengubahan semua karakter huruf menjadi huruf kecil. Proses ini dilakukan untuk menghilangkan redundansi *string* yang menyebabkan *noise* pada data.

3.2.2.1.2. Stop Word Removal

Pada data teks akan juga dihapus kata-kata yang frekuensi kemunculannya tinggi, namun tidak bermakna signifikan pada dokumen. Proses ini dilakukan untuk mengurangi redundansi yang disebabkan oleh kata-kata yang berfrekuensi tinggi. Rincian kata-kata yang termasuk *stop words* akan didapatkan dari library NLP yang digunakan.

3.2.2.1.3. Stemming dan Lemmatizing

Stemming adalah proses pengubahan sebuah kata menjadi sebuah elemen dasar yang disebut *stem* atau batang (Kannan, Gurusamy, Vijayarani, Ilamathi, & Nithya, 2014). Proses ini dilakukan untuk generalisasi kata kerja, supaya variasi-variasi kata kerja dalam Bahasa Inggris (contohnya: “work” dan “working”) dapat dikenali sebagai token yang sama. Dalam eksperimen yang akan dilakukan, akan diterapkan algoritma Porter Stemming yang disediakan oleh *library* NLP yang digunakan.

Lemmatizing adalah proses pengelompokan dan pengubahan sebuah kata berdasarkan *lemma*(kata dasar)-nya. Proses lemmatizing akan mengembalikan sebuah token kata yang valid, namun membutuhkan komponen POS Tagging untuk menentukan unsur kata (contohnya: “working” dapat dikategorikan sebagai *verb* atau *adjective*, tergantung dengan konteks). Proses ini akan dilakukan dengan bantuan library NLP yang digunakan. Akan dilakukan perbandingan penggunaan *lemmatizing* dan *stemming* pada *pipeline* data yang akan dibuat.

3.2.2.1.4. Tokenization

Tokenization adalah proses pemecahan sebuah dokumen menjadi kumpulan token (Kannan, Gurusamy, Vijayarani, Ilamathi, & Nithya, 2014). Dalam studi ini, karena studi berada di tingkat *lexical*, setiap dokumen akan dipecah menjadi token-token kata (*word tokens*). Dengan mengubah sebuah dokumen menjadi sekumpulan token, beberapa proses, seperti stemming dan *lemmatizing* serta *feature extraction* akan lebih mudah dilakukan. Proses *tokenization* akan dilakukan dengan bantuan library NLP yang digunakan.

3.2.3. Feature Extraction

Feature extraction adalah proses untuk mengubah setiap token yang sudah dibersihkan dengan *preprocessing* menjadi sekumpulan angka yang merepresentasikan token tersebut. Hal ini dilakukan agar token bisa menjadi input pada model *density-based clustering* yang akan digunakan. Dalam studi ini, akan dilakukan dua pendekatan *feature extraction*, yaitu *vectorization* dengan *word-* dan *sentence-embedding*, serta *topic modelling* dengan LDA. Kedua pendekatan akan diuji secara paralel untuk menentukan kinerja yang lebih baik untuk studi yang dilakukan.

3.2.3.1.1. Pendekatan Word- dan Sentence-Embedding

Pendekatan *word-embedding* digunakan untuk mengekspresikan makna semantik dan sintaktik token-token kata dalam sebuah corpus yang tidak dilabeli (Lai, Liu, He, & Zhao, 2016). Dengan pendekatan ini, setiap word token yang dihasilkan oleh proses *tokenization* akan memiliki representasi dalam bentuk sebuah vektor n-dimensi. Proses *word-embedding* akan dilakukan dengan metode *Word2Vec* yang sudah tersedia dalam *library* yang digunakan. Akan dilakukan perbandingan secara paralel pengujian beberapa variabel, diantaranya jumlah dimensi, serta model yang dibangun sendiri dan *pre-trained model*.

Adapun pendekatan *sentence-embedding* digunakan untuk menangkap makna sebuah kalimat atau dokumen yang terdiri dari sekumpulan *word token* yang sudah *di-embed* menjadi vektor. Vektor-vektor yang dihasilkan lewat *word-embedding* setiap token yang ada dalam satu dokumen akan diagregasikan menjadi satu *sentence vector* yang berdimensi sama. Akan diuji beberapa metode agregasi untuk menentukan kinerja yang paling baik. Metode-metode agregasi yang akan diuji adalah *averaging*, *sum*, *weighted-averaging*, dan *weighted-sum*; *weight* atau berat yang akan digunakan diambil dari nilai TF-IDF setiap token pada dokumen yang bersangkutan. Luaran dari proses ini adalah sebuah vektor berdimensi-n untuk setiap dokumen, dimana n adalah jumlah dimensi yang ditentukan oleh peneliti. Vektor dari setiap dokumen akan menjadi input untuk algoritma *density-based clustering* yang akan digunakan.

3.2.3.1.2. Pendekatan Topic Modelling

Metode *feature extraction* menggunakan *topic modelling* akan diuji sebagai alternatif dari pendekatan *embedding*. Dalam pendekatan ini, akan dicari pola-pola tersemat dalam token-token kata yang ada dalam sebuah dokumen (Jacobi, van Atteveldt, & Welbers, 2015), dengan asumsi jumlah topik tertentu. Pendekatan ini adalah pendekatan stokastik, sehingga dapat menghasilkan keputusan yang berbeda-beda dalam setiap operasi dengan parameter dan input yang sama. Akan diuji beberapa variasi parameter yang mempengaruhi algoritma LDA,

diantaranya jumlah topik yang diasumsikan –akan diuji beberapa jumlah topik sesuai dengan studi literatur tentang LDA dan LSA (Williams & Betak, 2019). Akan diuji juga performa algoritma dengan input tambahan berupa TF-IDF sebagai *term-document matrix*. Luaran dari proses ini adalah sebuah vektor berdimensi-n, dimana n merupakan jumlah topik yang diinferensikan. Nilai dari setiap dimensi dari vektor yang terbuat melambangkan proporsi topik yang diinferensikan yang terkandung dalam dokumen yang bersangkutan. Kumpulan vektor yang didapatkan dari setiap dokumen akan menjadi input untuk algoritma *density-based clustering* yang akan digunakan.

3.2.3.1.3. TF-IDF

TF-IDF (Term Frequency-Inverse Document Frequency) adalah metode statistical untuk mendapatkan *term-document matrix* yang mewakili relevansi setiap kata pada setiap dokumen pada *corpus*. *Matrix* yang didapatkan dari proses TF-IDF untuk corpus yang menjadi bahan penelitian akan digunakan untuk augmentasi dan *weighting* metode-metode *feature extraction* yang digunakan, dengan harapan bahwa relevansi setiap token dicerminkan dari matriks yang didapatkan.

3.2.4. Density-based Clustering

Setelah *feature extraction* dijalankan untuk setiap dokumen dalam *corpus*, akan dilakukan proses *density-based clustering* dengan DBSCAN (*Density-Based Spatial Clustering of Applications with Noise*). Penggunaan metode ini bertujuan untuk mendapatkan *cluster-cluster* berdasarkan kedekatan vektor-vektor setiap dokumen yang telah didapatkan dengan metode *feature extraction* yang telah dipilih. *Feature extraction* yang baik akan menghasilkan data yang berkualitas dan merefleksikan dokumen sesungguhnya. Diharapkan akan ditemukan poin-poin data yang tidak tergabung dalam *cluster* manapun untuk diidentifikasikan sebagai *outlier*.

3.2.5. DBSCAN dan Parameter-Parameternya

DBSCAN adalah *algoritma density-based clustering* yang membuat *cluster-cluster* berdasarkan kedekatannya (Ester, Kriegel, Sander, & Xu, 1996). Pendekatan ini dipilih karena bisa menghasilkan *outlier* dalam bentuk poin-poin data yang terletak jauh dari *cluster-cluster* yang terbentuk. Dalam algoritma ini, terdapat dua parameter yang dapat diubah-ubah, yaitu *MinPts* –jumlah poin data minimum yang ada di sekeliling sebuah poin data, dan ε –radius dimana *MinPts* diperhitungkan. DBSCAN akan diterapkan dan divisualisasikan dengan *library* yang telah disediakan.

3.2.6. Fungsi Jarak yang Akan Digunakan

Fungsi jarak yang digunakan dapat mempengaruhi pembentukan cluster karena perbedaan karakteristik masing-masing fungsi jarak yang dikenali. Dalam penelitian ini, akan dibandingkan secara paralel beberapa fungsi jarak, diantaranya Euclidean Distance, Cosine Distance, dan Mahalanobis Distance.

3.2.7. Anomaly Detection and Validation

Dalam eksperimen yang dilakukan, diasumsikan hipotesis utama bahwa *outlier-outlier* yang ditemukan adalah *lexical anomaly* pada data, dan mencerminkan kontribusi peserta diskusi yang ganjil atau tidak sesuai topik. Hasil dari eksperimen-eksperimen ini akan divalidasi oleh tim penyelenggara diskusi Komunitas X, yang berperan sebagai pengguna dan memiliki kapasitas dalam *domain* yang bersangkutan. Akan ditentukan apakah *outlier* yang ditemukan oleh program yang dibuat mencerminkan kontribusi yang ganjil atau tidak.

3.3. Desain Eksperimen dan Program

Bagian ini akan menjelaskan tentang desain eksperimen untuk mendeteksi anomali, serta desain program implementasi yang akan dibuat.

3.3.1. Alur Eksperimen

3.3.1.1.1. Pengumpulan Data

Pada tahap ini *corpus* dibangun dari notulen dan transkrip audio. Data dari Notulen akan langsung dimasukkan ke dalam tabel data dengan format yang telah ditentukan. Adapun transkrip yang berupa audio akan diubah dahulu menjadi transkrip teks melalui API Speech-to-text Google. Setelah itu, untuk input yang tidak berbahasa Inggris, akan diterjemahkan ke dalam Bahasa Inggris dengan API DeepL dan intervensi manual. Kedua proses ini akan dilakukan secara terpisah dan dijalankan secara paralel, untuk menguji efektivitas komponen API speech-to-text dan translation. Pada akhir proses ini, data yang tersimpan dalam tabel akan diakses dengan program dan dikenakan *text preprocessing*.

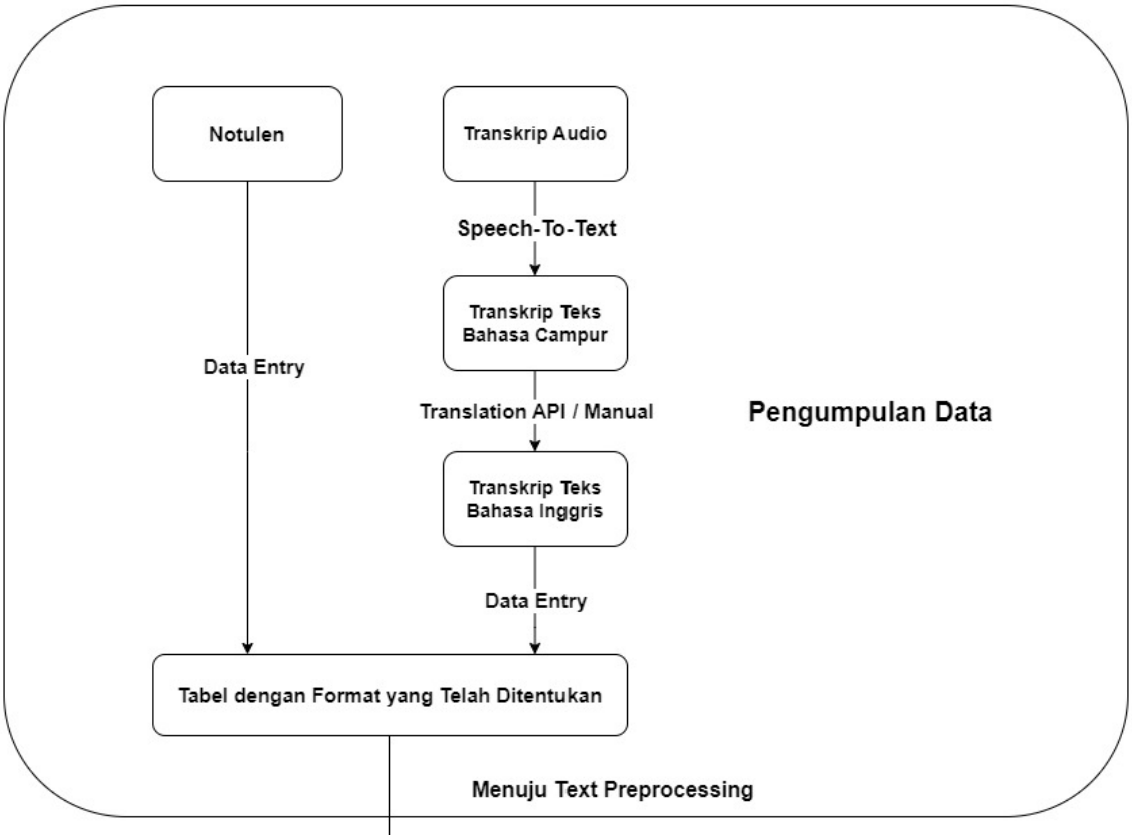

Gambar 3.2 Diagram Alur Eksperimen – Pengumpulan Data

3.3.1.1.2. Text Preprocessing

Text preprocessing dimulai dari *case-folding* untuk meratakan isi *corpus*, menjadikannya *lower case*. Setelah itu, akan dihilangkan tanda baca dan elemen-elemen nonesensial lainnya seperti angka yang tidak relevan. Dokumen-dokumen yang hanya berisi karakter-karakter alfabetik akan dijadikan kumpulan *word tokens* dengan fungsi *word tokenize*, menghasilkan dokumen-dokumen yang berisi kumpulan token. Untuk setiap dokumen, akan dijalankan proses *stop words removal*, untuk menghapus token-token yang frekuensinya tinggi namun tidak menawarkan banyak makna, untuk mengurangi *noise* dalam data. Selanjutnya, akan dijalankan secara paralel *stemming* dan *lemmatization*, untuk dibandingkan hasilnya. Kedua proses itu akan mengubah setiap dokumen menjadi kumpulan token yang berisi *stem* atau *lemma* dasar dari setiap kata, dan siap untuk memasuki tahap *feature extraction*.

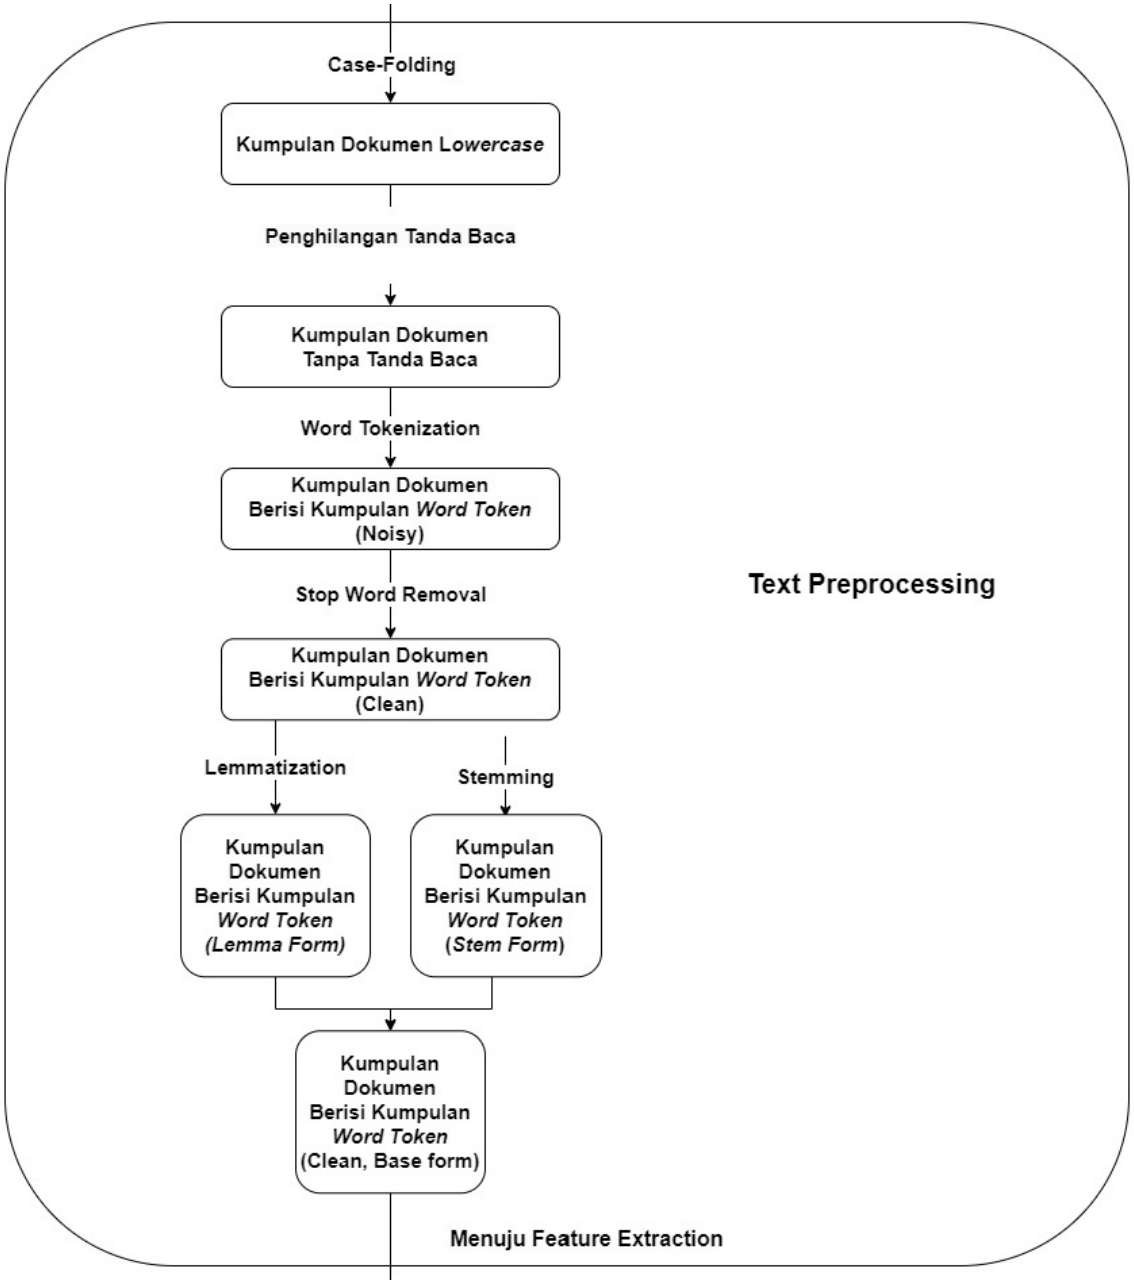

Gambar 3.3 Diagram Alur Eksperimen – Text Preprocessing

3.3.1.1.3. Feature Extraction

Untuk proses *feature extraction*, ada dua pendekatan utama yang akan diuji, yaitu pendekatan *topic modelling* lewat LDA, dan pendekatan *embedding* lewat *word-embedding* dan *sentence-embedding.* Akan juga dijalankan TF-IDF untuk mendapatkan *term-document matrix*, yang merupakan sebuah nilai numerik untuk setiap *word token* di setiap dokumen, sebagai variabel pengujian pada dua metode *feature extraction* yang dipakai. *Topic modelling* dan *word/sentence-embedding* akan dijalankan secara paralel untuk dibandingkan performanya.

Dalam pendekatan *embedding*, akan dilakukan *word-embedding* pada setiap token kata yang terkandung dalam setiap dokumen. Akan digunakan variasi model Word2Vec, dengan menggunakan beberapa *pre-trained model* yang sudah tersedia serta model yang dibangun sendiri. Akan dilakukan juga variasi jumlah dimensi vektor yang dihasilkan. Setelah setiap word-token berhasil di-embed, akan dilakukan agregasi pada setiap word-token yang dimiliki sebuah dokumen, untuk mendapatkan sebuah vektor yang merepresentasikan dokumen tersebut (*sentence-embedding*). Akan dicoba secara paralel dan dibandingkan metode *aggregation* dengan *averaging* dan *sum*, serta *weighted averaging* dan *weighted sum* dengan menggunakan *term-document matrix* sebagai *weight.* Proses agregasi ini akan menghasilkan sebuah *n-dimensional numerical vector* untuk setiap dokumen.

Dalam pendekatan *topic modelling* dengan LDA, akan dilakukan variasi eksperimen, yaitu proses LDA sebagaimana adanya, dibandingkan dengan proses LDA dengan input TF-IDF sebagai *term-document matrix*, dengan harapan weight yang diberikan oleh matriks tersebut mempengaruhi probabilitas stokastik. Akan juga dilakukan variasi jumlah topik yang diinferensikan, untuk mencari jumlah topik optimal yang bisa menghasilkan distribusi topik yang baik. Proses LDA akan menghasilkan sebuah *n-dimensional numerical vector* untuk setiap dokumen, dengan n merupakan jumlah topik yang diinferensikan, dan setiap dimensi vektor melambangkan proporsi topik tersebut pada dokumen yang bersangkutan.

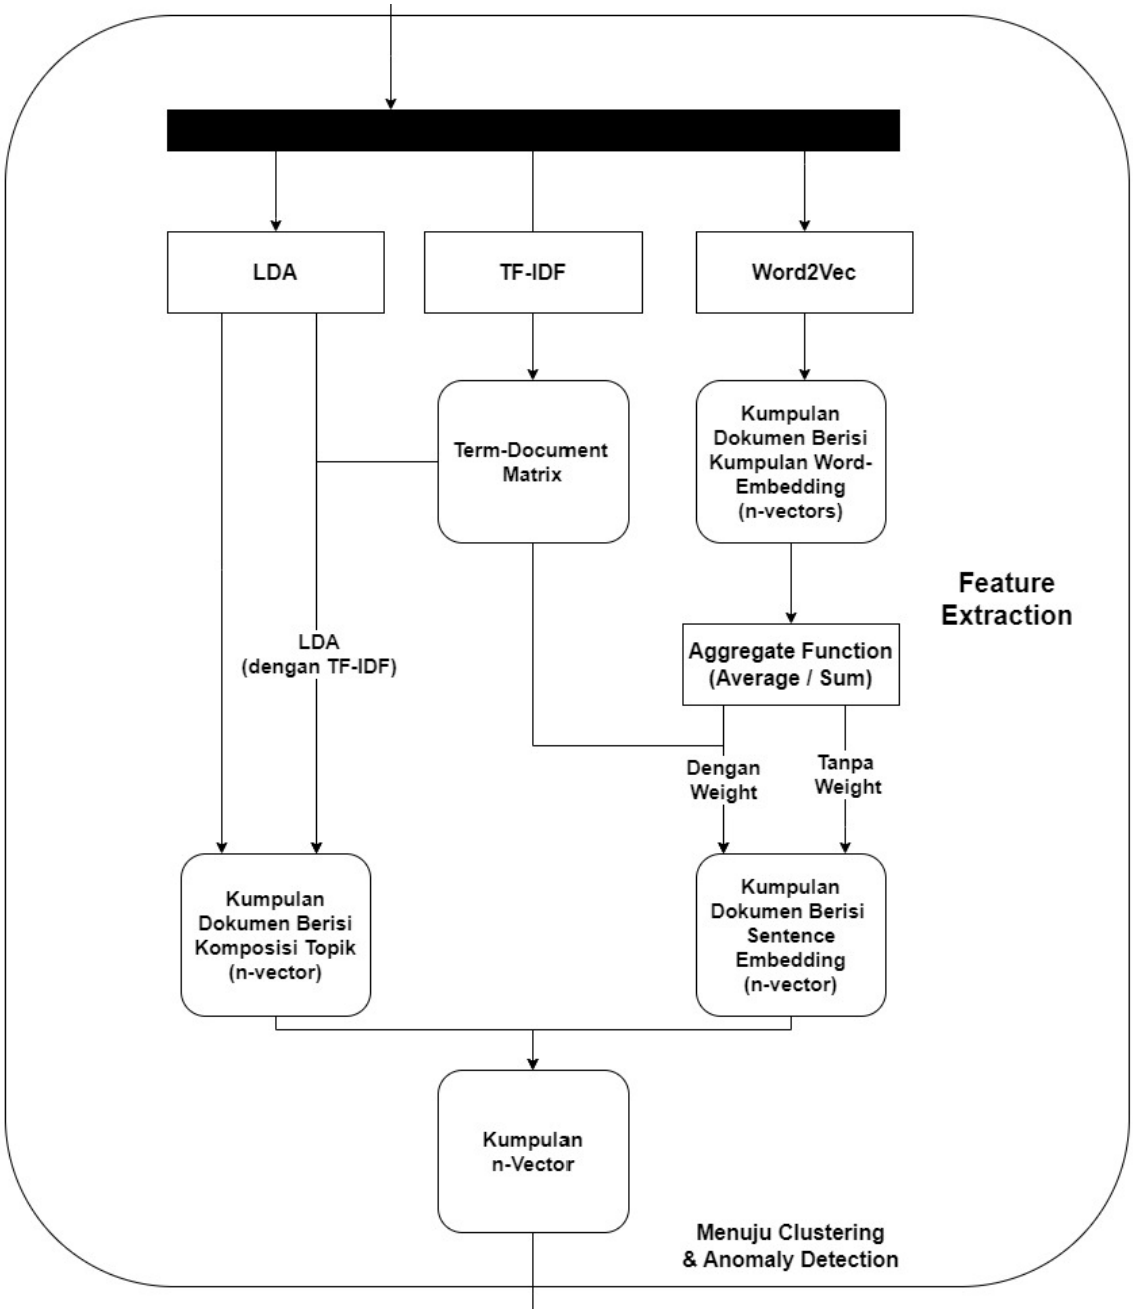

Gambar 3.4 Diagram Alur Eksperimen – *Feature Extraction*

3.3.1.1.4. Clustering & Anomaly Detection

Vektor-vektor n-dimensi yang terbentuk akan di-*fit* dalam model DBSCAN dan dikelompokkan dalam *cluster-cluster* menurut algoritmanya. Akan dilakukan *tuning* terhadap parameter berupa MinPts dan ε untuk mendapatkan *cluster-cluster* yang berkualitas, dan mendapatkan *outlier* yang benar. Setiap iterasi dari eksperimen akan direpresentasikan secara visual dalam *point graph*, dan akan divalidasi oleh penyelenggara diskusi Komunitas X sebagai

pengguna, untuk menentukan keakuratan *cluster* yang terbentuk dan validasi *outlier-outlier* yang teridentifikasi sebagai anomali yang dicari dalam data.

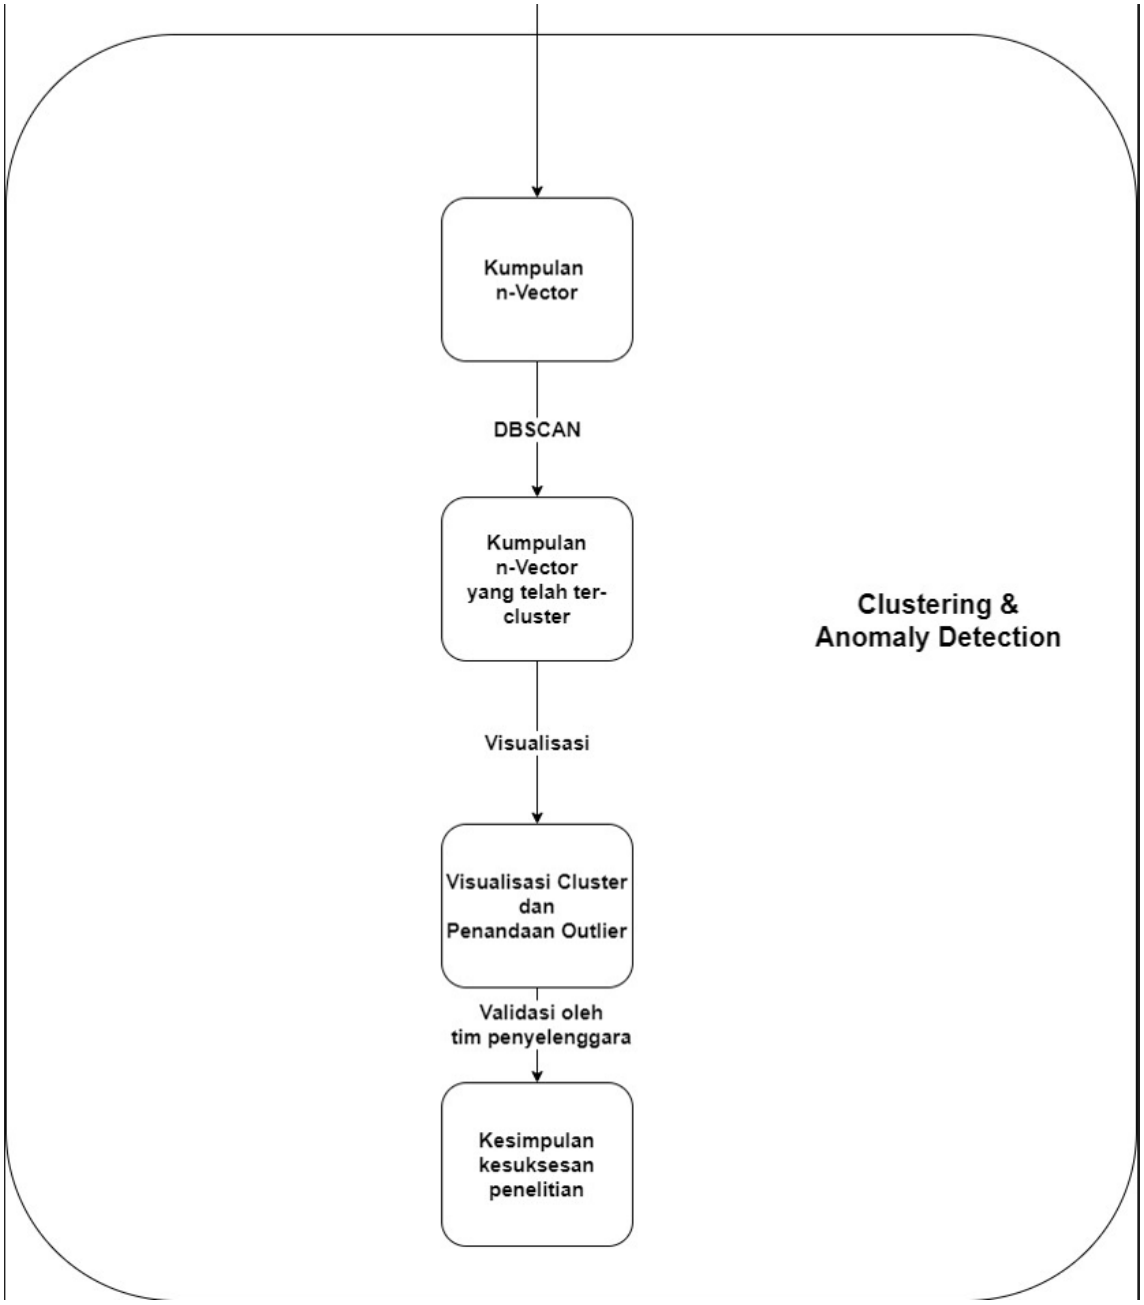

Gambar 3.5 Diagram Alur Eksperimen – *Clustering* & *Anomaly Detection*

3.3.2. Alur Program

3.3.2.1. Alur Keseluruhan Program

Program akan memiliki tiga *state* inti, yaitu Opened, Listening, dan Processing. Pada saat program dijalankan, program akan memasuki *state* Opened. Akan disajikan sebuah menu bagi pengguna untuk memilih aksi selanjutnya, yaitu StartProcessing, StartListening, atau

CloseProgram. Ketika pengguna memilih aksi StartListening, program akan memasuki *state* Listening, dimana program akan mendengarkan dan merekam suara yang ada di komputer pengguna, untuk menangkap jalannya diskusi yang sedang berlangsung. Dalam *state* ini, pengguna dapat kembali ke *state* Opened dengan aksi StopListening.

Ketika pengguna memilih aksi StartProcessing, pengguna akan memasuki state Processing. Dalam state ini, pengguna bisa membuka file database untuk mengakses data rekaman terstruktur yang telah dibuat, lalu menjalankan anomaly detection dan mendapatkan visualisasi data. Pengguna dapat kembali ke state Opened dengan aksi StopProcessing. Ketika di state Opened, pengguna dapat mejalankan aksi CloseProgram untuk menghentikan jalan program.

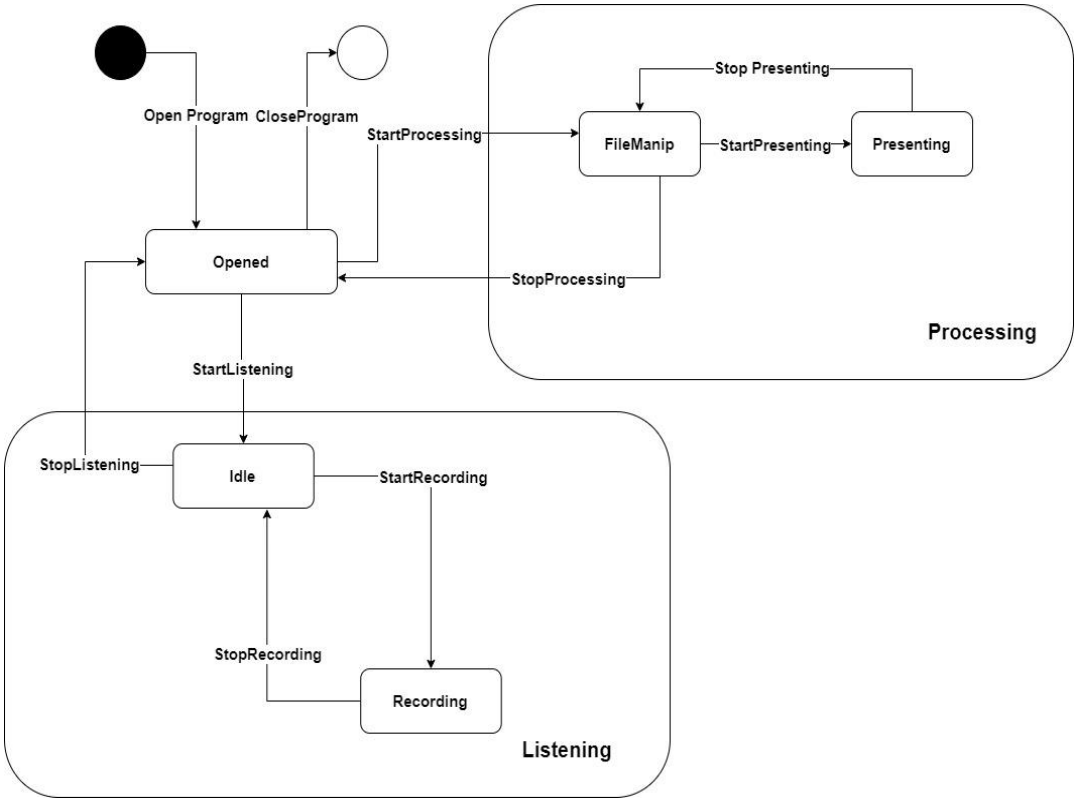

Gambar 3.6 State Diagram Program yang Akan Dibuat

3.3.2.2. Alur Pengumpulan Klip Suara

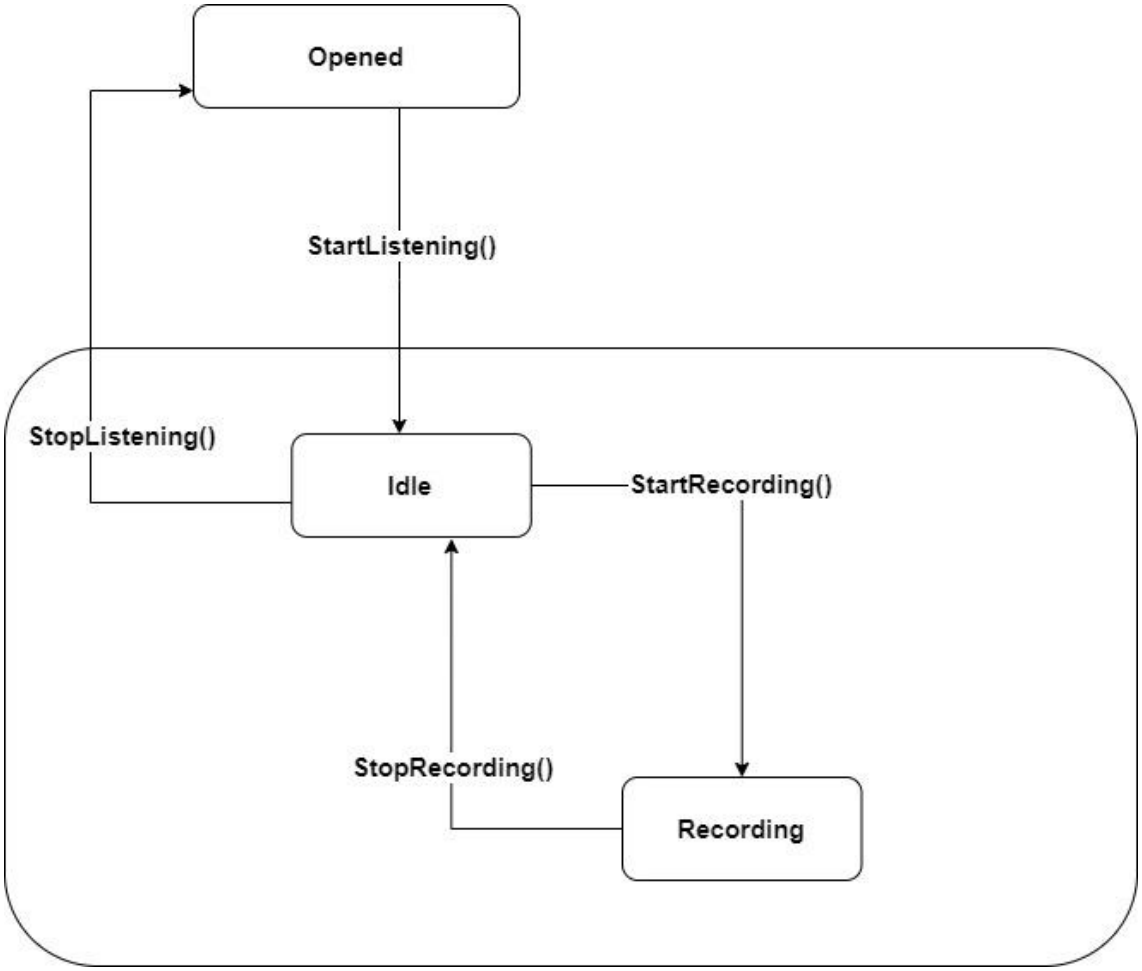

Gambar 3.7 *State Diagram* Alur Pengumpulan Klip Suara

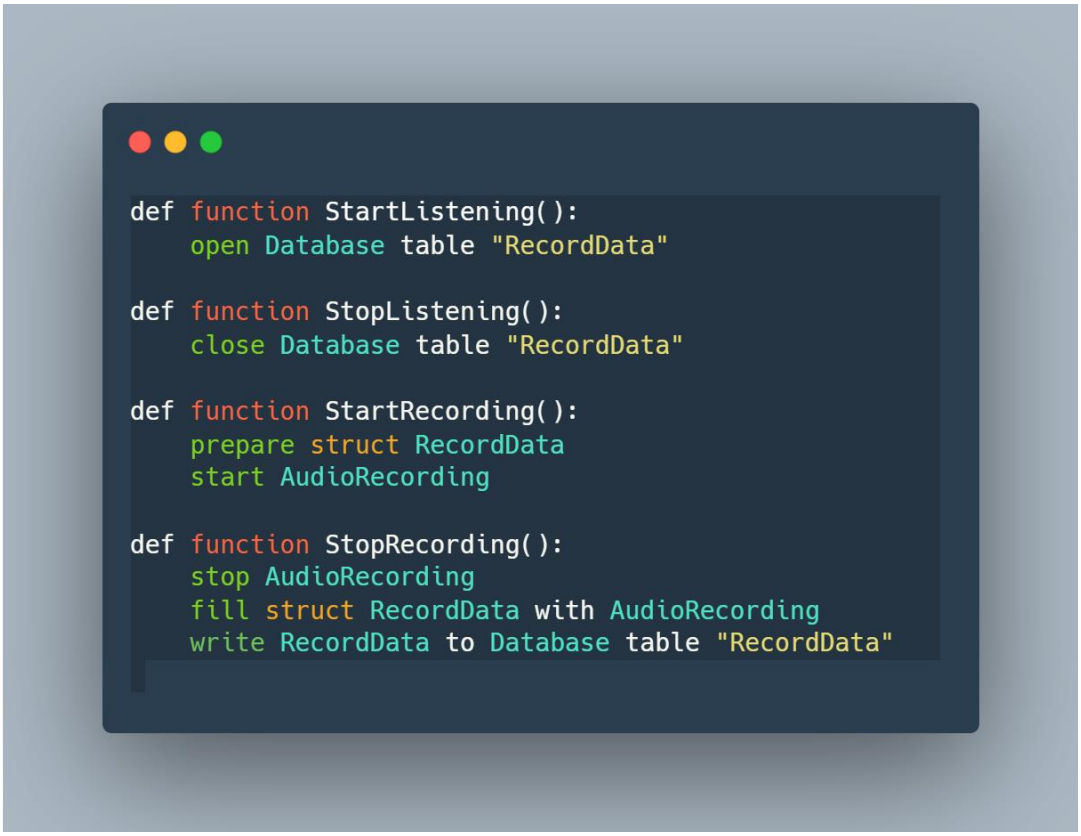

```
def function StartListening():
    open Database table "RecordData"

def function StopListening():
    close Database table "RecordData"

def function StartRecording():
    prepare struct RecordData
    start AudioRecording

def function StopRecording():
    stop AudioRecording
    fill struct RecordData with AudioRecording
    write RecordData to Database table "RecordData"
```

Gambar 3.8 Pseudocode Alur Pengumpulan Klip Suara

Berikut penjelasan setiap perintah yang ada dalam bagan yang ditunjukkan:

- StartListening(): Ketika pengguna memilih perintah StartListening(), program akan membuka koneksi ke tabel dalam *database* untuk menyimpan data rekaman suara, lalu memasuki *state* Idle. Dalam *state* Idle, pengguna dapat memulai proses rekaman dengan perintah StartRecording().
- StartRecording(): Ketika perintah ini diberikan, akan disiapkan sebuah *struct* untuk menampung data yang akan disimpan dalam *database*. Data mencakup ID rekaman, tanggal rekaman, dan *file* suara yang akan disimpan. Proses rekaman suara akan dimulai sampai perintah StopRecording() diberikan.
- StopRecording(): Ketika perintah ini diberikan, proses rekaman akan dihentikan. *File* rekaman yang terbentuk akan disimpan dalam *database* berdasarkan *struct* yang telah didefinisikan. *State* program akan kembali ke Idle.
- StopListening(): Ketika perintah ini diberikan, program akan menutup koneksi ke *database* dan kembali ke *state* Opened.

3.3.2.3. Alur Proses dan Penyajian Data

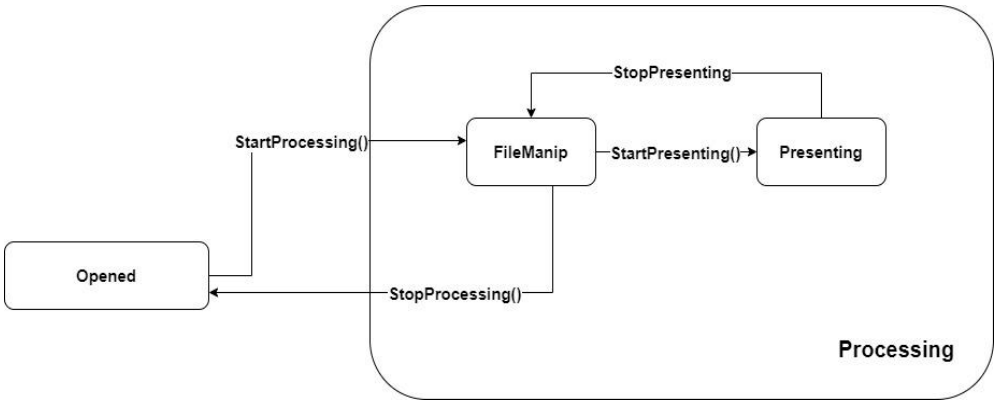

Gambar 3.9 State Diagram Alur Proses dan Penyajian Data

```
def function StartProcessing():
    open Database table "RecordData"
    open Database table "TranscriptData"

def function StartPresenting(recordID):
    prepare list RecordTable
    prepare list TranscriptTable
    read Database table "RecordData" with recordID to RecordTable
    for recordData in RecordTable:
        prepare struct TranscriptData
        transcribe recordData with SpeechToTextAPI
        translate recordData with TranslateAPI
        fill struct TranscriptData with recordData
        append TranscriptData to TranscriptTable
    process TranscriptTable with DataPipeline


def function StopPresenting():
    open Database table "SaveData"
    prepare struct SaveData
    fill struct SaveData with DataPipeline_Result
    write SaveData to Database table "SaveData"
    close Database table "SaveData"

def function StopProcessing():
    close Database table "RecordData"
    close Database table "TranscriptData"
```

Gambar 3.10 Pseudocode Alur Proses dan Penyajian Data

Berikut penjelasan setiap perintah yang ada dalam bagan yang ditunjukkan:

- StartProcessing(): Pada saat perintah ini diberikan, program akan memasuki *state* FileManip. Dalam *state* ini, dibuka koneksi ke tabel-tabel dalam *database* yang menyimpan transkrip audio dan transkrip teks. Pengguna dapat memilih untuk mengakses rekor transkrip audio yang diinginkan, untuk diproses menjadi transkrip teks dan dijadikan input proses *anomaly detection*.
- StartPresenting(recordID): Perintah ini dijalankan dengan parameter ID dari salah satu rekor data rekaman audio. Data akan diambil dari tabel yang bersangkutan dan diproses dengan komponen-komponen API *speech-to-text* dan *translator* untuk menghasilkan transkrip berupa teks berbahasa Inggris. Kumpulan transkrip teks akan dijadikan input untuk *pipeline* data yang melibatkan *preprocessing*, *tokenization*, *feature extraction*, *clustering*, dan *anomaly detection*. Akhirnya, hasil dari *anomaly detection* akan dipresentasikan. Ketika perintah ini dijalankan, program akan memasuki *state* Presenting, dimana pengguna dapat melihat visualisasi analisa data.
- StopPresenting(): Ketika perintah ini dijalankan, hasil *anomaly detection* akan disimpan dalam sebuah format tertentu dalam sebuah tabel pada *database*. Program akan kembali ke *state* FileManip dimana pengguna bisa memilih rekor-rekor data audio yang akan diproses.
- StopProcessing(): Ketika perintah ini dijalankan, koneksi *database* ke tabel yang bersangkutan akan ditutup dan *state* akan kembali ke Opened.

4. IMPLEMENTASI SISTEM

Bab ini akan menjabarkan implementasi desain sistem yang telah dirumuskan dalam Bab sebelumnya, serta mendokumentasikan code dan tools yang dipakai untuk merancang program dan eksperimen.

4.1. Implementasi Umum

4.1.1. Tools dan IDE

Implementasi eksperimen dan program ditulis dengan Bahasa Python, berikut library-library yang ada dalam *repository* PyPI (*Python Package Index*).

4.1.2. Mapping Konsep dan Implementasi

4.1.2.1.1. Eksperimen

Berikut adalah tabel *mapping* antara konsep-konsep yang dirumuskan dalam bab 3.3.1 tentang Alur Eksperimen dengan implementasinya pada tahap implementasi eksperimen.

Tabel 4.1 *Mapping* Konsep ke Implementasi Eksperimen

Tabel /Gambar Bab 3	Segmen Program	Implementasi
	Tahap Pengumpulan Data	

4.1.2.1.2. Program

Berikut adalah tabel *mapping* antara konsep-konsep yang dirumuskan dalam Bab 3.3.2 tentang Alur Program dengan implementasinya pada tahap implementasi program.

4.2. Implementasi Eksperimen

4.2.1. Tools dan IDE

Eksperimen dilaksanakan dengan bahasa pemrograman Python. IDE yang digunakan adalah Jupyter Notebook, yang memungkinkan pembagian program dalam segmen-segmen yang bisa dijalankan secara individu. *Pipeline* eksperimen yang lengkap dijadikan sebuah *class* yang diimplementasikan dalam program.

4.2.2. Importing Library

Eksperimen yang dilaksanakan memanfaatkan beberapa *library* untuk mempermudah pelaksanaan komponen-komponen yang ada didalamnya.

Segmen Kode 4.1Imports

```
# imports go here
import numpy as np
import db
import pandas as pd
import inflect
import string
import nltk
import gensim
import matplotlib.pyplot as plt
import gensim.downloader as api
from gensim import corpora, models
from nltk.test.gensim_fixt import setup_module
from nltk.corpus import stopwords
from nltk.stem import WordNetLemmatizer
from nltk.corpus import wordnet
from sklearn.feature_extraction.text import TfidfVectorizer
from sklearn.cluster import DBSCAN
from sklearn.ensemble import IsolationForest
from sklearn.neighbors import LocalOutlierFactor
```

Adapun fungsi dari library-library yang digunakan adalah sebagai berikut:

Tabel 4.2 Fungsi-fungsi *library* yang di-*import*

Nama Library	Fungsi
numpy	Memudahkan operasi-operasi matematika pada sekelompok data.
pandas	Menyediakan struktur data yang mempermudah pengambilan, pengelompokan, dan penyaringan data.
inflect	Mengubah angka menjadi bentuk terbilangnya dalam bahasa Inggris.

	Contoh : string yang menyatakan angka '92' akan diubah menjadi '*ninety-two*'.
string	Memudahkan operasi yang melibatkan tipe data string.
nltk	Natural Language Toolkit, memudahkan tugas-tugas yang berhubungan dengan *preprocessing*, seperti *word tokenization* dan *POS tagging*
gensim	Memudahkan tugas-tugas yang berhubungan dengan *Topic Modelling* dan *preprocessing*. Diantaranya, gensim digunakan untuk menyediakan *pre-trained model* untuk *word embedding* yang digunakan, serta menyediakan LDA.

4.2.3. Text Preprocessing

Pipeline text preprocessing dibuat dalam fungsi `PreprocessDocument()`. Ada beberapa parameter *boolean* yang disertakan dan diberikan nilai *default* sesuai dengan penemuan dalam eksperimen.

Segmen Kode 4.2 Fungsi untuk melakukan *text preprocessing*

```
'''
    inputs:
    - doc : str --> a string representing a sentence/document.
    - isLemma : bool --> use lemmatizer or not? Defaults to not.
    - isStopWords : bool --> use stopwords or not? Defaults to
not.
    - isInflect : bool --> use inflections (you're --> you are)
or not? Defaults to not.
    - isNumberFiltered :  bool --> delete numbers in the string?
Defaults to yes.
    '''
    '''
    output : list<str> --> a list of word tokens (list<string>)
```

```
    '''

    def PreprocessDocument(doc: str, isLemma: bool = False,
isStopWords: bool = False, isInflect: bool = False,
isNumberFiltered: bool = True):
        inflector = inflect.engine()
        stopwordSet = set(stopwords.words("english"))
        lemmatizer = WordNetLemmatizer()
        punctuations = string.punctuation
        # if numbers are filtered, add that to the punctuation
string
        if isNumberFiltered:
            punctuations += "1234567890"

        # case fold
        doc = doc.lower()

        # remove puncs
        doc = "".join([char for char in doc if char not in
punctuations])

        # tokenize it.
        token_list = nltk.word_tokenize(doc)

        for i in range(len(token_list)):
            # if inflect
            if isInflect:
                if token_list[i].isdigit():
                    token_list[i]                                =
inflector.number_to_words(token_list[i])

            # if lemma
            if isLemma:
                tagged_word = nltk.pos_tag([token_list[i]])
                wordnet_pos = getWordnetPos(tagged_word[0][1])
```

```
                token_list[i] = lemmatizer.lemmatize(
                    tagged_word[0][0], pos=wordnet_pos)

            # if stopword
            if isStopWords:
                if    token_list[i]    in    stopwordSet    or
token_list[i].isdigit():
                    token_list[i] = "#"  # mark as #

        # remove the marked strings
        token_list = [token for token in token_list if token !=
"#"]

        if token_list:
            return token_list
        return [""]
```

Segmen Kode 4.3 Fungsi getWordnetPos

```
'''
inputs:
- tag : str --> the tag obtained from POS tagging.
'''
'''
outputs:
- str --> Wordnet POS tag.
'''

def getWordnetPos(self, tag):
    """Map POS tag to WordNet POS tag"""
    if tag.startswith('J'):
        return wordnet.ADJ
    elif tag.startswith('V'):
        return wordnet.VERB
    elif tag.startswith('R'):
        return wordnet.ADV
```

```
    else:
        return wordnet.NOUN  # solves as noun by default.
```

Fungsi ini mengambil input berupa sebuah string yang berisi teks, dan melakukan *preprocessing* atas string tersebut. Pertama, teks akan dijadikan *lowercase* untuk menghindari kerancuan. Setelah itu, akan dihapus tanda-tanda baca yang ada dalam string dengan fungsi `string.lower()`. String yang telah dibersihkan dari tanda baca akan dibagi-bagi menjadi kumpulan *word-token* dengan fungsi `nltk.word_tokenize()`. Untuk setiap *word-token*, akan dilakukan infleksi dengan komponen `inflector_engine()` untuk *word-token* yang berupa angka, untuk mengubahnya menjadi bentuk terucapnya (contoh : "34" akan menjadi "*thirty-four*"). Setelah itu, akan dilakukan *lemmatizing* dengan `nltk.stem.Lemmatizer()` dengan terlebih dahulu ditentukan POS nya dengan *POS-tagging* yang disediakan oleh `nltk.pos_tag()` dan fungsi `getWordnetPos()`. Akhirnya, setiap *token* yang tergolong *stop-words* akan dihapus dari list. Fungsi ini akan mengembalikan sebuah list yang berisi *word-token* dalam bentuk string.

4.2.4. Word-Embedding

Word-embedding dilakukan untuk mengubah setiap *word-token* menjadi sebuah vektor n-dimensi. Vektor-vektor ini dimaksudkan menjadi fitur-fitur dari setiap *word-token*, yang akan menjadi input algoritma-algoritma *density-based clustering* dan *anomaly detection* yang akan dijalankan. *Word-embedding* dilakukan menggunakan pendekatan *word2vec* yang disediakan oleh *library* Python `gensim`, dan menggunakan model-model *pre-trained* yang telah disediakan.

Segmen Kode 4.4 Fungsi untuk mengganti model *word embedding* yang digunakan dan *list* modelnya

```
def SetModel(self, modelName: str = "glove-wiki-gigaword-300"):
        self.model = api.load(modelName)
WordEmbeddingModelList = ["word2vec-google-news-300",
                          "glove-wiki-gigaword-50",
                          "glove-wiki-gigaword-100",
                          "glove-wiki-gigaword-300"]
```

Segmen Kode 4.5 Fungsi WordEmbed

```
# input : list<str> : tokens of one document/sentence
# output : list<(str, list<int>[50|100|300])> : list of word-vector pair for each word available on the model
def WordEmbed(self, document: list, model):
    word_embed_pairs = []
    for word in document:
        if word in model:
            word_embed_pairs.append((word, model[word]))
    return word_embed_pairs
```

Fungsi ini mengambil sebuah *list* yang berisi *word-token*, dan berupaya melakukan *embedding* terhadap setiap *word-token* didalamnya. Token-token yang tidak ada dalam model *word-embedding* yang digunakan akan dibuang. Ada 4 *pre-trained model* yang digunakan, yaitu word2vec-google-news-300, glove-wiki-gigaword-50, glove-wiki-gigaword-100, glove-wiki-gigaword-300. Model yang digunakan menentukan besar dimensi vektor yang dihasilkan.

4.2.5. Sentence-Embedding

Setelah didapatkan *word-embedding* untuk setiap token dalam setiap dokumen, akan dilakukan proses *sentence-embedding*, yaitu melakukan agregasi setiap *word-vector* yang mewakili sebuah dokumen menjadi satu vektor kalimat atau dokumen yang berdimensi sama. Vektor ini dianggap sebagai representasi sebuah dokumen yang akan dijadikan input algoritma *anomaly detection* yang ada. Terdapat pilihan untuk menambahkan *weight* pada *sentence-embedding* yang dilakukan, menggunakan *TF-IDF score* dari *word-token* tertentu dalam dokumennya.

Segmen Kode 4.6 Fungsi untuk melakukan *sentence-embedding* tanpa *weight*

```
# input : list<(str, list<float>[300])>, str : word-vector pair list and preferred agg method.
# output : list<float>[300] : 300-d vector that represents an aggregated value of the input words

def SentenceEmbedUnweightedFunction(self, word_embed_pair_list: list, aggregateMethod: str = "avg"):
```

```
    wvs = []
    for pair in word_embed_pair_list:
        wvs.append(pair[1])
    if aggregateMethod == "avg":
        return np.mean(wvs, axis=0)
    else:
        return np.sum(wvs, axis=0)

# input : list<list<(str, list<float>[300])>>, str : list
containing word-vector pairs and preferred agg method
# output : list<(str, list<int>[300])> : list containing
sentence-vector pairs.

def SentenceEmbedUnweighted(self, word_embedded_docs: list,
aggregateMethod: str = "avg"):
    sentence_embedded_docs = []
    for i in range(len(word_embedded_docs)):

sentence_embedded_docs.append(self.SentenceEmbedUnweightedFunc
tion(
            word_embedded_docs[i], aggregateMethod))
    return sentence_embedded_docs
```

Dalam pendekatan dengan fungsi ini, setiap *word-vector* n-dimensi yang ada dalam sebuah dokumen akan diagregasi dengan *mean* atau *sum* sebagaimana terlihat pada fungsi `SentenceEmbedUnweightedFunction()`, sehingga menghasilkan satu vektor n-dimensi yang dianggap sebagai fitur suatu dokumen. Fungsi `SentenceEmbedUnweighted` akan mengembalikan sebuah *list* vektor n-dimensi yang merupakan cerminan fitur untuk setiap dokumen.

Segmen Kode 4.7 Fungsi untuk melakukan *sentence-embedding* dengan TF-IDF sebagai *weight*.

```
'''
input :
```

```
list<list<(str, list<float>[300])>> : word-vector pair list
matrix : tf-idf matrix for the corresponding doc
int : the row we want
str : preferred agg method
'''
# output : list<float>[300] : 300-d vector that represents an
aggregated value of the input words

def SentenceEmbedWeightedFunction(self, word_embed_pair_list:
list, tfidf_matrix, index: int, aggregateMethod: str = "avg"):
    weighted_wvs = []
    # multiplies each word with its TF-IDF value in the
corresponding row. Is 0 if word isn't found somehow.
    for pair in word_embed_pair_list:
        tfidf_weight = 0
        if pair[0] in tfidf_matrix:
            tfidf_weight = tfidf_matrix[pair[0]][index]
        weighted_wvs.append(pair[1] * tfidf_weight)
    # turn into array for fast aggregating
    weighted_wvs = np.array(weighted_wvs)
    if aggregateMethod == "avg":
        sentence_vector = np.mean(weighted_wvs, axis=0)
    else:
        sentence_vector = np.sum(weighted_wvs, axis=0)
    return sentence_vector

# input : list<list<(str, list<float>[300])>>, str : list
containing word-vector pairs, TF-IDF matrix of the corpus, and
preferred agg method
# output : list<(str, list<float>[300])> : list containing
sentence-vector pairs.
def SentenceEmbedWeighted(self, word_embedded_docs: list,
tfidf_matrix, aggregateMethod="avg"):
    sentence_embedded_docs = []
    for i in range(len(word_embedded_docs)):
```

```
sentence_embedded_docs.append(self.SentenceEmbedWeightedFunction(
            word_embedded_docs[i],       tfidf_matrix,       i, aggregateMethod))
    return sentence_embedded_docs
```

Dalam pendekatan ini, matriks TF-IDF score akan digunakan sebagai *weighting* untuk setiap token kata yang ada dalam sebuah dokumen. Fungsi agregat yang dipakai untuk mendapatkan satu vektor dokumen adalah *mean* dan *sum*, sama dengan pendekatan *unweighted*. Fungsi `SentenceEmbedWeightedFunction()` dipanggil dengan parameter `index` untuk mendapatkan baris pada matriks TF-IDF yang berkorespondensi dengan dokumen yang bersangkutan. Setiap word-vector akan dikalikan dengan TF-IDF *score* untuk kata tersebut dalam proses agregasi. Ini dilakukan dengan asumsi bahwa TF-IDF *score* mencerminkan relevansi sebuah *word-token* dalam sebuah dokumen, dalam dataset yang ada.

4.2.6. Tiny Word-Embedding

Pendekatan ini merupakan pendekatan alternatif dari *sentence-embedding*. Dalam feature extraction tiny word-embedding, fitur sebuah dokumen berupa sebuah *list* yang berisi nilai-nilai singuler hasil agregat dimensi-dimensi yang didapatkan dari *word-embedding*.

Segmen Kode 4.8 Fungsi tiny word-embedding untuk sebuah dokumen tanpa *weighting*

```
'''
inputs :
- model         :           --> word2vec model
- document      : list<str> --> a list of word tokens to embed.
- maxLength     : int       --> the maximum length, to pad the vector with if necessary.
- weighted      : bool      --> multiply each word with respective TF-IDF score or not.
'''

def TinyWordEmbed(self, document: list, model, maxLength: int):
    features = []
    # this creates a feature length of len(document)
    for word in document:
```

```
        if word in model:
            features.append(np.mean(model[word], axis=0))
    # if less than maxLength, pad with zeros.
    if len(features) < maxLength:
        padLength = maxLength - len(features)
        padding = np.zeros(padLength)
        features = np.concatenate((features, padding))

    # i remain pessimistic that this would work.
    return features
```

Karakteristik agregat yang dilakukan menyebabkan kemungkinan panjang fitur setiap dokumen berbeda-beda, yaitu sesuai jumlah *word-token* yang dimiliki sebuah dokumen. Oleh karena itu, digunakan sebuah parameter `maxLength` yang memastikan kesamaan jumlah fitur untuk setiap dokumen dalam dataset.

Segmen Kode 4.9 Fungsi *tiny word-embed* dengan *weighting* TF-IDF

```
# ditto TinyWordEmbed but with weight
def TinyWordEmbedWeighted(self, document: list, model,
maxLength: int, index: int):
    features = []
    for word in document:
        if word in model:
            weight = 0
            if word in self.tfidf_df:
                weight = self.tfidf_df[word][index]
            features.append(
                np.mean(model[word], axis=0) * weight)

    # if less than maxLength, pad with zeros.
    if len(features) < maxLength:
        padLength = maxLength - len(features)
        padding = np.zeros(padLength)
        features = np.concatenate((features, padding))
```

```
    # i still remain pessimistic that this would work.
    return features
```

Fungsi diatas berfungsi sama dengan fungsi `TinyWordEmbed`, namun dengan tambahan parameter `index` untuk mendapatkan TF-IDF *score* untuk *weighting* nilai agregat setiap *word-token*.

4.2.7. TF-IDF sebagai *Weighting*

Matriks TF-IDF diperlukan sebagai weight dalam *feature extraction*, yaitu ketika mengagregasi *word-vector* menjadi *sentence-vector*, membuat *document-vector* dengan *tiny word-embedding*, atau sebagai *word-document matrix* pada *topic distribution* LDA. Matriks TF-IDF dihitung ketika ditentukan oleh parameter yang bersangkutan, dengan menggunakan library *Python* `sklearn.feature_extraction.text.TfIdfVectorizer`.

Segmen Kode 4.10 Fungsi untuk mendapatkan Matriks TF-IDF

```
'''
inputs:
- doclist : list<str> --> list of doc/sentences.
- isProcessed : bool --> has it already been preprocessed? Defaults to True.
'''
'''
outputs:
- df_tfidf : Dataframe --> the TFIDF matrix in df form.
- matrix : matrix --> the TFIDF matrix purely. mainly for LDA purposes.
'''

def GetTFIDF(self, doclist: list, isPreprocessed=True):
    if not isPreprocessed:
        doclist = [self.PreprocessDocument(
            doc, isLemma=True, isStopWords=True) for doc in doclist]
    # else:
    #     # just tokenize the thing
    #     doclist = [nltk.word_tokenize(doc) for doc in doclist]
```

```
    # i think the thing has already been tokenized. That's the
problem.
    flat_doclist = [' '.join(doc)
                    for doc in doclist]   # turn into one big
corpus
    vectorizer = TfidfVectorizer()
    matrix = vectorizer.fit_transform(flat_doclist)
    tfidf_keys = vectorizer.get_feature_names_out()
    df_tfidf        =        db.pd.DataFrame(matrix.toarray(),
columns=tfidf_keys)

    return df_tfidf, matrix
```

Fungsi ini mengembalikan data matriks TF-IDF dalam dua format, yaitu dalam format `DataFrame` dan `spmatrix`, untuk menangani kebutuhan tipe data yang berbeda.

4.2.8. Latent Dirichlet Allocation (LDA)

LDA adalah metode *feature extraction* yang diajukan, dan diterapkan melalui *library* Python `gensim.models.LdaModel()` pada sebuah dataset. Parameter yang diuji adalah jumlah topik yang diinferensikan, yang ada dalam parameter `num_topics`.

Segmen Kode 4.11 Fungsi untuk mendapatkan distribusi topik dengan LDA

```
def GetLDADistribution(self, doclist: list, topics: int = 5,
use_tfidf: bool = True):
    new_corpus = []

    if use_tfidf:
        for i in range(len(doclist)):
            doc = [(j, self.tfidf_matrix[i, j])
                    for j in self.tfidf_matrix[i].indices]
            new_corpus.append(doc)
            gensim_dict                                          =
corpora.Dictionary.from_corpus(new_corpus)
    else:
        gensim_dict = corpora.Dictionary(doclist)
```

```
        new_corpus = [gensim_dict.doc2bow(doc) for doc in
doclist]

    lda_model = gensim.models.LdaModel(
        new_corpus, num_topics=topics, id2word=gensim_dict)
    doc_topic_distributions = lda_model[new_corpus]

    docFeatureList = []
    for doc_topic_dist in doc_topic_distributions:
        featureList = [0.0 for i in range(0, topics)]
        for topic_dist in doc_topic_dist:
            featureList[topic_dist[0]] = topic_dist[1]
        docFeatureList.append(featureList)

    return docFeatureList
```

Fungsi ini akan mengembalikan vektor n-dimensi untuk setiap dokumen, dimana n adalah parameter `num_topics` pada `gensim.models.LdaModel()`. Vektor-vektor tersebut digunakan sebagai fitur data yang akan menjadi input algoritma *anomaly detection* yang digunakan.

4.2.9. Density-Based Clustering of Applications with Noise (DBSCAN)

DBSCAN adalah metode utama yang digunakan untuk mendeteksi anomali. Dalam penelitian ini, DBSCAN diterapkan dengan

Segmen Kode 4.12 Fungsi DBSCAN

```
'''
inputs:
- vectors : list<list<float>> --> list of features corresponding
to each doc/sentence
- epsilon : float --> the radius within which points are
considered connected.
- min : int --> minimum amount of connected points for a point
to be considered a core point of a cluster.
'''
'''
```

```
output:
clusters : list<int> --> a list of integers to assign each data
point to a cluster. -1 means outlier.
'''

def GetDBSCANClusters(self, vectors, epsilon: float, min: int):
    dbscan = DBSCAN(eps=epsilon, min_samples=min)
    clusters = dbscan.fit_predict(vectors)
    return clusters
```

Fungsi ini mengambil *list* fitur-fitur data yang telah diekstraksi dengan metode yang dipilih dan menjalankan algoritma DBSCAN. Data yang dikembalikan adalah pengelompokan *cluster* data. Dokumen yang mendapatkan *cluster* -1 adalah dokumen yang ditandai sebagai *outlier*, dan ditandai sebagai anomali berdasarkan asumsi penelitian.

4.2.10. Local Outlier Factor (LOF)

Local Outlier Factor digunakan sebagai metode *anomaly detection* pembanding, dan diterapkan dalam penelitian ini menggunakan *library* Python `sklearn.neighbors.LocalOutlierFactor`. Parameter-parameter yang akan diuji adalah `n_neighbors` dan `contamination`.

Segmen Kode 4.13 Fungsi yang menjalankan algoritma LOF

```
def SetLOFClusters(self, vector):
    lof = LocalOutlierFactor(
        n_neighbors=self.AnomalyDetectionParams["neighbors"],
contamination=self.AnomalyDetectionParams["contamination"])
    lof.fit(vector)
    LOFResults = lof.negative_outlier_factor_

    # minus values yield anomalies
    if "lof_generalize" in self.AnomalyDetectionParams and
self.AnomalyDetectionParams["lof_generalize"]:
        print("if minus we go bald")
        LOFResults[LOFResults >= 0] = 0
        LOFResults[LOFResults < 0] = -1
    else:
```

```
        # if not generalize, we assume outliers are within the
n-th percentile, with n = contamination rate.
        print(
            "taking                    the                    {}-th
percentile".format(self.AnomalyDetectionParams["contamination"
] * 100))
        threshold = np.percentile(
            LOFResults,                    100                    *
self.AnomalyDetectionParams["contamination"])
        LOFResults[LOFResults >= threshold] = 0
        LOFResults[LOFResults < threshold] = -1
    self.df["Cluster Assignment"] = LOFResults
```

Fungsi ini akan mengembalikan nilai `_negative_outlier_factor` untuk setiap dokumen. Akan dilaksanakan penempatan *cluster* yang berbeda untuk menentukan *outlier*. Jika tidak digeneralisir, maka akan diambil persentil ke-n dengan nilai negatif tertinggi, dimana n adalah nilai parameter `contamination`. Jika digeneralisir, maka semua dokumen yang memiliki nilai `_negative_outlier_factor` negatif akan ditandai sebagai *outlier*. Dalam rangka penelitian ini, dokumen-dokumen yang ditandai sebagai *outlier* akan dianggap sebagai anomali.

4.2.11. Isolation Forest (IF)

Isolation Forest digunakan sebagai metode *anomaly detection* pembanding. Isolation Forest diterapkan dengan menggunakan *library* Python `sklearn.ensemble.IsolationForest`. Parameter-parameter yang akan diuji adalah `contamination` dan `n_estimators`.

Segmen Kode 4.14 Fungsi yang menjalankan algoritma Isolation Forest

```
'''
inputs:
- vectors : list<list<float>> --> list of features corresponding
to each doc/sentence

'''

def SetIFClusters(self, vector):
```

```
    isolationForest = IsolationForest(

n_estimators=self.AnomalyDetectionParams["estimators"],
contamination=self.AnomalyDetectionParams["contamination"])
    isolationForest.fit(vector)
    IFResults = isolationForest.decision_function(vector)

    # minus values yield anomalies.
    for i in range(len(IFResults)):
        if IFResults[i] >= 0:
            IFResults[i] = 0
        else:
            IFResults[i] = -1
    self.df["Cluster Assignment"] = IFResults
```

Fungsi ini menghasilkan `decision_function` untuk setiap rekor data. Dokumen dengan nilai dibawah nol, atau nilai negatif, merupakan *outlier*, dan dalam rangka penelitian ini ditandai sebagai anomali.

4.2.12. *Class* AnomalyDetector sebagai Pipeline Eksperimen dan Komponen Program

Seluruh komponen-komponen diatas disusun sedemikian rupa dalam sebuah *class* `AnomalyDetector`, yang memiliki fungsi-fungsi pembantu untuk memudahkan pergantian parameter dan mendapatkan hasil *anomaly detection* dalam bentuk yang dapat dimanfaatkan oleh program. *Class* ini dimuat dalam *file* anomalydetector.py yang digunakan sebagai komponen langsung program yang dirancang.

Segmen Kode 4.15 anomalydetector.py

```
# imports go here
import numpy as np
from objects import db
import pandas as pd
import inflect
import string
import nltk
import gensim
import matplotlib.pyplot as plt
```

```
import gensim.downloader as api
from gensim import corpora, models
from nltk.test.gensim_fixt import setup_module
from nltk.corpus import stopwords
from nltk.stem import WordNetLemmatizer
from nltk.corpus import wordnet
from sklearn.feature_extraction.text import TfidfVectorizer
from sklearn.cluster import DBSCAN
from sklearn.ensemble import IsolationForest
from sklearn.neighbors import LocalOutlierFactor
from sklearn.decomposition import PCA

# this is where everything we've experimented on will be
implemented.


class AnomalyDetector():
    def __init__(self, dbName: str = "",  dh=None, model=None,
modelName="glove-wiki-gigaword-300") -> None:
        if dh is None:
            self.dh = db.DatabaseHandler(dbName=dbName)
        else:
            self.dh = dh
        if model is None:
            if modelName != "":
                self.model = api.load(modelName)
        else:
            self.model = model

        self.FeatureExtractionParams = {}
        self.AnomalyDetectionParams = {}

    '''
    inputs :
    - dh : DatabaseHandler --> to retrieve data from database
```

```
    - eventID : int --> we're doing this by event, so straight
to the eventID
    - selector : str --> pretty much formality.
    - splitBySentences : bool --> Split each doc into sentences
or not. Defaults to no.
    '''
    '''
    outputs:
    None, just setting
    '''

    def SetDFFromDB(self, eventID: int, selector: str =
"event_id", splitBySentences: bool = False):
        self.df =
self.dh.get_recordDataJoinedDF(selector=selector, ID=eventID)
        if splitBySentences:
            # df.set_index('id', inplace=True)
            self.df['answer'] =
self.df['answer'].str.split('.')
            self.df = self.df.explode("answer", True)
            self.df.drop(self.df[self.df["answer"] ==
""].index, inplace=True)
            self.df.reset_index(drop=True, inplace=True)

    # ditto above, but takes a pre-made DF instead.
    def SetDF(self, df: db.pd.DataFrame, splitBySentences: bool
= False):
        self.df = df
        if splitBySentences:
            # df.set_index('id', inplace=True)
            self.df['answer'] =
self.df['answer'].str.split('.')
            self.df = self.df.explode("answer", True)
            self.df.drop(self.df[self.df["answer"] ==
""].index, inplace=True)
```

```
            self.df.reset_index(drop=True, inplace=True)

    def SetModel(self, modelName: str = "glove-wiki-gigaword-300"):
        self.model = api.load(modelName)

    # these are to add key:value to the dictionaries that dictate parameters. Indeed, we are refurbishing.
    def SetFeatureExtractionParam(self, key: str, value):
        self.FeatureExtractionParams[key] = value

    def SetAnomalyDetectionParam(self, key: str, value):
        self.AnomalyDetectionParams[key] = value

    '''
    inputs :
    - dh : DatabaseHandler --> to retrieve data from database
    - eventID : int --> we're doing this by event, so straight to the eventID
    - selector : str --> pretty much formality.
    - splitBySentences : bool --> Split each doc into sentences or not. Defaults to no.
    '''
    '''
    outputs:
    - df : DataFrame --> dataframe containing the thing we're gonna be using.
    '''

    def GetDF(self, dh: db.DatabaseHandler, eventID: int, selector: str = "event_id", splitBySentences: bool = False):
        df = dh.get_recordDataJoinedDF(selector=selector, ID=eventID)
        if splitBySentences:
            # df.set_index('id', inplace=True)
```

```
            df['answer'] = df['answer'].str.split('.')
            df = df.explode("answer", True)
            df.drop(df[df["answer"] == ""].index, inplace=True)
            df.reset_index(drop=True, inplace=True)
        return df

    '''
    inputs:
    - doc : str --> a string representing a sentence/document.
    - isLemma : bool --> use lemmatizer or not? Defaults to not.
    - isStopWords : bool --> use stopwords or not? Defaults to
not.
    - isInflect : bool --> use inflections (you're --> you are)
or not? Defaults to not.
    - isNumberFiltered :  bool --> delete numbers in the string?
Defaults to yes.
    '''
    '''
    output : list<str> --> a list of word tokens (list<string>)
    '''

    def  PreprocessDocument(self,  doc:  str,  isLemma:  bool  =
False,  isStopWords:  bool  =  False,  isInflect:  bool  =  False,
isNumberFiltered: bool = True):
        inflector = inflect.engine()
        stopwordSet = set(stopwords.words("english"))
        lemmatizer = WordNetLemmatizer()
        punctuations = string.punctuation
        # if numbers are filtered, add that to the punctuation
string
        if isNumberFiltered:
            punctuations += "1234567890"

        # case fold
        doc = doc.lower()
```

```
        # remove puncs
        doc = "".join([char for char in doc if char not in
punctuations])

        # tokenize it.
        token_list = nltk.word_tokenize(doc)

        for i in range(len(token_list)):
            # if inflect
            if isInflect:
                if token_list[i].isdigit():
                    token_list[i]                                =
inflector.number_to_words(token_list[i])

            # if lemma
            if isLemma:
                tagged_word = nltk.pos_tag([token_list[i]])
                wordnet_pos                                      =
self.getWordnetPos(tagged_word[0][1])
                token_list[i] = lemmatizer.lemmatize(
                    tagged_word[0][0], pos=wordnet_pos)

            # if stopword
            if isStopWords:
                if    token_list[i]    in    stopwordSet    or
token_list[i].isdigit():
                    token_list[i] = "#"  # mark as #

        # remove the marked strings
        token_list = [token for token in token_list if token !=
"#"]

        if token_list:
            return token_list
```

```
        return [""]

    '''
    inputs:
    - tag : str --> the tag obtained from POS tagging.
    '''
    '''
    outputs:
    - str --> Wordnet POS tag.
    '''

    def getWordnetPos(self, tag):
        """Map POS tag to WordNet POS tag"""
        if tag.startswith('J'):
            return wordnet.ADJ
        elif tag.startswith('V'):
            return wordnet.VERB
        elif tag.startswith('R'):
            return wordnet.ADV
        else:
            return wordnet.NOUN  # solves as noun by default.

    '''
    inputs:
    - doclist : list<str> --> list of doc/sentences.
    - isProcessed : bool --> has it already been preprocessed?
Defaults to True.
    '''
    '''
    outputs:
    - df_tfidf : Dataframe --> the TFIDF matrix in df form.
    - matrix : matrix --> the TFIDF matrix purely. mainly for
LDA purposes.
    '''
```

```
    def GetTFIDF(self, doclist: list, isPreprocessed=True):
        if not isPreprocessed:
            doclist = [self.PreprocessDocument(
                doc, isLemma=True, isStopWords=True) for doc in
doclist]
        # else:
        #     # just tokenize the thing
        #       doclist = [nltk.word_tokenize(doc) for doc in
doclist]
        # i think the thing has already been tokenized. That's
the problem.
        flat_doclist = [' '.join(doc)
                        for doc in doclist]  # turn into one big
corpus
        vectorizer = TfidfVectorizer()
        matrix = vectorizer.fit_transform(flat_doclist)
        tfidf_keys = vectorizer.get_feature_names_out()
        df_tfidf      =      db.pd.DataFrame(matrix.toarray(),
columns=tfidf_keys)

        return df_tfidf, matrix

    # input : list<str> : tokens of one document/sentence
    # output : list<(str, list<int>[300])> : list of word-vector
pair for each word available on the model
    def WordEmbed(self, document: list, model):
        word_embed_pairs = []
        for word in document:
            if word in model:
                word_embed_pairs.append((word, model[word]))
        return word_embed_pairs

    '''
    inputs :
    - model         :           -->word2vec model
```

```
    - document       : list<str> --> a list of word tokens to
embed.
    - maxLength      : int       --> the maximum length, to pad
the vector with if necessary.
    - weighted       : bool      --> multiply each word with
respective TF-IDF score or not.
    '''

    def TinyWordEmbed(self, document: list, model, maxLength:
int):
        features = []
        # this creates a feature length of len(document)
        for word in document:
            if word in model:
                features.append(np.mean(model[word], axis=0))
        # if less than maxLength, pad with zeros.
        if len(features) < maxLength:
            padLength = maxLength - len(features)
            padding = np.zeros(padLength)
            features = np.concatenate((features, padding))

        # i remain pessimistic that this would work.
        return features

    # ditto TinyWordEmbed but with weight
    def  TinyWordEmbedWeighted(self,  document:  list,  model,
maxLength: int, index: int):
        features = []
        for word in document:
            if word in model:
                weight = 0
                if word in self.tfidf_df:
                    weight = self.tfidf_df[word][index]
                features.append(
                    np.mean(model[word], axis=0) * weight)
```

```
        # if less than maxLength, pad with zeros.
        if len(features) < maxLength:
            padLength = maxLength - len(features)
            padding = np.zeros(padLength)
            features = np.concatenate((features, padding))

        # i remain pessimistic that this would work.
        return features

    # input : list<(str, list<float>[300])>, str : word-vector
pair list and preferred agg method.
    # output : list<float>[300] : 300-d vector that represents
an aggregated value of the input words

    def                    SentenceEmbedUnweightedFunction(self,
word_embed_pair_list: list, aggregateMethod: str = "avg"):
        wvs = []
        for pair in word_embed_pair_list:
            wvs.append(pair[1])
        if aggregateMethod == "avg":
            return np.mean(wvs, axis=0)
        else:
            return np.sum(wvs, axis=0)

    # input : list<list<(str, list<float>[300])>>, str : list
containing word-vector pairs and preferred agg method
    # output : list<(str, list<int>[300])> : list containing
sentence-vector pairs.
    def SentenceEmbedUnweighted(self, word_embedded_docs: list,
aggregateMethod: str = "avg"):
        sentence_embedded_docs = []
        for i in range(len(word_embedded_docs)):
```

```
sentence_embedded_docs.append(self.SentenceEmbedUnweightedFunc
tion(
                word_embedded_docs[i], aggregateMethod))
        return sentence_embedded_docs

    '''
    input :
    list<list<(str, list<float>[300])>> : word-vector pair list
    matrix : tf-idf matrix for the corresponding doc
    int : the row we want
    str : preferred agg method
    '''
    # output : list<float>[300] : 300-d vector that represents
an aggregated value of the input words

    def                    SentenceEmbedWeightedFunction(self,
word_embed_pair_list:   list,   tfidf_matrix,   index:   int,
aggregateMethod: str = "avg"):
        weighted_wvs = []
        # multiplies each word with its TF-IDF value in the
corresponding row. Is 0 if word isn't found somehow.
        for pair in word_embed_pair_list:
            tfidf_weight = 0
            if pair[0] in tfidf_matrix:
                tfidf_weight = tfidf_matrix[pair[0]][index]
            weighted_wvs.append(pair[1] * tfidf_weight)
        # turn into array for fast aggregating
        weighted_wvs = np.array(weighted_wvs)
        if aggregateMethod == "avg":
            sentence_vector = np.mean(weighted_wvs, axis=0)
        else:
            sentence_vector = np.sum(weighted_wvs, axis=0)
        return sentence_vector
```

```
    # input : list<list<(str, list<float>[300])>>, str : list
containing word-vector pairs, TF-IDF matrix of the corpus, and
preferred agg method
    # output : list<(str, list<float>[300])> : list containing
sentence-vector pairs.
    def SentenceEmbedWeighted(self, word_embedded_docs: list,
tfidf_matrix, aggregateMethod="avg"):
        sentence_embedded_docs = []
        for i in range(len(word_embedded_docs)):

sentence_embedded_docs.append(self.SentenceEmbedWeightedFunctio
n(
                word_embedded_docs[i],     tfidf_matrix,     i,
aggregateMethod))
        return sentence_embedded_docs

    '''
    input:
    - doclist : list<list<str>> --> list of tokenized
sentences/docs
    - topics : int --> number of inferred topics.
    - use_tfidf : bool --> use TFIDF or not? defaults to yes.
    '''
    '''
    output:
    - docFeatureList : list<list<float>> --> topic distribution
for each sentence/doc
    '''

    def GetLDADistribution(self, doclist: list, topics: int =
5, use_tfidf: bool = True):
        new_corpus = []

        if use_tfidf:
            for i in range(len(doclist)):
```

```
                doc = [(j, self.tfidf_matrix[i, j])
                       for j in self.tfidf_matrix[i].indices]
                new_corpus.append(doc)
                gensim_dict                                          =
corpora.Dictionary.from_corpus(new_corpus)
        else:
            gensim_dict = corpora.Dictionary(doclist)
            new_corpus = [gensim_dict.doc2bow(doc) for doc in
doclist]

        lda_model = gensim.models.LdaModel(
            new_corpus, num_topics=topics, id2word=gensim_dict)
        goofy_ahh_doc_topic_distributions                            =
lda_model[new_corpus]

        docFeatureList = []
        for                  doc_topic_dist                  in
goofy_ahh_doc_topic_distributions:
            featureList = [0.0 for i in range(0, topics)]
            for topic_dist in doc_topic_dist:
                featureList[topic_dist[0]] = topic_dist[1]
            docFeatureList.append(featureList)

        return docFeatureList

    '''
    inputs:
    - vectors : list<list<float>> --> list of features
corresponding to each doc/sentence
    - epsilon : float --> the radius within which points are
considered connected.
    - min : int --> minimum amount of connected points for a
point to be considered a core point of a cluster.
    '''
    '''
```

```
    output:
    clusters : list<int> --> a list of integers to assign each
data point to a cluster. -1 means outlier.
    '''

    def GetDBSCANClusters(self, vectors, epsilon: float, min:
int):
        dbscan = DBSCAN(eps=epsilon, min_samples=min)
        clusters = dbscan.fit_predict(vectors)
        # plt.title("to the depths of depravity {} and the cusp
of blasphemy {}.".format(epsilon, min))
        # plt.scatter(vectors[:, 0], vectors[:, 1], c=clusters)
        # plt.show()
        # print(clusters)
        return clusters
    '''
    inputs:
    - vectors : list<list<float>> --> list of features
corresponding to each doc/sentence

    '''

    def GetIFResults(self, vector):
        isolationForest = IsolationForest(n_estimators=500,
contamination=0.1)
        isolationForest.fit(vector)
        IFResults = isolationForest.decision_function(vector)

        # minus values yield anomalies.
        for i in range(len(IFResults)):
            if IFResults[i] >= 0:
                IFResults[i] = 0
            else:
                IFResults[i] = -1
        return IFResults
```

```
    '''
    inputs :
    - clusters : list<int> --> a list of clusters assigned to
each doc/sentence
    - df : DataFrame --> the dataframe in question
    - isReturnSeparate : bool --> split return or not. Defaults
to split (for some reason...)
    '''
    '''
    outputs:
    - dfOutliers : DataFrame --> the dataframe whose answers
have been marked as outliers.
    - dfGoods : DataFrame --> the dataframe whose answers have
not been marked as outliers.
    '''

    def ReturnClusters(self, isReturnSeparate: bool = True):
        if isReturnSeparate:
            dfGoods       =       self.df.loc[self.df["Cluster
Assignment"] != -1]
            dfGoods.reset_index(inplace=True)
            dfOutliers      =      self.df.loc[self.df["Cluster
Assignment"] == -1]
            dfOutliers.reset_index(inplace=True)
            return dfOutliers, dfGoods
        else:
            if self.df.isnull().values.any():
                self.df.reset_index(inplace=True)
            return self.df

    '''
    inputs:
    - method : str --> LDA or Embedding.
    - isWeighted : bool --> use weights or not
```

```
    - nTopics : int --> for LDA.
    '''
    '''
    - outputs : none. This is an internal function
    '''

    def GetAnomalies(self, isReturnSeparate: bool = False):
        self.SetDocumentTokens()  # set tokens in the DF
        if      self.FeatureExtractionParams["method"]      ==
"Embedding":
            self.SetEmbeddingResult()
        elif self.FeatureExtractionParams["method"] == "LDA":
            self.SetLDAResult()
        elif self.FeatureExtractionParams["method"] == "Tiny":
            self.SetTinyEmbeddingResult()

        if     self.AnomalyDetectionParams["algorithm"]     ==
"DBSCAN":
            self.SetDBSCANClusters(list(self.df["Document
Embed"]))
        elif self.AnomalyDetectionParams["algorithm"] == "LOF":
            self.SetLOFClusters(list(self.df["Document
Embed"]))
        elif self.AnomalyDetectionParams["algorithm"] == "IF":
            self.SetIFClusters(list(self.df["Document
Embed"]))

        return
self.ReturnClusters(isReturnSeparate=isReturnSeparate)

    '''
    inputs  : None (checks self.FeatureExtractionParams)
    desc    : embeds each doc and put it in a new column "Document
Embed"
    '''
```

```
    def SetEmbeddingResult(self):
        # extract feature with embedding
        self.wordEmbeddedDocs = [self.WordEmbed(
            doc, self.model) for doc in self.preprocessedDocs]

        if "weighted" in self.FeatureExtractionParams and
self.FeatureExtractionParams["weighted"]:
            self.tfidf_df, self.tfidf_matrix = self.GetTFIDF(
                self.preprocessedDocs)
            self.doc_embeds = self.SentenceEmbedWeighted(
                self.wordEmbeddedDocs, self.tfidf_df,
self.FeatureExtractionParams["aggregate_method"])
        else:
            self.doc_embeds = self.SentenceEmbedUnweighted(
                self.wordEmbeddedDocs,
self.FeatureExtractionParams["aggregate_method"])

        self.df["Document Embed"] = self.doc_embeds

    def SetTinyEmbeddingResult(self):
        # get max length
        maxdoc = max(self.preprocessedDocs, key=len)
        maxlen = len(maxdoc)
        # extract feature of each word with embedding
        self.doc_embeds = [self.TinyWordEmbed(
            doc, self.model, maxlen) for doc in
self.preprocessedDocs]
        if "weighted" in self.FeatureExtractionParams and
self.FeatureExtractionParams["weighted"]:
            self.tfidf_df, self.tfidf_matrix =
self.GetTFIDF(self.preprocessedDocs)
            self.doc_embeds = [self.TinyWordEmbedWeighted(doc,
self.model, maxlen, i) for i, doc in
enumerate(self.preprocessedDocs)]
```

```
        self.df["Document Embed"] = self.doc_embeds

    def SetDefaultParams(self):
        # here we will put the default params
        self.SetFeatureExtractionParam("method", "Embedding")
        self.SetFeatureExtractionParam("weighted", True)
        self.SetFeatureExtractionParam("condense", False)
        self.SetFeatureExtractionParam("n_topics", 5)
        self.SetFeatureExtractionParam("aggregate_method",
"avg")
        self.SetAnomalyDetectionParam("algorithm", "DBSCAN")
        self.SetAnomalyDetectionParam("epsilon", 1.0)
        self.SetAnomalyDetectionParam("minsamp", 2)
        self.SetAnomalyDetectionParam("epsilon", 1.0)
        self.SetAnomalyDetectionParam("algorithm", "IF")
        self.SetAnomalyDetectionParam("estimators", 500)
        self.SetAnomalyDetectionParam("contamination", 0.1)
        self.SetAnomalyDetectionParam("neighbors", 5)

    # preprocess each doc/sentence
    def SetDocumentTokens(self):
        self.preprocessedDocs = [self.PreprocessDocument(
            doc, isLemma=True, isStopWords=True) for doc in
self.df["answer"]]
        self.df["Tokenized"] = self.preprocessedDocs

        # if cut off data with less than x values
        if "prune" in self.FeatureExtractionParams:
            mask = self.df['Embedded Docs'].apply(
                lambda x: len(x) >
self.FeatureExtractionParams["prune"])
            self.df = self.df[mask]

    '''
    inputs  : None (checks self.FeatureExtractionParams)
```

```
    desc    : assigns topic distribution for each document.
    '''

    def SetLDAResult(self):
        doclist = list(self.df["Tokenized"])
        new_corpus = []
        if self.FeatureExtractionParams["weighted"]:
            self.tfidf_df, self.tfidf_matrix = self.GetTFIDF(
                self.preprocessedDocs)
            for i in range(len(doclist)):
                doc = [(j, self.tfidf_matrix[i, j])
                       for j in self.tfidf_matrix[i].indices]
                new_corpus.append(doc)
                gensim_dict                                    =
corpora.Dictionary.from_corpus(new_corpus)
        else:
            gensim_dict = corpora.Dictionary(doclist)
            new_corpus = [gensim_dict.doc2bow(doc) for doc in
doclist]

        lda_model = gensim.models.LdaModel(
            new_corpus,
num_topics=self.FeatureExtractionParams["n_topics"],
id2word=gensim_dict)
        goofy_ahh_doc_topic_distributions                      =
lda_model[new_corpus]

        docFeatureList = []
        for                 doc_topic_dist                  in
goofy_ahh_doc_topic_distributions:
            featureList = [0.0 for i in range(
                0, self.FeatureExtractionParams["n_topics"])]
            for topic_dist in doc_topic_dist:
                featureList[topic_dist[0]] = topic_dist[1]
            docFeatureList.append(featureList)
```

```
        self.df["Document Embed"] = docFeatureList

    '''
    inputs  :
    -  vectors  :  list<list<float>>  -->  list  of  features
corresponding to each doc/sentence
    desc    : assigns cluster via DBSCAN.
    '''

    def SetDBSCANClusters(self, vectors):
        dbscan = DBSCAN(
            eps=self.AnomalyDetectionParams["epsilon"],
min_samples=self.AnomalyDetectionParams["minsamp"])
        clusters = dbscan.fit_predict(vectors)
        self.df["Cluster Assignment"] = clusters

    '''
    inputs:
    -  vectors  :  list<list<float>>  -->  list  of  features
corresponding to each doc/sentence

    '''

    def SetIFClusters(self, vector):
        isolationForest = IsolationForest(

n_estimators=self.AnomalyDetectionParams["estimators"],
contamination=self.AnomalyDetectionParams["contamination"])
        isolationForest.fit(vector)
        IFResults = isolationForest.decision_function(vector)

        # minus values yield anomalies.
        for i in range(len(IFResults)):
            if IFResults[i] >= 0:
```

```
                IFResults[i] = 0
            else:
                IFResults[i] = -1
        self.df["Cluster Assignment"] = IFResults

    '''
    inputs : vectors : list<list<float>> --> list of features
for each doc/sentence
    '''

    def SetLOFClusters(self, vector):
        lof = LocalOutlierFactor(

n_neighbors=self.AnomalyDetectionParams["neighbors"],
contamination=self.AnomalyDetectionParams["contamination"])
        lof.fit(vector)
        LOFResults = lof.negative_outlier_factor_

        # minus values yield anomalies
        if "lof_generalize" in self.AnomalyDetectionParams and
self.AnomalyDetectionParams["lof_generalize"]:
            print("if minus we go bald")
            LOFResults[LOFResults >= 0] = 0
            LOFResults[LOFResults < 0] = -1
        else:
            # if not generalize, we assume outliers are within
the n-th percentile, with n = contamination rate.
            print(
                "taking                the                {}-th
percentile".format(self.AnomalyDetectionParams["contamination"
] * 100))
            threshold = np.percentile(
                LOFResults,                100                *
self.AnomalyDetectionParams["contamination"])
            LOFResults[LOFResults >= threshold] = 0
```

```
            LOFResults[LOFResults < threshold] = -1
        self.df["Cluster Assignment"] = LOFResults
```

4.3. Implementasi Program

4.3.1. Tools, IDE, dan Library

Pengembangan program dilakukan dalam IDE Visual Studio Code menggunakan bahasa Python. Digunakan *library-library* Python yang diimpor dari PyPI untuk melaksanakan tugas-tugas yang berhubungan dengan perancangan GUI, mengadakan koneksi dengan database, serta melakukan *transcribing* dan *translating file* yang berupa rekaman suara menjadi teks.

4.3.2. GUI

Pengembangan GUI program dilakukan dengan software Qt Designer dan *library* Python-nya, PyQt6. Qt Designer digunakan untuk merancang desain layout untuk setiap window yang diperlukan, yang kemudian disimpan dalam sebuah file dengan extension *.ui*, yang berisi data layout dalam format XML. Dengan command line `pyuic6`, file tersebut dikonversi menjadi code dalam bahasa Python dalam rangka mempermudah pemrograman fungsionalitas dengan library PyQt6.

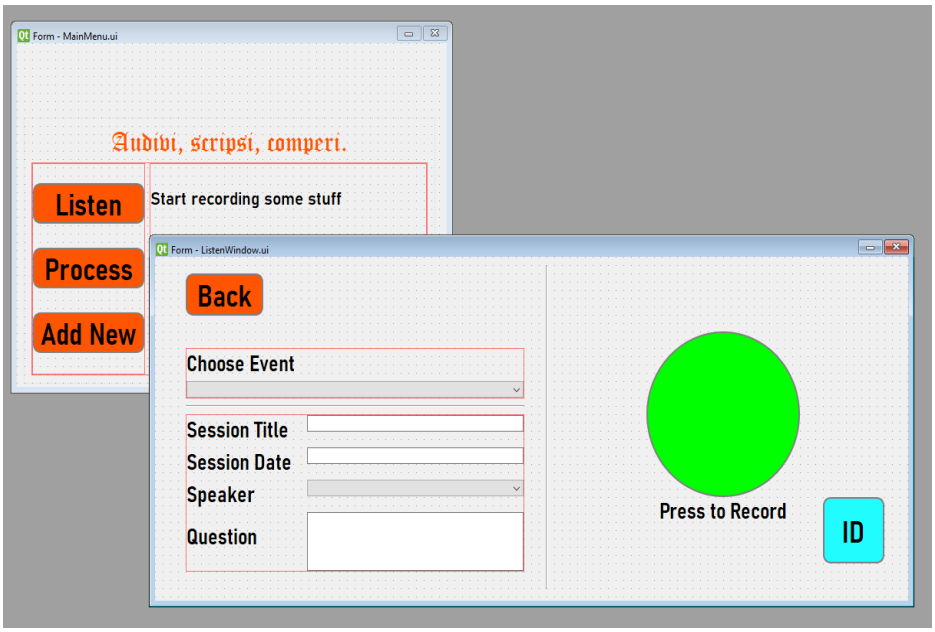

Gambar 4.1 Desain window MainMenu dan ListenWindow dalam program Qt Designer

Untuk program ini, dikembangkan lima Window utama, yaitu MainMenu, AddWindow, ListenWindow, ProcessWindow, dan PresentWindow.

4.3.2.1. MainMenu

MainMenu adalah Window utama dari program. Window ini berisi menu untuk mengarahkan pengguna untuk menjalankan modul yang dikehendaki.

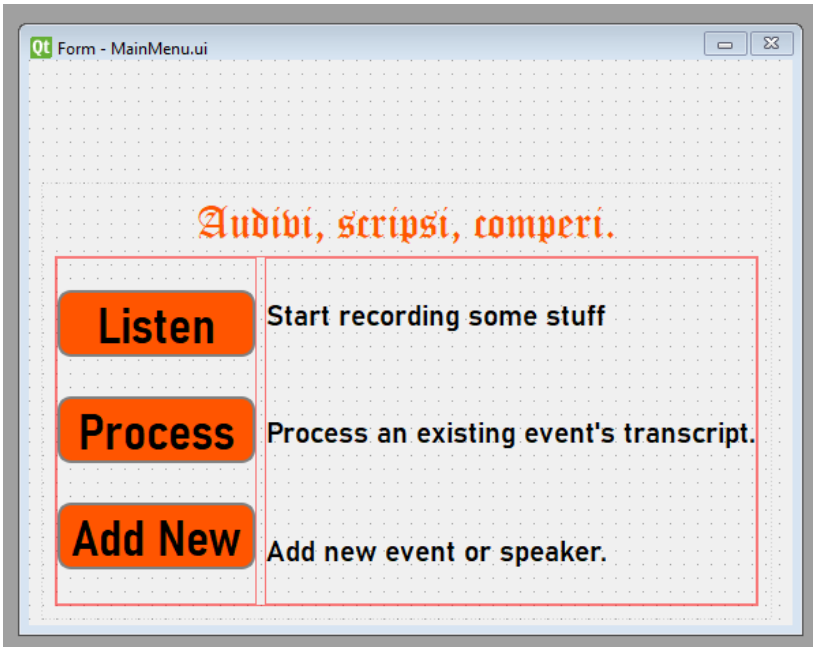

Gambar 4.2 Desain MainMenu dalam program Qt Designer

File MainMenu.ui yang dihasilkan dikonversi menjadi code dalam bahasa Python dengan perintah *command line* berikut ini :

Segmen Kode 4.16 Konversi MainMenu.ui ke mainmenu.py

```
pyuic6 ui/MainMenu.ui -x -o objects/mainmenu.py
```

Segmen Kode 4.17 mainmenu.py

```
# Form implementation generated from reading ui file
'MainMenu.ui'
#
# Created by: PyQt6 UI code generator 6.5.0
#
# WARNING: Any manual changes made to this file will be lost
when pyuic6 is
# run again.  Do not edit this file unless you know what you are
doing.
```

```
from PyQt6 import QtCore, QtGui, QtWidgets


class Ui_Form(object):
    def setupUi(self, Form):
        Form.setObjectName("Form")
        Form.resize(560, 415)
        Form.setStyleSheet("QLabel#label_title{ \n"
"    font: 24pt \"Old English Text MT\";\n"
"    color:rgb(255, 85, 0);\n"
"}\n"
"\n"
"QPushButton{\n"
"    font: 63 28pt \"Bahnschrift SemiBold SemiConden\";\n"
"    background:rgb(255, 85, 0);\n"
"    border: 2px solid gray;\n"
"      border-radius: 10px;\n"
"     padding: 0 8px;\n"
"}\n"
"\n"
"QPushButton:hover{\n"
"    background:rgb(255, 140, 0);\n"
"}\n"
"\n"
"QPushButton:pressed{\n"
"    background: rgb(255, 170, 0);\n"
"}\n"
"\n"
"QLabel{\n"
"    \n"
"    font: 63 16pt \"Bahnschrift SemiBold\";\n"
"}    \n"
"")
```

```
        self.frame = QtWidgets.QFrame(parent=Form)
        self.frame.setGeometry(QtCore.QRect(9, 90, 536, 321))
        self.frame.setStyleSheet("QLabel#label_title,
#label_subtitle{ \n"
"font: 24pt \"Old English Text MT\";\n"
"    color:rgb(255, 85, 0);\n"
"}\n"
"\n"
"QPushButton{\n"
"    font: 63 28pt \"Bahnschrift SemiBold SemiConden\";\n"
"    background:rgb(255, 85, 0);\n"
"    border: 2px solid gray;\n"
"      border-radius: 10px;\n"
"     padding: 0 8px;\n"
"}\n"
"\n"
"QPushButton:hover{\n"
"    background:rgb(255, 140, 0);\n"
"}\n"
"\n"
"QPushButton:pressed{\n"
"    background: rgb(255, 170, 0);\n"
"}\n"
"\n"
"QLabel{\n"
"    \n"
"    font: 63 16pt \"Bahnschrift SemiBold\";\n"
"}    \n"
"")

self.frame.setFrameShape(QtWidgets.QFrame.Shape.StyledPanel)

self.frame.setFrameShadow(QtWidgets.QFrame.Shadow.Raised)
        self.frame.setObjectName("frame")
```

```
        self.verticalLayout_2                                    =
QtWidgets.QVBoxLayout(self.frame)

self.verticalLayout_2.setObjectName("verticalLayout_2")
        self.label_title = QtWidgets.QLabel(parent=self.frame)
        font = QtGui.QFont()
        font.setFamily("Old English Text MT")
        font.setPointSize(24)
        font.setBold(False)
        font.setItalic(False)
        font.setWeight(50)
        self.label_title.setFont(font)

self.label_title.setAlignment(QtCore.Qt.AlignmentFlag.AlignCen
ter)
        self.label_title.setObjectName("label_title")
        self.verticalLayout_2.addWidget(self.label_title)
        self.horizontalLayout = QtWidgets.QHBoxLayout()

self.horizontalLayout.setObjectName("horizontalLayout")
        self.layout_buttons = QtWidgets.QVBoxLayout()
        self.layout_buttons.setObjectName("layout_buttons")
        self.button_listen                                       =
QtWidgets.QPushButton(parent=self.frame)
        sizePolicy                                               =
QtWidgets.QSizePolicy(QtWidgets.QSizePolicy.Policy.Minimum,
QtWidgets.QSizePolicy.Policy.Fixed)
        sizePolicy.setHorizontalStretch(0)
        sizePolicy.setVerticalStretch(0)

sizePolicy.setHeightForWidth(self.button_listen.sizePolicy().h
asHeightForWidth())
        self.button_listen.setSizePolicy(sizePolicy)
        self.button_listen.setObjectName("button_listen")
        self.layout_buttons.addWidget(self.button_listen)
```

```
        self.button_process                                    =
QtWidgets.QPushButton(parent=self.frame)
        self.button_process.setObjectName("button_process")
        self.layout_buttons.addWidget(self.button_process)
        self.button_create                                     =
QtWidgets.QPushButton(parent=self.frame)
        self.button_create.setObjectName("button_create")
        self.layout_buttons.addWidget(self.button_create)
        self.horizontalLayout.addLayout(self.layout_buttons)
        self.layout_labels = QtWidgets.QVBoxLayout()
        self.layout_labels.setObjectName("layout_labels")
        self.label_listen = QtWidgets.QLabel(parent=self.frame)
        self.label_listen.setObjectName("label_listen")
        self.layout_labels.addWidget(self.label_listen)
        self.label_process                                     =
QtWidgets.QLabel(parent=self.frame)
        self.label_process.setObjectName("label_process")
        self.layout_labels.addWidget(self.label_process)
        self.label_add = QtWidgets.QLabel(parent=self.frame)
        self.label_add.setObjectName("label_add")
        self.layout_labels.addWidget(self.label_add)
        self.horizontalLayout.addLayout(self.layout_labels)
        self.horizontalLayout.setStretch(0, 1)
        self.horizontalLayout.setStretch(1, 2)
        self.verticalLayout_2.addLayout(self.horizontalLayout)
        self.verticalLayout_2.setStretch(1, 8)
        self.label_icon = QtWidgets.QLabel(parent=Form)
        self.label_icon.setGeometry(QtCore.QRect(220,  0,  100,
100))
        sizePolicy                                             =
QtWidgets.QSizePolicy(QtWidgets.QSizePolicy.Policy.Fixed,
QtWidgets.QSizePolicy.Policy.Fixed)
        sizePolicy.setHorizontalStretch(0)
        sizePolicy.setVerticalStretch(0)
```

```
sizePolicy.setHeightForWidth(self.label_icon.sizePolicy().hasH
eightForWidth())
        self.label_icon.setSizePolicy(sizePolicy)
        self.label_icon.setText("")

self.label_icon.setPixmap(QtGui.QPixmap("asset/images/Solaire.
png"))
        self.label_icon.setScaledContents(True)
        self.label_icon.setObjectName("label_icon")

        self.retranslateUi(Form)
        QtCore.QMetaObject.connectSlotsByName(Form)

    def retranslateUi(self, Form):
        _translate = QtCore.QCoreApplication.translate
        Form.setWindowTitle(_translate("Form", "Form"))
        self.label_title.setText(_translate("Form",    "Audivi,
scripsi, comperi."))
        self.button_listen.setText(_translate("Form",
"Listen"))
        self.button_process.setText(_translate("Form",
"Process"))
        self.button_create.setText(_translate("Form",      "Add
New"))
        self.label_listen.setText(_translate("Form",     "Start
recording some stuff"))
        self.label_process.setText(_translate("Form",  "Process
an existing event\'s transcript."))
        self.label_add.setText(_translate("Form",    "Add    new
event or speaker."))


if __name__ == "__main__":
    import sys
```

```
    app = QtWidgets.QApplication(sys.argv)
    Form = QtWidgets.QWidget()
    ui = Ui_Form()
    ui.setupUi(Form)
    Form.show()
    sys.exit(app.exec())
```

File `mainmenu.py` yang dihasilkan digunakan sebagai *inheritance* untuk *class* `MainMenu()` yang ada di file utama `app.py`, dimana tombol-tombol yang telah didesain dihubungkan dengan fungsi-fungsi yang sesuai.

Segmen Kode 4.18 Class MainMenuWindow

```
class MainMenuWindow(qtw.QWidget):
    def __init__(self):
        super().__init__()
        # set stuff here
        self.ui = mm.Ui_Form()
        self.ui.setupUi(self)
        self.setWindowTitle(
            "I hear, I write, I discover")

self.setWindowIcon(qtg.QIcon("asset/images/Solaire.png"))
        # thanks to Rueful on Discord for grammatical
correction.
        self.ui.label_title.setText("Audio, Scribo, Comperio")
        #
self.ui.label_icon.setPixmap(qtg.QPixmap("asset/images/Solaire
.png"))

        # connect stuff here

self.ui.button_listen.clicked.connect(self.button_startListeni
ng)
```

```
self.ui.button_process.clicked.connect(self.button_startProces
sing)

self.ui.button_create.clicked.connect(self.button_startCreatin
g)

    def button_startListening(self):
        self.listenWindow = ListenWindow(self)
        self.hide()
        self.listenWindow.show()

    def button_startProcessing(self):
        self.processWindow = ProcessWindow(self)
        self.hide()
        self.processWindow.show()

    def button_startCreating(self):
        self.addWindow = AddWindow(self)
        self.hide()
        self.addWindow.show()
```

Dalam *class* ini, diatur fungsi setiap tombol yang ada dalam menu. Tombol “Listen” akan membuka ListenWindow, dimana pengguna bisa memulai proses rekaman dalam sebuah diskusi dan menyimpan datanya. Tombol “Process” akan membuka ProcessWindow, dimana pengguna bisa membuka data hasil rekaman sebuah diskusi, melakukan *transcribing*, lalu memerintahkan program untuk melakukan deteksi anomali pada data tersebut. Tombol “Add New” akan membuka AddWindow, dimana pengguna bisa melakukan penambahan data sesi diskusi, serta nama dan kode pembicara yang bisa digunakan dalam proses Listening berikutnya.

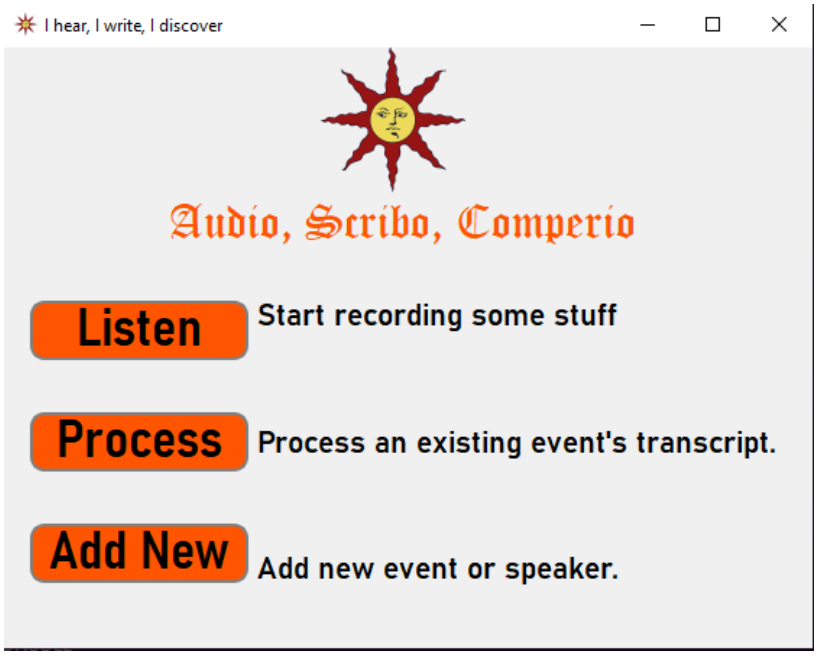

Gambar 4.3 Window MainMenu dalam program yang sudah dirancang dan dijalankan

4.3.2.1. AddWindow

AddWindow adalah sebuah Window dimana pengguna dapat menambahkan data berupa *event* diskusi atau pembicara baru. Data-data ini digunakan sebagai metadata pelengkap untuk mencatat rekor data rekaman pernyataan seorang peserta dalam sebuah sesi diskusi, menurut skema *database* yang telah ditentukan.

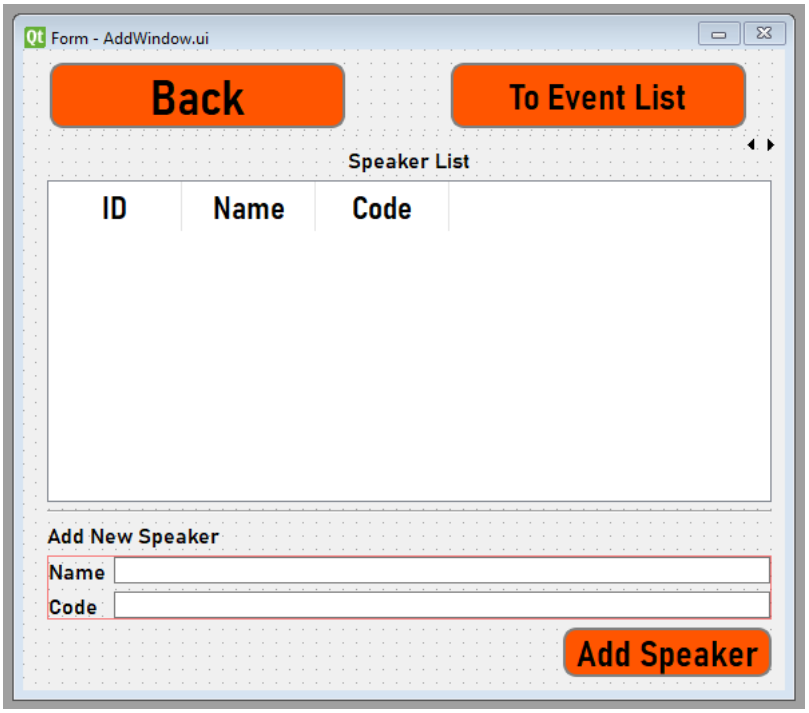

Gambar 4.4 Desain AddWindow dalam QtDesigner

File AddWindow.ui yang dihasilkan dikonversi menjadi code dalam bahasa Python dengan perintah *command line* berikut ini :

Segmen Kode 4.19 Konversi AddWindow.ui ke addwindow.py

```
pyuic6 ui/AddWindow.ui -x -o objects/addwindow.py
```

Segmen Kode 4.20 addwindow.py

```
# Form implementation generated from reading ui file
'ui/AddWindow.ui'
#
# Created by: PyQt6 UI code generator 6.5.0
#
# WARNING: Any manual changes made to this file will be lost
when pyuic6 is
# run again.  Do not edit this file unless you know what you are
doing.


from PyQt6 import QtCore, QtGui, QtWidgets


class Ui_Form(object):
    def setupUi(self, Form):
        Form.setObjectName("Form")
        Form.resize(570, 480)
        Form.setStyleSheet("QLabel#label_title,
#label_subtitle{ \n"
"    \n"
"    font: 63 28pt \"Bahnschrift SemiBold SemiConden\";\n"
"    color:rgb(255, 85, 0);\n"
"}\n"
"\n"
"QPushButton{\n"
"    font: 63 28pt \"Bahnschrift SemiBold SemiConden\";\n"
"    background:rgb(255, 85, 0);\n"
```

```
"    border: 2px solid gray;\n"
"      border-radius: 10px;\n"
"     padding: 0 8px;\n"
"}\n"
"\n"
"QPushButton#button_addSpeaker,    QPushButton#button_addEvent,
QPushButton#button_toggle_widget{\n"
"    font: 63 20pt \"Bahnschrift SemiBold SemiConden\";\n"
"}\n"
"QPushButton:hover{\n"
"    background:rgb(255, 140, 0);\n"
"}\n"
"\n"
"QPushButton:pressed{\n"
"    background: rgb(255, 170, 0);\n"
"}\n"
"\n"
"QLabel{\n"
"    font: 63 16pt \"Bahnschrift SemiBold\";\n"
"}    \n"
"\n"
"QLabel{\n"
"    \n"
"    font: 63 12pt \"Bahnschrift SemiBold\";\n"
"}\n"
"QTableWidget{\n"
"    font: 14pt \"Bahnschrift\";\n"
"}\n"
"\n"
"QHeaderView{\n"
"    font: 63 18pt \"Bahnschrift SemiBold SemiConden\";\n"
"}")
        self.button_toggle_widget                                    =
QtWidgets.QPushButton(parent=Form)
        self.button_toggle_widget.setEnabled(True)
```

```
self.button_toggle_widget.setGeometry(QtCore.QRect(320,     10,
221, 49))
        sizePolicy                                              =
QtWidgets.QSizePolicy(QtWidgets.QSizePolicy.Policy.Maximum,
QtWidgets.QSizePolicy.Policy.Fixed)
        sizePolicy.setHorizontalStretch(0)
        sizePolicy.setVerticalStretch(0)

sizePolicy.setHeightForWidth(self.button_toggle_widget.sizePol
icy().hasHeightForWidth())
        self.button_toggle_widget.setSizePolicy(sizePolicy)
        self.button_toggle_widget.setFlat(False)

self.button_toggle_widget.setObjectName("button_toggle_widget"
)
        self.stackedWidget                                      =
QtWidgets.QStackedWidget(parent=Form)
        self.stackedWidget.setGeometry(QtCore.QRect(9, 64, 560,
415))
        self.stackedWidget.setObjectName("stackedWidget")
        self.page_addSpeaker = QtWidgets.QWidget()
        self.page_addSpeaker.setObjectName("page_addSpeaker")
        self.verticalLayout                                     =
QtWidgets.QVBoxLayout(self.page_addSpeaker)
        self.verticalLayout.setObjectName("verticalLayout")
        self.label_speakerList                                  =
QtWidgets.QLabel(parent=self.page_addSpeaker)

self.label_speakerList.setAlignment(QtCore.Qt.AlignmentFlag.Al
ignCenter)

self.label_speakerList.setObjectName("label_speakerList")
        self.verticalLayout.addWidget(self.label_speakerList)
```

```
        self.table_speakers =
QtWidgets.QTableWidget(parent=self.page_addSpeaker)
        self.table_speakers.setShowGrid(True)
        self.table_speakers.setColumnCount(3)
        self.table_speakers.setObjectName("table_speakers")
        self.table_speakers.setRowCount(0)
        item = QtWidgets.QTableWidgetItem()
        self.table_speakers.setHorizontalHeaderItem(0, item)
        item = QtWidgets.QTableWidgetItem()
        self.table_speakers.setHorizontalHeaderItem(1, item)
        item = QtWidgets.QTableWidgetItem()
        self.table_speakers.setHorizontalHeaderItem(2, item)
        self.verticalLayout.addWidget(self.table_speakers)
        self.line =
QtWidgets.QFrame(parent=self.page_addSpeaker)
        self.line.setFrameShape(QtWidgets.QFrame.Shape.HLine)

self.line.setFrameShadow(QtWidgets.QFrame.Shadow.Sunken)
        self.line.setObjectName("line")
        self.verticalLayout.addWidget(self.line)
        self.label_addSpeaker =
QtWidgets.QLabel(parent=self.page_addSpeaker)

self.label_addSpeaker.setObjectName("label_addSpeaker")
        self.verticalLayout.addWidget(self.label_addSpeaker)
        self.formLayout = QtWidgets.QFormLayout()
        self.formLayout.setObjectName("formLayout")
        self.label_name =
QtWidgets.QLabel(parent=self.page_addSpeaker)
        font = QtGui.QFont()
        font.setFamily("Bahnschrift SemiBold")
        font.setPointSize(12)
        font.setBold(False)
        font.setItalic(False)
        font.setWeight(7)
```

```
        self.label_name.setFont(font)
        self.label_name.setObjectName("label_name")
        self.formLayout.setWidget(0,
QtWidgets.QFormLayout.ItemRole.LabelRole, self.label_name)
        self.line_name                                          =
QtWidgets.QLineEdit(parent=self.page_addSpeaker)
        self.line_name.setObjectName("line_name")
        self.formLayout.setWidget(0,
QtWidgets.QFormLayout.ItemRole.FieldRole, self.line_name)
        self.label_code                                         =
QtWidgets.QLabel(parent=self.page_addSpeaker)
        self.label_code.setObjectName("label_code")
        self.formLayout.setWidget(1,
QtWidgets.QFormLayout.ItemRole.LabelRole, self.label_code)
        self.line_code                                          =
QtWidgets.QLineEdit(parent=self.page_addSpeaker)
        self.line_code.setObjectName("line_code")
        self.formLayout.setWidget(1,
QtWidgets.QFormLayout.ItemRole.FieldRole, self.line_code)
        self.verticalLayout.addLayout(self.formLayout)
        self.button_addSpeaker                                  =
QtWidgets.QPushButton(parent=self.page_addSpeaker)
        sizePolicy                                              =
QtWidgets.QSizePolicy(QtWidgets.QSizePolicy.Policy.Maximum,
QtWidgets.QSizePolicy.Policy.Fixed)
        sizePolicy.setHorizontalStretch(0)
        sizePolicy.setVerticalStretch(0)

sizePolicy.setHeightForWidth(self.button_addSpeaker.sizePolicy
().hasHeightForWidth())
        self.button_addSpeaker.setSizePolicy(sizePolicy)

self.button_addSpeaker.setLayoutDirection(QtCore.Qt.LayoutDire
ction.RightToLeft)
```

```
self.button_addSpeaker.setObjectName("button_addSpeaker")
        self.verticalLayout.addWidget(self.button_addSpeaker)
        self.stackedWidget.addWidget(self.page_addSpeaker)
        self.page_addEvent = QtWidgets.QWidget()
        self.page_addEvent.setObjectName("page_addEvent")
        self.verticalLayout_2                                    =
QtWidgets.QVBoxLayout(self.page_addEvent)

self.verticalLayout_2.setObjectName("verticalLayout_2")
        self.label_eventList                                     =
QtWidgets.QLabel(parent=self.page_addEvent)

self.label_eventList.setAlignment(QtCore.Qt.AlignmentFlag.Alig
nCenter)
        self.label_eventList.setObjectName("label_eventList")
        self.verticalLayout_2.addWidget(self.label_eventList)
        self.table_events                                        =
QtWidgets.QTableWidget(parent=self.page_addEvent)
        self.table_events.setObjectName("table_events")
        self.table_events.setColumnCount(3)
        self.table_events.setRowCount(0)
        item = QtWidgets.QTableWidgetItem()
        self.table_events.setHorizontalHeaderItem(0, item)
        item = QtWidgets.QTableWidgetItem()
        self.table_events.setHorizontalHeaderItem(1, item)
        item = QtWidgets.QTableWidgetItem()
        self.table_events.setHorizontalHeaderItem(2, item)
        self.verticalLayout_2.addWidget(self.table_events)
        self.line_2                                              =
QtWidgets.QFrame(parent=self.page_addEvent)

self.line_2.setFrameShape(QtWidgets.QFrame.Shape.HLine)

self.line_2.setFrameShadow(QtWidgets.QFrame.Shadow.Sunken)
```

```
        self.line_2.setObjectName("line_2")
        self.verticalLayout_2.addWidget(self.line_2)
        self.label_addEvent                                    =
QtWidgets.QLabel(parent=self.page_addEvent)
        self.label_addEvent.setObjectName("label_addEvent")
        self.verticalLayout_2.addWidget(self.label_addEvent)
        self.formLayout_2 = QtWidgets.QFormLayout()
        self.formLayout_2.setObjectName("formLayout_2")
        self.label_eventTitle                                  =
QtWidgets.QLabel(parent=self.page_addEvent)

self.label_eventTitle.setObjectName("label_eventTitle")
        self.formLayout_2.setWidget(0,
QtWidgets.QFormLayout.ItemRole.LabelRole,
self.label_eventTitle)
        self.label_2                                           =
QtWidgets.QLabel(parent=self.page_addEvent)
        self.label_2.setObjectName("label_2")
        self.formLayout_2.setWidget(1,
QtWidgets.QFormLayout.ItemRole.LabelRole, self.label_2)
        self.line_title                                        =
QtWidgets.QLineEdit(parent=self.page_addEvent)
        self.line_title.setObjectName("line_title")
        self.formLayout_2.setWidget(0,
QtWidgets.QFormLayout.ItemRole.FieldRole, self.line_title)
        self.line_date                                         =
QtWidgets.QLineEdit(parent=self.page_addEvent)
        self.line_date.setObjectName("line_date")
        self.formLayout_2.setWidget(1,
QtWidgets.QFormLayout.ItemRole.FieldRole, self.line_date)
        self.verticalLayout_2.addLayout(self.formLayout_2)
        self.button_addEvent                                   =
QtWidgets.QPushButton(parent=self.page_addEvent)
```

```
        sizePolicy                                                  =
QtWidgets.QSizePolicy(QtWidgets.QSizePolicy.Policy.Maximum,
QtWidgets.QSizePolicy.Policy.Fixed)
        sizePolicy.setHorizontalStretch(0)
        sizePolicy.setVerticalStretch(0)

sizePolicy.setHeightForWidth(self.button_addEvent.sizePolicy()
.hasHeightForWidth())
        self.button_addEvent.setSizePolicy(sizePolicy)

self.button_addEvent.setLayoutDirection(QtCore.Qt.LayoutDirect
ion.RightToLeft)
        self.button_addEvent.setDefault(False)
        self.button_addEvent.setObjectName("button_addEvent")
        self.verticalLayout_2.addWidget(self.button_addEvent)
        self.stackedWidget.addWidget(self.page_addEvent)
        self.button_back = QtWidgets.QPushButton(parent=Form)
        self.button_back.setEnabled(True)
        self.button_back.setGeometry(QtCore.QRect(20, 10, 221,
49))
        sizePolicy                                                  =
QtWidgets.QSizePolicy(QtWidgets.QSizePolicy.Policy.Maximum,
QtWidgets.QSizePolicy.Policy.Fixed)
        sizePolicy.setHorizontalStretch(0)
        sizePolicy.setVerticalStretch(0)

sizePolicy.setHeightForWidth(self.button_back.sizePolicy().has
HeightForWidth())
        self.button_back.setSizePolicy(sizePolicy)
        self.button_back.setFlat(False)
        self.button_back.setObjectName("button_back")

        self.retranslateUi(Form)
        self.stackedWidget.setCurrentIndex(0)
        QtCore.QMetaObject.connectSlotsByName(Form)
```

```
    def retranslateUi(self, Form):
        _translate = QtCore.QCoreApplication.translate
        Form.setWindowTitle(_translate("Form", "Form"))
        self.button_toggle_widget.setText(_translate("Form",
"To Event List"))
        self.label_speakerList.setText(_translate("Form",
"Speaker List"))
        item = self.table_speakers.horizontalHeaderItem(0)
        item.setText(_translate("Form", "ID"))
        item = self.table_speakers.horizontalHeaderItem(1)
        item.setText(_translate("Form", "Name"))
        item = self.table_speakers.horizontalHeaderItem(2)
        item.setText(_translate("Form", "Code"))
        self.label_addSpeaker.setText(_translate("Form",   "Add
New Speaker"))
        self.label_name.setText(_translate("Form", "Name"))
        self.label_code.setText(_translate("Form", "Code"))
        self.button_addSpeaker.setText(_translate("Form",  "Add
Speaker"))
        self.label_eventList.setText(_translate("Form",  "Event
List"))
        item = self.table_events.horizontalHeaderItem(0)
        item.setText(_translate("Form", "ID"))
        item = self.table_events.horizontalHeaderItem(1)
        item.setText(_translate("Form", "Title"))
        item = self.table_events.horizontalHeaderItem(2)
        item.setText(_translate("Form", "Date"))
        self.label_addEvent.setText(_translate("Form", "Add New
Event"))
        self.label_eventTitle.setText(_translate("Form",
"Title"))
        self.label_2.setText(_translate("Form", "Date"))
        self.button_addEvent.setText(_translate("Form",    "Add
event"))
```

```
        self.button_back.setText(_translate("Form", "Back"))


if __name__ == "__main__":
    import sys
    app = QtWidgets.QApplication(sys.argv)
    Form = QtWidgets.QWidget()
    ui = Ui_Form()
    ui.setupUi(Form)
    Form.show()
    sys.exit(app.exec())
```

File `addwindow.py` digunakan sebagai *inheritance* untuk *class* baru `AddWindow()` yang dibuat di `app.py`. Elemen-elemen yang telah didesain dihubungkan dengan fungsi-fungsi yang berfungsi untuk menambahkan data pada tabel-tabel `speakers` dan `events` pada *database*.

Segmen Kode 4.21 Class AddWindow

```
class AddWindow(qtw.QWidget):
    def __init__(self, mainwindow):
        super().__init__()

        # set mainwindow
        self.mainwindow = mainwindow

        # set stuff
        self.ui = aw.Ui_Form()
        self.ui.setupUi(self)
        # whosoever has hands with which to write, let him write!
        self.setWindowTitle("qui habet manus scribendum,
scribat!")

self.setWindowIcon(qtg.QIcon("asset/images/Solaire.png"))
        self.LoadTables(self.ui.table_speakers)
        self.LoadTables(self.ui.table_events)
```

```
        self.msgBox = qtw.QMessageBox()

self.msgBox.setStandardButtons(qtw.QMessageBox.StandardButton.
Ok)

self.msgBox.setWindowIcon(qtg.QIcon("asset/images/Solaire.png"
))

        # connect stuff here
        self.ui.button_back.clicked.connect(self.GoBack)

self.ui.button_toggle_widget.clicked.connect(self.ToggleWidget
)
        self.ui.button_addEvent.clicked.connect(self.AddEvent)

self.ui.button_addSpeaker.clicked.connect(self.AddSpeaker)

    def GoBack(self):
        self.hide()
        self.mainwindow.show()

    def ToggleWidget(self):
        if self.ui.stackedWidget.currentIndex() == 0:
            self.ui.stackedWidget.setCurrentIndex(1)
            self.ui.button_toggle_widget.setText("To    Speaker
List")
        else:
            self.ui.stackedWidget.setCurrentIndex(0)
            self.ui.button_toggle_widget.setText("To      Event
List")

    def LoadTables(self, table):
        # fetch data
        dataList = []
        if table.objectName() == "table_speakers":
```

```
            dataList = cursor.list_speakers()
        elif table.objectName() == "table_events":
            dataList = cursor.list_events()
        # put in table
        for i in range(len(dataList)):
            table.insertRow(i)
            for j in range(len(dataList[i])):
                table.setItem(
                    i,                                          j,
qtw.QTableWidgetItem(str(dataList[i][j])))

        # resize
        header = table.horizontalHeader()
        header.setSectionResizeMode(
            0, qtw.QHeaderView.ResizeMode.ResizeToContents)
        header.setSectionResizeMode(1,
qtw.QHeaderView.ResizeMode.Stretch)
        header.setSectionResizeMode(
            2, qtw.QHeaderView.ResizeMode.ResizeToContents)

    def MessageSuccess(self, txt):
        # success
        self.msgBox.setIcon(qtw.QMessageBox.Icon.Information)
        self.msgBox.setText("You dun did it\n{}".format(txt))
        self.msgBox.show()

    def MessageFail(self, txt):
        self.msgBox.setIcon(qtw.QMessageBox.Icon.Warning)
        self.msgBox.setText("You dun goofed\n{}".format(txt))
        self.msgBox.show()

    def AddEvent(self):
        if     self.ui.line_title.text()     !=     ""     and
self.ui.line_date.text() != "":
            cursor.create_event(self.ui.line_title.text(),
```

```
                                self.ui.line_date.text())

            # success
            self.MessageSuccess("Event created")
            # clear lines
            self.ui.line_title.clear()
            self.ui.line_date.clear()
            # reload table
            self.ui.table_events.setRowCount(0)
            self.LoadTables(self.ui.table_events)

        else:
            self.MessageFail("Event not created")

    def AddSpeaker(self):
        if     self.ui.line_name.text()     !=     ""     and
self.ui.line_code.text() != "":
            cursor.create_speaker(self.ui.line_name.text(),
                                  self.ui.line_code.text())
            # success
            self.MessageSuccess("Speaker created")
            # clear lines
            self.ui.line_name.clear()
            self.ui.line_code.clear()
            # reload table
            self.ui.table_speakers.setRowCount(0)
            self.LoadTables(self.ui.table_speakers)
        else:
            self.MessageFail("Speaker not created")
```

Berikut tabel fungsi-fungsi yang ada dalam class `AddWindow` dan fungsinya.

Tabel 4.3 Mapping fungsi class AddWindow

Class	Parameter	Keterangan

`GoBack()`	-	Dihubungkan pada tombol "Back". Berfungsi untuk kembali ke `MainMenuWindow`.
`ToggleWidget()`	-	Untuk mengganti pilihan menu, melakukan toggle antara menambahkan pembicara ("speaker") atau sesi diskusi ("event") baru.
`LoadTables()`	Obyek tabel yang ada dalam `addwindow.py`	Memerintahkan obyek `DatabaseHandler()` untuk mengambil seluruh data pembicara dari tabel `speakers` atau sesi diskusi dari tabel `events`, tergantung *widget* yang sedang aktif sekarang.
`MessageSuccess()`	Pesan berupa *string*	Menampilkan *message box* yang akan dipanggil jika penambahan data berhasil.
`MessageFail()`	Pesan berupa *string*	Menampilkan message box yang akan dipanggil jika penambahan data gagal.
`AddEvent()`	-	Memerintahkan obyek `DatabaseHandler()` untuk membuat sebuah rekor data baru pada tabel `events` sesuai dengan data yang dimasukkan pengguna.
`AddSpeaker()`	-	Memerintahkan obyek `DatabaseHandler()` untuk membuat sebuah rekor data baru pada tabel

		`speakers` sesuai dengan masukan pengguna.

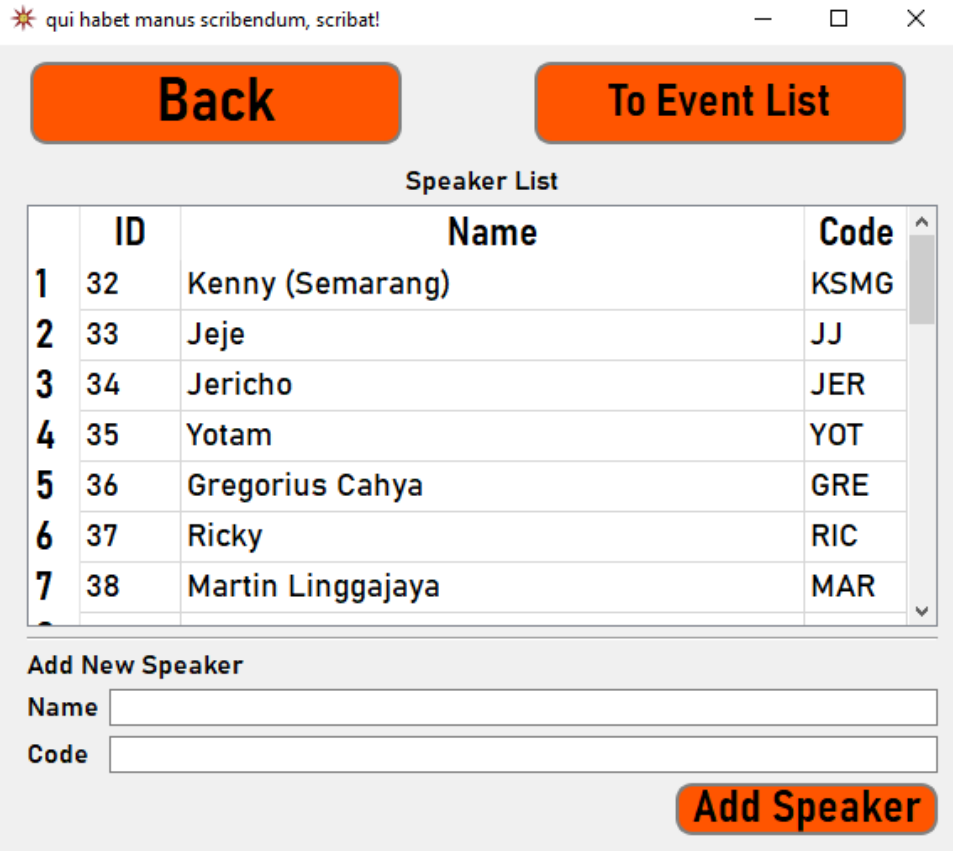

Gambar 4.5 AddWindow untuk menambahkan pembicara baru.

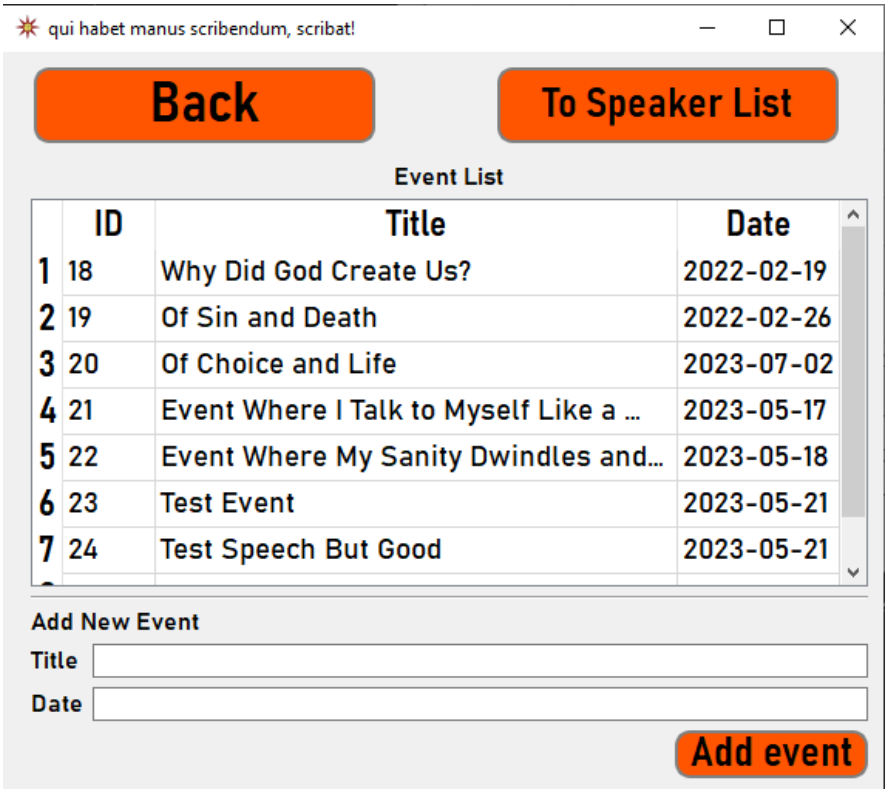

Gambar 4.6 AddWindow untuk menambahkan sesi diskusi baru.

4.3.2.2. ListenWindow

ListenWindow digunakan sebagai sarana pengumpulan rekaman pendapat pembicara dalam sebuah sesi diskusi. Pengguna bisa memilih sesi dan pembicara yang telah terdaftarkan sebagai metadata, dan memulai atau menghentikan rekaman sesuai dengan kebutuhan.

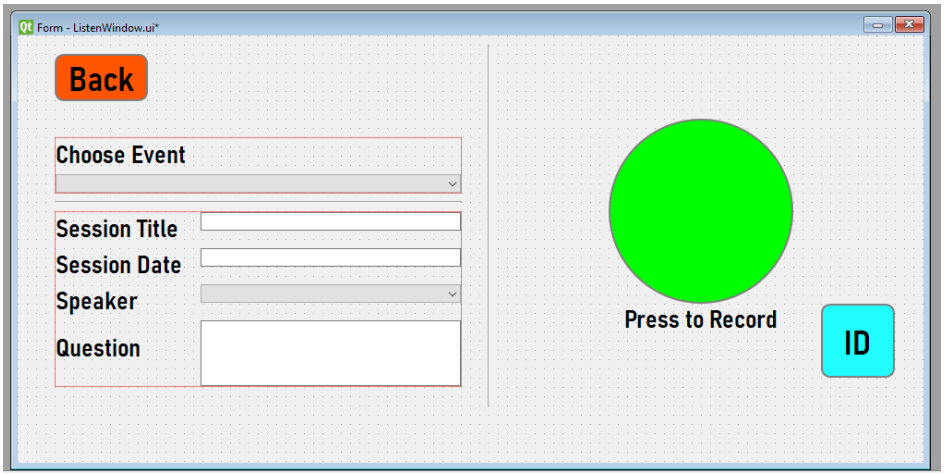

Gambar 4.7 Desain ListenWindow pada Qt Designer

File ListenWindow.ui yang dihasilkan dikonversi menjadi code dalam bahasa Python dengan perintah *command line* berikut ini :

Segmen Kode 4.22 Konversi ListenWindow.ui ke listenwindow.py

```
pyuic6 ui/ListenWindow.ui -x -o objects/listenwindow.py
```

Segmen Kode 4.23 listenwindow.py

```
# Form implementation generated from reading ui file
'ui/ListenWindow.ui'
#
# Created by: PyQt6 UI code generator 6.5.0
#
# WARNING: Any manual changes made to this file will be lost
when pyuic6 is
# run again.  Do not edit this file unless you know what you are
doing.


from PyQt6 import QtCore, QtGui, QtWidgets


class Ui_Form(object):
    def setupUi(self, Form):
        Form.setObjectName("Form")
        Form.resize(981, 415)
        Form.setStyleSheet("QLabel#label_title,
#label_subtitle{ \n"
"    \n"
"    font: 63 28pt \"Bahnschrift SemiBold SemiConden\";\n"
"    color:rgb(255, 85, 0);\n"
"}\n"
"\n"
"QLabel{\n"
"    font: 63 20pt \"Bahnschrift SemiBold SemiConden\";\n"
"}\n"
"\n"
"QPushButton{\n"
```

```
"    font: 63 28pt \"Bahnschrift SemiBold SemiConden\";\n"
"    background:rgb(255, 85, 0);\n"
"    border: 2px solid gray;\n"
"    border-radius:10px;\n"
"     padding: 0 8px;\n"
"}\n"
"\n"
"QPushButton:hover{\n"
"    background:rgb(255, 140, 0);\n"
"}\n"
"\n"
"QPushButton:pressed{\n"
"    background: rgb(255, 170, 0);\n"
"}\n"
"\n"
"QPushButton#button_record{\n"
"    background:rgb(0, 255, 0);\n"
"    border-radius: 100px;\n"
"}\n"
"\n"
"QPushButton#button_record:checked{\n"
"    background:rgb(255, 0, 0);\n"
"}\n"
"\n"
"QPushButton#button_record:hover{\n"
"    background:rgb(0, 170, 0);\n"
"}\n"
"\n"
"QPushButton#button_record:checked:hover{\n"
"    background:rgb(255, 35, 28);\n"
"}\n"
"\n"
"QPushButton#button_toggleLang:checked{\n"
"    \n"
"    background: rgb(32, 252, 255);\n"
```

```
"}\n"
"\n"
"QPushButton#button_toggleLang:checked:hover{\n"
"    \n"
"    background: rgb(0, 170, 255);\n"
"}\n"
"\n"
"QPushButton#button_toggleLang:pressed{\n"
"    \n"
"    background: rgb(85, 0, 255);\n"
"}\n"
"\n"
"QPushButton#button_toggleLang{\n"
"    \n"
"    background: rgb(255, 42, 88);\n"
"}\n"
"\n"
"QPushButton#button_toggleLang:hover{\n"
"    \n"
"    background: rgb(255, 0, 0);\n"
"}")
        self.button_record = QtWidgets.QPushButton(parent=Form)
        self.button_record.setGeometry(QtCore.QRect(640,    90,
200, 200))
        font = QtGui.QFont()
        font.setFamily("Bahnschrift SemiBold SemiConden")
        font.setPointSize(28)
        font.setBold(False)
        font.setItalic(False)
        font.setWeight(7)
        self.button_record.setFont(font)
        self.button_record.setText("")
        icon = QtGui.QIcon()
```

```
icon.addPixmap(QtGui.QPixmap("ui\\asset/images/mic.png"),
QtGui.QIcon.Mode.Normal, QtGui.QIcon.State.Off)
        self.button_record.setIcon(icon)
        self.button_record.setIconSize(QtCore.QSize(100, 100))
        self.button_record.setCheckable(True)
        self.button_record.setChecked(False)
        self.button_record.setObjectName("button_record")
        self.formLayoutWidget_2                                    =
QtWidgets.QWidget(parent=Form)
        self.formLayoutWidget_2.setGeometry(QtCore.QRect(40,
190, 441, 190))

self.formLayoutWidget_2.setObjectName("formLayoutWidget_2")
        self.formLayout_2                                          =
QtWidgets.QFormLayout(self.formLayoutWidget_2)
        self.formLayout_2.setContentsMargins(0, 0, 0, 0)
        self.formLayout_2.setHorizontalSpacing(20)
        self.formLayout_2.setObjectName("formLayout_2")
        self.label_session                                         =
QtWidgets.QLabel(parent=self.formLayoutWidget_2)
        font = QtGui.QFont()
        font.setFamily("Bahnschrift SemiBold SemiConden")
        font.setPointSize(20)
        font.setBold(False)
        font.setItalic(False)
        font.setWeight(7)
        self.label_session.setFont(font)
        self.label_session.setObjectName("label_session")
        self.formLayout_2.setWidget(0,
QtWidgets.QFormLayout.ItemRole.LabelRole, self.label_session)
        self.line_title                                            =
QtWidgets.QLineEdit(parent=self.formLayoutWidget_2)
        self.line_title.setReadOnly(True)
        self.line_title.setObjectName("line_title")
```

```
        self.formLayout_2.setWidget(0,
QtWidgets.QFormLayout.ItemRole.FieldRole, self.line_title)
        self.label_date                                          =
QtWidgets.QLabel(parent=self.formLayoutWidget_2)
        font = QtGui.QFont()
        font.setFamily("Bahnschrift SemiBold SemiConden")
        font.setPointSize(20)
        font.setBold(False)
        font.setItalic(False)
        font.setWeight(7)
        self.label_date.setFont(font)
        self.label_date.setObjectName("label_date")
        self.formLayout_2.setWidget(1,
QtWidgets.QFormLayout.ItemRole.LabelRole, self.label_date)
        self.line_date                                           =
QtWidgets.QLineEdit(parent=self.formLayoutWidget_2)
        self.line_date.setReadOnly(True)
        self.line_date.setObjectName("line_date")
        self.formLayout_2.setWidget(1,
QtWidgets.QFormLayout.ItemRole.FieldRole, self.line_date)
        self.label_speakers                                      =
QtWidgets.QLabel(parent=self.formLayoutWidget_2)
        font = QtGui.QFont()
        font.setFamily("Bahnschrift SemiBold SemiConden")
        font.setPointSize(20)
        font.setBold(False)
        font.setItalic(False)
        font.setWeight(7)
        self.label_speakers.setFont(font)
        self.label_speakers.setObjectName("label_speakers")
        self.formLayout_2.setWidget(2,
QtWidgets.QFormLayout.ItemRole.LabelRole, self.label_speakers)
        self.combo_speakerList                                   =
QtWidgets.QComboBox(parent=self.formLayoutWidget_2)
```

```
self.combo_speakerList.setObjectName("combo_speakerList")
        self.formLayout_2.setWidget(2,
QtWidgets.QFormLayout.ItemRole.FieldRole,
self.combo_speakerList)
        self.label_question                                    =
QtWidgets.QLabel(parent=self.formLayoutWidget_2)
        self.label_question.setObjectName("label_question")
        self.formLayout_2.setWidget(3,
QtWidgets.QFormLayout.ItemRole.LabelRole, self.label_question)
        self.text_question                                     =
QtWidgets.QTextEdit(parent=self.formLayoutWidget_2)
        self.text_question.setObjectName("text_question")
        self.formLayout_2.setWidget(3,
QtWidgets.QFormLayout.ItemRole.FieldRole, self.text_question)
        self.line = QtWidgets.QFrame(parent=Form)
        self.line.setGeometry(QtCore.QRect(40, 170, 441, 20))
        self.line.setFrameShape(QtWidgets.QFrame.Shape.HLine)

self.line.setFrameShadow(QtWidgets.QFrame.Shadow.Sunken)
        self.line.setObjectName("line")
        self.line_2 = QtWidgets.QFrame(parent=Form)
        self.line_2.setGeometry(QtCore.QRect(500, 10, 20, 391))

self.line_2.setFrameShape(QtWidgets.QFrame.Shape.VLine)

self.line_2.setFrameShadow(QtWidgets.QFrame.Shadow.Sunken)
        self.line_2.setObjectName("line_2")
        self.label_record = QtWidgets.QLabel(parent=Form)
        self.label_record.setGeometry(QtCore.QRect(640,    290,
201, 31))

self.label_record.setAlignment(QtCore.Qt.AlignmentFlag.AlignCe
nter)
        self.label_record.setObjectName("label_record")
```

```
        self.button_back = QtWidgets.QPushButton(parent=Form)
        self.button_back.setGeometry(QtCore.QRect(40, 20, 101,
51))
        self.button_back.setObjectName("button_back")
        self.layoutWidget = QtWidgets.QWidget(parent=Form)
        self.layoutWidget.setGeometry(QtCore.QRect(40,     110,
441, 61))
        self.layoutWidget.setObjectName("layoutWidget")
        self.verticalLayout                                    =
QtWidgets.QVBoxLayout(self.layoutWidget)
        self.verticalLayout.setContentsMargins(0, 0, 0, 0)
        self.verticalLayout.setObjectName("verticalLayout")
        self.label_chooseEvent                                 =
QtWidgets.QLabel(parent=self.layoutWidget)

self.label_chooseEvent.setObjectName("label_chooseEvent")
        self.verticalLayout.addWidget(self.label_chooseEvent)
        self.combo_eventList                                   =
QtWidgets.QComboBox(parent=self.layoutWidget)
        self.combo_eventList.setObjectName("combo_eventList")
        self.verticalLayout.addWidget(self.combo_eventList)
        self.button_toggleLang                                 =
QtWidgets.QPushButton(parent=Form)
        self.button_toggleLang.setGeometry(QtCore.QRect(870,
290, 80, 80))

self.button_toggleLang.setStyleSheet("QButton#button_togglelan
g{\n"
"    \n"
"    font: 22pt \"Algerian\";\n"
"}")
        self.button_toggleLang.setCheckable(True)
        self.button_toggleLang.setChecked(True)

self.button_toggleLang.setObjectName("button_toggleLang")
```

```
        self.retranslateUi(Form)
        QtCore.QMetaObject.connectSlotsByName(Form)

    def retranslateUi(self, Form):
        _translate = QtCore.QCoreApplication.translate
        Form.setWindowTitle(_translate("Form", "Form"))
        self.label_session.setText(_translate("Form",  "Session
Title"))
        self.label_date.setText(_translate("Form",     "Session
Date"))
        self.label_speakers.setText(_translate("Form",
"Speaker"))
        self.label_question.setText(_translate("Form",
"Question"))
        self.label_record.setText(_translate("Form", "Press to
Record"))
        self.button_back.setText(_translate("Form", "Back"))
        self.label_chooseEvent.setText(_translate("Form",
"Choose Event"))
        self.button_toggleLang.setText(_translate("Form",
"ID"))


if __name__ == "__main__":
    import sys
    app = QtWidgets.QApplication(sys.argv)
    Form = QtWidgets.QWidget()
    ui = Ui_Form()
    ui.setupUi(Form)
    Form.show()
    sys.exit(app.exec())
```

Class `ListenWindow` yang ada di app.py mengimplementasikan listenwindow.py dan menghubungkan fungsi-fungsinya dengan elemen-elemen UI.

Segmen Kode 4.24 Class ListenWindow

```
class ListenWindow(qtw.QWidget):
    def __init__(self, mainwindow):
        super().__init__()

        # the mainwindow
        self.mainwindow = mainwindow

        # set stuff here
        self.ui = lw.Ui_Form()
        self.ui.setupUi(self)
        # whosoever has ears for hearing, let him hear!
        self.setWindowTitle("qui habet aurem audendi, audiat!")

self.setWindowIcon(qtg.QIcon("asset/images/Solaire.png"))
        self.eventID = 0
        self.speakerID = 0
        self.eventList = cursor.list_events()
        self.speakerList = cursor.list_speakers()
        self.LoadComboBox(self.ui.combo_eventList)
        self.LoadComboBox(self.ui.combo_speakerList)
        self.msgBox = qtw.QMessageBox()

self.msgBox.setStandardButtons(qtw.QMessageBox.StandardButton.
Ok)

self.msgBox.setWindowIcon(qtg.QIcon("asset/images/Solaire.png"
))

self.ui.button_record.setIcon(qtg.QIcon("asset/images/mic.png"
))
        self.ui.button_toggleLang.setText("ID")

        # connect stuff here
        self.ui.button_back.clicked.connect(self.GoBack)
```

```
self.ui.button_record.clicked.connect(self.ToggleRecord)

self.ui.combo_eventList.currentIndexChanged.connect(self.Chang
eEvent)
        self.ui.combo_speakerList.currentIndexChanged.connect(
            self.ChangeSpeaker)

self.ui.button_toggleLang.clicked.connect(self.ToggleLang)

    def GoBack(self):
        self.hide()
        self.mainwindow.show()

    def ToggleRecord(self):
        if self.ValidateRecord():
            if self.ui.button_record.isChecked():
                # file path
                filePath                                        =
"records/event{}/{}.wav".format(self.ui.combo_eventList.curren
tData(
                ),
self.ui.combo_speakerList.currentText().split("    |")[0]    +
dt.now().strftime("%d%m%Y%H%M%S"))
                # begin record thread
                self.ui.rt = RecorderThread(filePath)
                self.ui.rt.start()
                # change label
                self.ui.label_record.setText("Recording...")
                self.ui.button_toggleLang.setDisabled(
                    True)  # disable toggle language
            else:
                # save in database

self.ui.rt.toggle_signal.connect(self.SaveRecording)
```

```
                # stop thread
                self.ui.rt.stop()
                # change label
                self.ui.label_record.setText("Press to Record")

                # success
                self.MessageSuccess("Recording finished.")
                self.ui.button_toggleLang.setDisabled(
                    False)  # re-enable toggle language
        else:
            self.MessageFail("Fill the speaker and event data
first.")
            self.ui.button_record.setChecked(False)

    def ToggleLang(self):
        sender = self.sender()
        if sender.isChecked():
            sender.setText("ID")
        else:
            sender.setText("EN")

    def SaveRecording(self, fileName):

cursor.create_record_audio(self.ui.combo_eventList.currentData
(
        ),             self.ui.combo_speakerList.currentData(),
self.ui.text_question.toPlainText(),                  fileName,
self.ui.button_toggleLang.text())

    def LoadComboBox(self, comboBox):
        dataList = []
        if comboBox.objectName() == "combo_eventList":
            comboBox.setPlaceholderText("Select Event")
            dataList = self.eventList
```

```
        elif comboBox.objectName() == "combo_speakerList":
            comboBox.setPlaceholderText("Select Speaker")
            dataList = self.speakerList

        for item in dataList:
            if comboBox.objectName() == "combo_eventList":
                comboBox.addItem(item[1], item[0])
            elif comboBox.objectName() == "combo_speakerList":
                comboBox.addItem("{}    |    {}".format(item[2],
item[1]), item[0])

    def ChangeEvent(self):
        self.eventID = self.ui.combo_eventList.itemData(
            self.ui.combo_eventList.currentIndex())
        event = cursor.get_event("id", self.eventID)
        self.ui.line_title.setText(event[1])
        self.ui.line_date.setText(event[2])

    def ChangeSpeaker(self):
        self.speakerID = self.ui.combo_speakerList.itemData(
            self.ui.combo_speakerList.currentIndex())

    def ValidateRecord(self):
        if self.eventID > 0 and self.speakerID > 0:
            return True
        return False

    def MessageSuccess(self, txt):
        # success
        self.msgBox.setWindowTitle("Good Job!")
        self.msgBox.setIcon(qtw.QMessageBox.Icon.Information)
        self.msgBox.setText("You dun did it\n{}".format(txt))
        self.msgBox.show()

    def MessageFail(self, txt):
```

```
        self.msgBox.setWindowTitle("What the hell, oh my god,
no way")
        self.msgBox.setIcon(qtw.QMessageBox.Icon.Warning)
        self.msgBox.setText("You dun goofed\n{}".format(txt))
        self.msgBox.show()
```

Berikut tabel fungsi-fungsi yang ada dalam class `ListenWindow` dan fungsinya.

Tabel 4.4 Mapping fungsi class ListenWindow

Fungsi	Input	Keterangan
`ToggleRecord()`	-	Memulai atau menghentikan rekaman. Jika memulai rekaman, program akan membuat sebuah *file* dalam direktori sesi diskusi untuk memuat data suara yang sedang direkam. Setelah itu, program akan memulai *thread* `RecorderThread` baru untuk merekam suara yang berjalan paralel dengan GUI program. Jika menghentikan rekaman, thread perekam suara akan mengirimkan sinyal berhenti pada program utama, melalui `self.SaveRecording(self, fileName:str)`. Rekor data rekaman akan disimpan dalam *database* dengan memperhatikan pilihan sesi dan pembicara yang diatur lewat GUI program.
`ToggleLang()`	-	Mengatur keterangan bahasa yang akan digunakan dalam proses *transcribing*. Pilihan “EN” berarti

		file akan ditranskripsikan dalam Bahasa Inggris, sedangkan pilihan "ID" berarti *file* akan ditranskripsikan dalam Bahasa Indonesia, lalu diterjemahkan dalam Bahasa Inggris.
`SaveRecording()`	*File path* tujuan dalam bentuk *string*.	Fungsi yang dipanggil ketika proses rekaman yang *asynchronous* dihentikan. Setelah rekaman selesai, data rekaman akan ditulis dalam *file path* yang ditentukan, lalu rekor data akan disimpan dalam *database* oleh obyek `DatabaseHandler`.

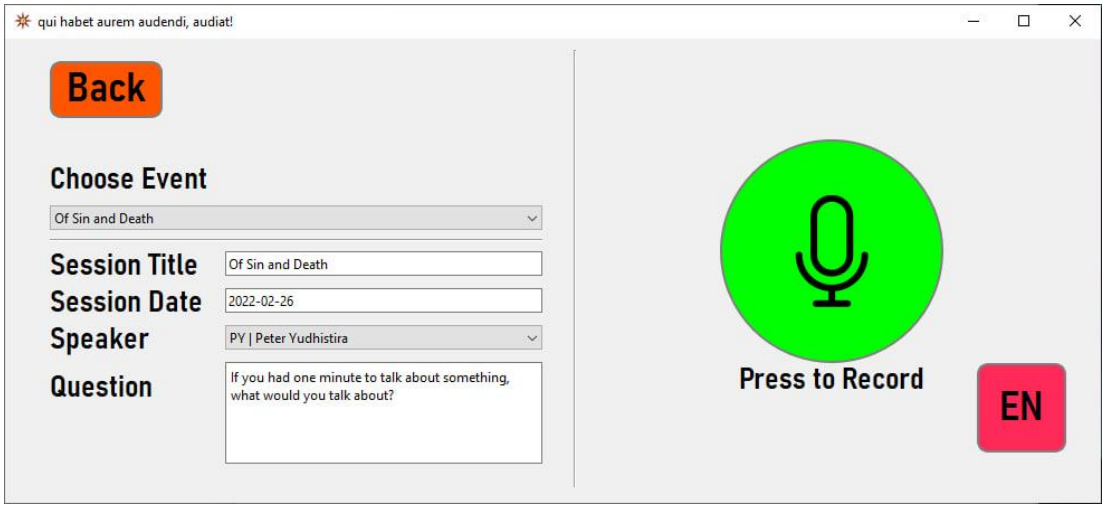

Gambar 4.8 ListenWindow dengan data sesi, pembicara, dan pertanyaan yang sudah diisi

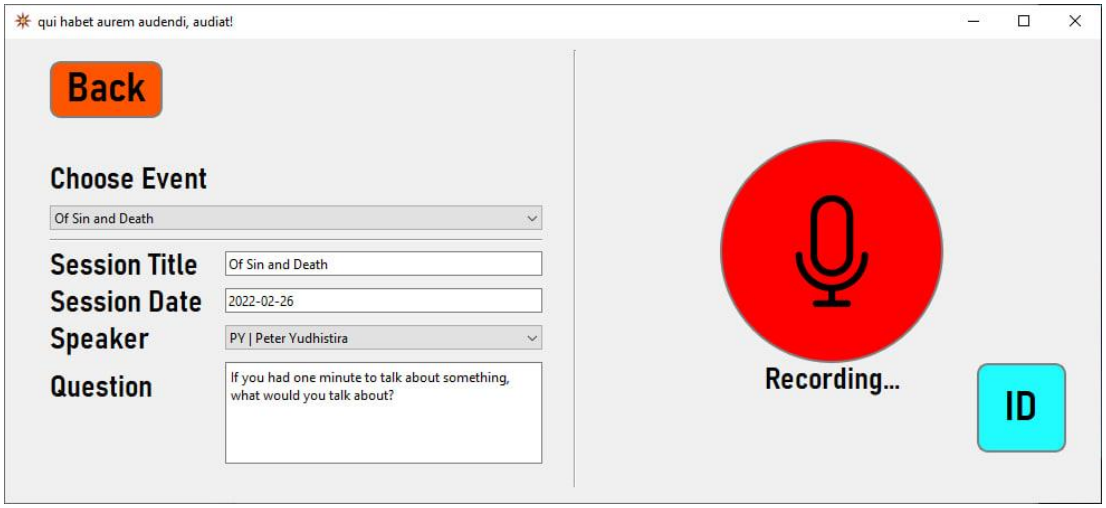

Gambar 4.9 ListenWindow dalam proses rekaman menggunakan pilihan Bahasa Indonesia

4.3.2.3. ProcessWindow

ProcessWindow adalah sebuah *interface* dimana pengguna bisa melihat rekor-rekor data yang telah direkam dalam sebuah sesi. Pada *interface* ini terdapat pilihan untuk melakukan *playback* rekor data audio, melakukan proses *transcribing* atas semua data audio dalam sebuah sesi, dan melakukan deteksi anomali dengan parameter-parameter yang ada. Pilihan "Nerd Mode" diadakan untuk kepentingan penelitian, agar memudahkan penggantian kombinasi parameter untuk mendeteksi anomali sesuai keinginan. Jika pilihan "Nerd Mode" dinonaktifkan, deteksi anomali dilakukan dengan parameter *default* yang akan ditentukan dalam akhir penelitian.

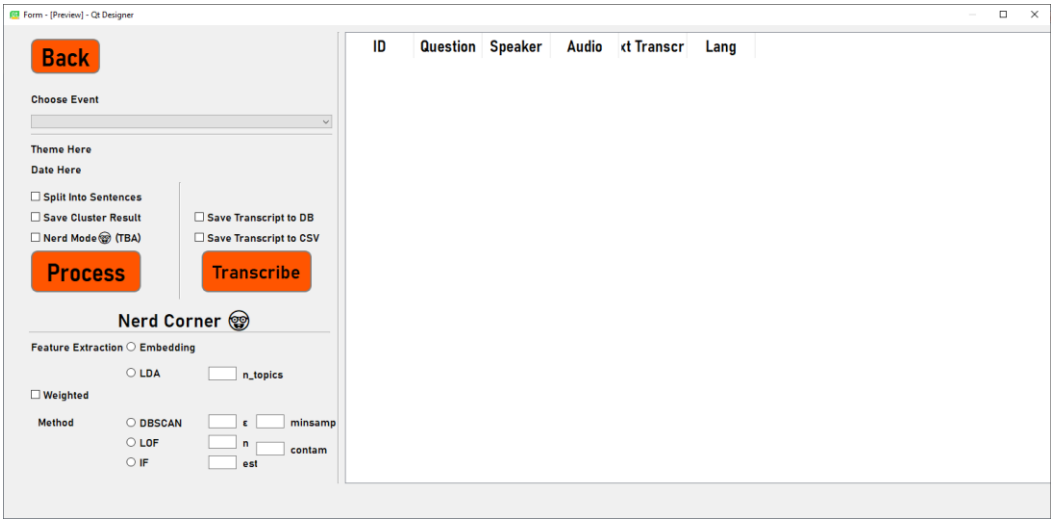

Gambar 4.10 Desain ProcessWindow dalam Qt Designer

File ListenWindow.ui yang dihasilkan dikonversi menjadi code dalam bahasa Python dengan perintah *command line* berikut ini :

Segmen Kode 4.25 Konversi ProcessWindow.ui ke processwindow.py

```
pyuic6 ui/ProcessWindow.ui -x -o objects/processwindow.py
```

```
# Form implementation generated from reading ui file
'ui/ProcessWindow.ui'
#
# Created by: PyQt6 UI code generator 6.5.0
#
# WARNING: Any manual changes made to this file will be lost
when pyuic6 is
# run again.  Do not edit this file unless you know what you are
doing.


from PyQt6 import QtCore, QtGui, QtWidgets


class Ui_Form(object):
    def setupUi(self, Form):
        Form.setObjectName("Form")
        Form.resize(1636, 707)
        Form.setStyleSheet("QLabel#label_title,
#label_subtitle{ \n"
"    \n"
"    font: 63 28pt \"Bahnschrift SemiBold SemiConden\";\n"
"    color:rgb(255, 85, 0);\n"
"}\n"
"\n"
"QPushButton{\n"
"    font: 63 28pt \"Bahnschrift SemiBold SemiConden\";\n"
"    background:rgb(255, 85, 0);\n"
"    border: 2px solid gray;\n"
"      border-radius: 10px;\n"
"     padding: 0 8px;\n"
"}\n"
```

```
"\n"
"QPushButton#button_addSpeaker,    QPushButton#button_addEvent,
QPushButton#button_toggle_widget{\n"
"    font: 63 20pt \"Bahnschrift SemiBold SemiConden\";\n"
"}\n"
"QPushButton:hover{\n"
"    background:rgb(255, 140, 0);\n"
"}\n"
"\n"
"QPushButton:pressed{\n"
"    background: rgb(255, 170, 0);\n"
"}\n"
"\n"
"QPushButton:disabled{\n"
"    background: rgb(150, 150, 150);\n"
"}\n"
"\n"
"QLabel{\n"
"    font: 63 16pt \"Bahnschrift SemiBold\";\n"
"}    \n"
"\n"
"QLabel{\n"
"    \n"
"    font: 63 12pt \"Bahnschrift SemiBold\";\n"
"}\n"
"\n"
"QCheckBox{\n"
"    font: 63 12pt \"Bahnschrift SemiBold\";\n"
"}\n"
"\n"
"QTableWidget{\n"
"    font: 14pt \"Bahnschrift\";\n"
"}\n"
"\n"
"QHeaderView{\n"
```

```
"    font: 63 18pt \"Bahnschrift SemiBold SemiConden\";\n"
"}\n"
"\n"
"QLabel#label_NerdMode{\n"
"    font: 63 20pt \"Bahnschrift SemiBold\";\n"
"}\n"
"\n"
"QRadioButton{\n"
"    font: 63 12pt \"Bahnschrift SemiBold\";\n"
"}")
        self.button_back = QtWidgets.QPushButton(parent=Form)
        self.button_back.setGeometry(QtCore.QRect(40, 20, 101,
51))
        self.button_back.setObjectName("button_back")
        self.layoutWidget = QtWidgets.QWidget(parent=Form)
        self.layoutWidget.setGeometry(QtCore.QRect(40, 90, 441,
61))
        self.layoutWidget.setObjectName("layoutWidget")
        self.verticalLayout                                    =
QtWidgets.QVBoxLayout(self.layoutWidget)
        self.verticalLayout.setContentsMargins(0, 0, 0, 0)
        self.verticalLayout.setObjectName("verticalLayout")
        self.label_chooseEvent                                 =
QtWidgets.QLabel(parent=self.layoutWidget)

self.label_chooseEvent.setObjectName("label_chooseEvent")
        self.verticalLayout.addWidget(self.label_chooseEvent)
        self.combo_eventList                                   =
QtWidgets.QComboBox(parent=self.layoutWidget)
        self.combo_eventList.setObjectName("combo_eventList")
        self.verticalLayout.addWidget(self.combo_eventList)
        self.line = QtWidgets.QFrame(parent=Form)
        self.line.setGeometry(QtCore.QRect(40, 150, 441, 20))
        self.line.setFrameShape(QtWidgets.QFrame.Shape.HLine)
```

```
self.line.setFrameShadow(QtWidgets.QFrame.Shadow.Sunken)
        self.line.setObjectName("line")
        self.line_2 = QtWidgets.QFrame(parent=Form)
        self.line_2.setGeometry(QtCore.QRect(480, 10, 20, 661))

self.line_2.setFrameShape(QtWidgets.QFrame.Shape.VLine)

self.line_2.setFrameShadow(QtWidgets.QFrame.Shadow.Sunken)
        self.line_2.setObjectName("line_2")
        self.table_recordData                                    =
QtWidgets.QTableWidget(parent=Form)
        self.table_recordData.setGeometry(QtCore.QRect(500,
10, 1121, 661))
        sizePolicy                                               =
QtWidgets.QSizePolicy(QtWidgets.QSizePolicy.Policy.Expanding,
QtWidgets.QSizePolicy.Policy.Expanding)
        sizePolicy.setHorizontalStretch(0)
        sizePolicy.setVerticalStretch(0)

sizePolicy.setHeightForWidth(self.table_recordData.sizePolicy(
).hasHeightForWidth())
        self.table_recordData.setSizePolicy(sizePolicy)

self.table_recordData.setObjectName("table_recordData")
        self.table_recordData.setColumnCount(6)
        self.table_recordData.setRowCount(0)
        item = QtWidgets.QTableWidgetItem()
        self.table_recordData.setHorizontalHeaderItem(0, item)
        item = QtWidgets.QTableWidgetItem()
        self.table_recordData.setHorizontalHeaderItem(1, item)
        item = QtWidgets.QTableWidgetItem()
        self.table_recordData.setHorizontalHeaderItem(2, item)
        item = QtWidgets.QTableWidgetItem()
        self.table_recordData.setHorizontalHeaderItem(3, item)
```

```
        item = QtWidgets.QTableWidgetItem()
        self.table_recordData.setHorizontalHeaderItem(4, item)
        item = QtWidgets.QTableWidgetItem()
        self.table_recordData.setHorizontalHeaderItem(5, item)
        self.label_theme = QtWidgets.QLabel(parent=Form)
        self.label_theme.setGeometry(QtCore.QRect(40, 170, 441,
21))
        self.label_theme.setObjectName("label_theme")
        self.label_date = QtWidgets.QLabel(parent=Form)
        self.label_date.setGeometry(QtCore.QRect(40, 200, 441,
21))
        self.label_date.setObjectName("label_date")
        self.button_process                                    =
QtWidgets.QPushButton(parent=Form)
        self.button_process.setGeometry(QtCore.QRect(40,   330,
161, 61))
        self.button_process.setObjectName("button_process")
        self.line_3 = QtWidgets.QFrame(parent=Form)
        self.line_3.setGeometry(QtCore.QRect(250,   230,   16,
171))

self.line_3.setFrameShape(QtWidgets.QFrame.Shape.VLine)

self.line_3.setFrameShadow(QtWidgets.QFrame.Shadow.Sunken)
        self.line_3.setObjectName("line_3")
        self.check_isSplit = QtWidgets.QCheckBox(parent=Form)
        self.check_isSplit.setGeometry(QtCore.QRect(40,    240,
181, 21))
        self.check_isSplit.setObjectName("check_isSplit")
        self.check_saveResult                                  =
QtWidgets.QCheckBox(parent=Form)
        self.check_saveResult.setGeometry(QtCore.QRect(40,
270, 181, 21))

self.check_saveResult.setObjectName("check_saveResult")
```

```
        self.check_nerdMode = QtWidgets.QCheckBox(parent=Form)
        self.check_nerdMode.setEnabled(True)
        self.check_nerdMode.setGeometry(QtCore.QRect(40,   300,
181, 21))
        self.check_nerdMode.setObjectName("check_nerdMode")
        self.button_transcribe_all                                =
QtWidgets.QPushButton(parent=Form)

self.button_transcribe_all.setGeometry(QtCore.QRect(290,   330,
161, 61))
        font = QtGui.QFont()
        font.setFamily("Bahnschrift SemiBold")
        font.setPointSize(20)
        font.setBold(False)
        font.setItalic(False)
        font.setWeight(7)
        self.button_transcribe_all.setFont(font)
        self.button_transcribe_all.setStyleSheet("font: 63 20pt
\"Bahnschrift SemiBold\";")

self.button_transcribe_all.setObjectName("button_transcribe_al
l")
        self.check_saveTranscriptToCSV                            =
QtWidgets.QCheckBox(parent=Form)

self.check_saveTranscriptToCSV.setGeometry(QtCore.QRect(280,
300, 191, 21))

self.check_saveTranscriptToCSV.setObjectName("check_saveTransc
riptToCSV")
        self.check_saveTranscriptToDatabase                       =
QtWidgets.QCheckBox(parent=Form)

self.check_saveTranscriptToDatabase.setGeometry(QtCore.QRect(2
80, 270, 191, 21))
```

```
self.check_saveTranscriptToDatabase.setObjectName("check_saveT
ranscriptToDatabase")
        self.label_NerdMode = QtWidgets.QLabel(parent=Form)
        self.label_NerdMode.setGeometry(QtCore.QRect(50,   410,
431, 41))

self.label_NerdMode.setAlignment(QtCore.Qt.AlignmentFlag.Align
Center)
        self.label_NerdMode.setObjectName("label_NerdMode")
        self.line_4 = QtWidgets.QFrame(parent=Form)
        self.line_4.setGeometry(QtCore.QRect(37, 440, 441, 20))

self.line_4.setFrameShape(QtWidgets.QFrame.Shape.HLine)

self.line_4.setFrameShadow(QtWidgets.QFrame.Shadow.Sunken)
        self.line_4.setObjectName("line_4")
        self.label_FeatureExtraction                              =
QtWidgets.QLabel(parent=Form)

self.label_FeatureExtraction.setGeometry(QtCore.QRect(40,  460,
141, 21))

self.label_FeatureExtraction.setAlignment(QtCore.Qt.AlignmentF
lag.AlignLeading|QtCore.Qt.AlignmentFlag.AlignLeft|QtCore.Qt.A
lignmentFlag.AlignVCenter)

self.label_FeatureExtraction.setObjectName("label_FeatureExtra
ction")
        self.label_Method = QtWidgets.QLabel(parent=Form)
        self.label_Method.setGeometry(QtCore.QRect(50,     570,
131, 21))

self.label_Method.setAlignment(QtCore.Qt.AlignmentFlag.AlignLe
```

```
ading|QtCore.Qt.AlignmentFlag.AlignLeft|QtCore.Qt.AlignmentFla
g.AlignVCenter)
        self.label_Method.setObjectName("label_Method")
        self.check_isWeighted                                    =
QtWidgets.QCheckBox(parent=Form)
        self.check_isWeighted.setGeometry(QtCore.QRect(40,
530, 131, 21))

self.check_isWeighted.setObjectName("check_isWeighted")
        self.line_nTopics = QtWidgets.QLineEdit(parent=Form)
        self.line_nTopics.setGeometry(QtCore.QRect(300,    500,
41, 20))
        self.line_nTopics.setObjectName("line_nTopics")
        self.line_epsilon = QtWidgets.QLineEdit(parent=Form)
        self.line_epsilon.setGeometry(QtCore.QRect(300,    570,
41, 20))
        self.line_epsilon.setObjectName("line_epsilon")
        self.line_minSamp = QtWidgets.QLineEdit(parent=Form)
        self.line_minSamp.setGeometry(QtCore.QRect(370,    570,
41, 20))
        self.line_minSamp.setObjectName("line_minSamp")
        self.label = QtWidgets.QLabel(parent=Form)
        self.label.setGeometry(QtCore.QRect(350, 500, 81, 21))
        self.label.setObjectName("label")
        self.label_2 = QtWidgets.QLabel(parent=Form)
        self.label_2.setGeometry(QtCore.QRect(350,   570,   21,
21))
        self.label_2.setObjectName("label_2")
        self.label_3 = QtWidgets.QLabel(parent=Form)
        self.label_3.setGeometry(QtCore.QRect(420,   570,   71,
21))
        self.label_3.setObjectName("label_3")
        self.verticalLayoutWidget                                =
QtWidgets.QWidget(parent=Form)
```

```
self.verticalLayoutWidget.setGeometry(QtCore.QRect(180,    450,
121, 80))

self.verticalLayoutWidget.setObjectName("verticalLayoutWidget"
)
        self.verticalLayout_2                                    =
QtWidgets.QVBoxLayout(self.verticalLayoutWidget)
        self.verticalLayout_2.setContentsMargins(0, 0, 0, 0)

self.verticalLayout_2.setObjectName("verticalLayout_2")
        self.radio_Embed                                         =
QtWidgets.QRadioButton(parent=self.verticalLayoutWidget)
        self.radio_Embed.setObjectName("radio_Embed")
        self.verticalLayout_2.addWidget(self.radio_Embed)
        self.radio_LDA                                           =
QtWidgets.QRadioButton(parent=self.verticalLayoutWidget)
        self.radio_LDA.setObjectName("radio_LDA")
        self.verticalLayout_2.addWidget(self.radio_LDA)
        self.verticalLayoutWidget_2                              =
QtWidgets.QWidget(parent=Form)

self.verticalLayoutWidget_2.setGeometry(QtCore.QRect(180,  570,
141, 83))

self.verticalLayoutWidget_2.setObjectName("verticalLayoutWidge
t_2")
        self.verticalLayout_4                                    =
QtWidgets.QVBoxLayout(self.verticalLayoutWidget_2)
        self.verticalLayout_4.setContentsMargins(0, 0, 0, 0)

self.verticalLayout_4.setObjectName("verticalLayout_4")
        self.radio_DBSCAN                                        =
QtWidgets.QRadioButton(parent=self.verticalLayoutWidget_2)
        self.radio_DBSCAN.setObjectName("radio_DBSCAN")
```

```
        self.verticalLayout_4.addWidget(self.radio_DBSCAN)
        self.radio_LOF                                          =
QtWidgets.QRadioButton(parent=self.verticalLayoutWidget_2)
        self.radio_LOF.setObjectName("radio_LOF")
        self.verticalLayout_4.addWidget(self.radio_LOF)
        self.radio_IF                                           =
QtWidgets.QRadioButton(parent=self.verticalLayoutWidget_2)
        self.radio_IF.setObjectName("radio_IF")
        self.verticalLayout_4.addWidget(self.radio_IF)
        self.line_neighbors = QtWidgets.QLineEdit(parent=Form)
        self.line_neighbors.setGeometry(QtCore.QRect(300,  600,
41, 20))
        self.line_neighbors.setObjectName("line_neighbors")
        self.line_estimators = QtWidgets.QLineEdit(parent=Form)
        self.line_estimators.setGeometry(QtCore.QRect(300,
630, 41, 20))
        self.line_estimators.setObjectName("line_estimators")
        self.label_4 = QtWidgets.QLabel(parent=Form)
        self.label_4.setGeometry(QtCore.QRect(350,   600,   16,
21))
        self.label_4.setObjectName("label_4")
        self.label_5 = QtWidgets.QLabel(parent=Form)
        self.label_5.setGeometry(QtCore.QRect(350,   630,   21,
21))
        self.label_5.setObjectName("label_5")
        self.line_contamination                                 =
QtWidgets.QLineEdit(parent=Form)
        self.line_contamination.setGeometry(QtCore.QRect(370,
610, 41, 20))

self.line_contamination.setObjectName("line_contamination")
        self.label_6 = QtWidgets.QLabel(parent=Form)
        self.label_6.setGeometry(QtCore.QRect(420,   610,   71,
21))
        self.label_6.setObjectName("label_6")
```

```
        self.retranslateUi(Form)
        QtCore.QMetaObject.connectSlotsByName(Form)

    def retranslateUi(self, Form):
        _translate = QtCore.QCoreApplication.translate
        Form.setWindowTitle(_translate("Form", "Form"))
        self.button_back.setText(_translate("Form", "Back"))
        self.label_chooseEvent.setText(_translate("Form",
"Choose Event"))
        item = self.table_recordData.horizontalHeaderItem(0)
        item.setText(_translate("Form", "ID"))
        item = self.table_recordData.horizontalHeaderItem(1)
        item.setText(_translate("Form", "Question"))
        item = self.table_recordData.horizontalHeaderItem(2)
        item.setText(_translate("Form", "Speaker"))
        item = self.table_recordData.horizontalHeaderItem(3)
        item.setText(_translate("Form", "Audio"))
        item = self.table_recordData.horizontalHeaderItem(4)
        item.setText(_translate("Form", "Text Transcript"))
        item = self.table_recordData.horizontalHeaderItem(5)
        item.setText(_translate("Form", "Lang"))
        self.label_theme.setText(_translate("Form",      "Theme
Here"))
        self.label_date.setText(_translate("Form",        "Date
Here"))
        self.button_process.setText(_translate("Form",
"Process"))
        self.check_isSplit.setText(_translate("Form",    "Split
Into Sentences"))
        self.check_saveResult.setText(_translate("Form",  "Save
Cluster Result"))
        self.check_nerdMode.setText(_translate("Form",    "Nerd
Mode🤓 (TBA)"))
```

```
        self.button_transcribe_all.setText(_translate("Form",
"Transcribe"))

self.check_saveTranscriptToCSV.setText(_translate("Form",
"Save Transcript to CSV"))

self.check_saveTranscriptToDatabase.setText(_translate("Form",
"Save Transcript to DB"))
        self.label_NerdMode.setText(_translate("Form",    "Nerd
Corner 🧐"))

self.label_FeatureExtraction.setText(_translate("Form",
"Feature Extraction"))
        self.label_Method.setText(_translate("Form",
"Method"))
        self.check_isWeighted.setText(_translate("Form",
"Weighted"))
        self.label.setText(_translate("Form", "n_topics"))
        self.label_2.setText(_translate("Form", "ε"))
        self.label_3.setText(_translate("Form", "minsamp"))
        self.radio_Embed.setText(_translate("Form",
"Embedding"))
        self.radio_LDA.setText(_translate("Form", "LDA"))
        self.radio_DBSCAN.setText(_translate("Form",
"DBSCAN"))
        self.radio_LOF.setText(_translate("Form", "LOF"))
        self.radio_IF.setText(_translate("Form", "IF"))
        self.label_4.setText(_translate("Form", "n"))
        self.label_5.setText(_translate("Form", "est"))
        self.label_6.setText(_translate("Form", "contam"))



if __name__ == "__main__":
    import sys
    app = QtWidgets.QApplication(sys.argv)
```

```
    Form = QtWidgets.QWidget()
    ui = Ui_Form()
    ui.setupUi(Form)
    Form.show()
    sys.exit(app.exec())
```

Class `ProcessWindow` yang ada di app.py mengimplementasikan processwindow.py dan menghubungkan fungsi-fungsinya dengan elemen-elemen UI.

Segmen Kode 4.26 Class ProcessWindow

```
class ProcessWindow(qtw.QWidget):
    def __init__(self, mainwindow) -> None:
        super().__init__()

        # set mainwindow
        self.mainwindow = mainwindow

        # set stuff
        self.ui = pw.Ui_Form()
        self.ui.setupUi(self)
        self.eventList = cursor.list_events()
        self.audioPlayer = qtm.QMediaPlayer()
        self.audioOutput = qtm.QAudioOutput()
        self.audioPlayer.setAudioOutput(self.audioOutput)
        self.audioOutput.setVolume(100)
        self.presentWindow = None  # Funni little workaround
        # whosoever has power over the machine, let him
discover!
        self.setWindowTitle("qui habet potentia super machina,
comperiat!")

self.setWindowIcon(qtg.QIcon("asset/images/Solaire.png"))
        self.LoadComboBox(self.ui.combo_eventList)
```

```
self.ui.check_saveTranscriptToDatabase.setChecked(True)
        # we disable this for now.

self.ui.check_saveTranscriptToDatabase.setDisabled(True)
        self.ui.button_process.setDisabled(True)  #  will  only
enable after loading a table.
        self.ui.button_transcribe_all.setDisabled(True)
        self.ui.check_nerdMode.setChecked(True)
        self.ui.featureExtractionGroup = qtw.QButtonGroup(self)

self.ui.featureExtractionGroup.addButton(self.ui.radio_Embed)

self.ui.featureExtractionGroup.addButton(self.ui.radio_LDA)
        self.ui.anomalyDetectionGroup = qtw.QButtonGroup(self)

self.ui.anomalyDetectionGroup.addButton(self.ui.radio_DBSCAN)

self.ui.anomalyDetectionGroup.addButton(self.ui.radio_LOF)

self.ui.anomalyDetectionGroup.addButton(self.ui.radio_IF)
        # for now, disable LOF and IF
        # self.ui.radio_LOF.setDisabled(True)
        # self.ui.radio_IF.setDisabled(True)
        self.msgBox = qtw.QMessageBox()

self.msgBox.setStandardButtons(qtw.QMessageBox.StandardButton.
Ok)

self.msgBox.setWindowIcon(qtg.QIcon("asset/images/Solaire.png"
))
        self.buttonPlayList = []

        # connect stuff here
        self.ui.button_back.clicked.connect(self.GoBack)
```

```
self.ui.combo_eventList.currentIndexChanged.connect(self.Chang
eEvent)
        # i forgot the existence of lambda ENTIRELY.
        self.ui.button_process.clicked.connect(
            lambda: self.StartProcessing())

self.ui.button_transcribe_all.clicked.connect(self.TranscribeA
ll)

self.ui.check_nerdMode.toggled.connect(self.ToggleNerdMode)

    def GoBack(self):
        self.hide()
        self.mainwindow.show()

    def LoadComboBox(self, comboBox):
        comboBox.setPlaceholderText("Select Event")
        for item in self.eventList:
            comboBox.addItem(item[1], item[0])

    def ChangeEvent(self):
        eventID = self.ui.combo_eventList.currentData()
        currentEvent = cursor.get_event("id", eventID)
        self.LoadTables(self.ui.table_recordData, eventID)
        self.ui.label_theme.setText(str(currentEvent[1]))
        self.ui.label_date.setText(str(currentEvent[2]))

    def LoadTables(self, table, eventID):
        # fetch data
        self.dataList = cursor.get_recordDataJoined("event_id",
eventID)
        # clear table first
        table.clearContents()
        table.setRowCount(0)
```

```
        # put in table
        for i in range(len(self.dataList)):
            table.insertRow(i)
            table.setItem(i, 0, qtw.QTableWidgetItem(
                str(self.dataList[i][0])))  # id
            table.setItem(i, 1, qtw.QTableWidgetItem(
                str(self.dataList[i][4])))  # question
            table.setItem(i, 2, qtw.QTableWidgetItem(
                str(self.dataList[i][3])))  # speaker

            # make audio button. if audio path doesn't exist,
disable it.
            self.button_play = qtw.QPushButton("▶".format(i),
self)

self.button_play.setObjectName(str(self.dataList[i][5]))
            self.button_play.setCheckable(True)
            self.button_play.clicked.connect(
                lambda                                          ch,
filePath=self.button_play.objectName():
self.TogglePlayRecord(filePath))
            if self.dataList[i][5] == "":
                self.button_play.setDisabled(True)
                self.button_play.setText("🙅")
            self.buttonPlayList.append(self.button_play)
            table.setCellWidget(i, 3, self.button_play)

            table.setItem(i, 4, qtw.QTableWidgetItem(
                str(self.dataList[i][6])))  # text
            table.setItem(i, 5, qtw.QTableWidgetItem(
                str(self.dataList[i][7])))  # language code
        # resize
        table.horizontalHeader().setSectionResizeMode(
            1, qtw.QHeaderView.ResizeMode.Stretch)
        table.horizontalHeader().setSectionResizeMode(
```

```
            4, qtw.QHeaderView.ResizeMode.Stretch)
        # do this AFTER stretching.
        self.ui.table_recordData.resizeRowsToContents()

        # enable the buttons
        self.ui.button_process.setDisabled(False)
        self.ui.button_transcribe_all.setDisabled(False)

    # toggle the params. I will surely regret this later.
    def ToggleNerdMode(self):
        sender = self.sender()
        if sender.isChecked():
            self.ui.radio_Embed.setDisabled(False)
            self.ui.radio_LDA.setDisabled(False)
            self.ui.radio_DBSCAN.setDisabled(False)
            self.ui.radio_LOF.setDisabled(False)
            self.ui.radio_IF.setDisabled(False)
            self.ui.check_isWeighted.setDisabled(False)
            self.ui.line_epsilon.setDisabled(False)
            self.ui.line_minSamp.setDisabled(False)
            self.ui.line_nTopics.setDisabled(False)
        else:
            self.ui.radio_Embed.setDisabled(True)
            self.ui.radio_LDA.setDisabled(True)
            self.ui.radio_DBSCAN.setDisabled(True)
            self.ui.radio_LOF.setDisabled(True)
            self.ui.radio_IF.setDisabled(True)
            self.ui.check_isWeighted.setDisabled(True)
            self.ui.line_epsilon.setDisabled(True)
            self.ui.line_minSamp.setDisabled(True)
            self.ui.line_nTopics.setDisabled(True)

    def StartProcessing(self):
        currentEventID = self.ui.combo_eventList.currentData()
        ad.SetDFFromDB(eventID=currentEventID,
```

```
splitBySentences=self.ui.check_isSplit.isChecked())
        # i'll implement nerd mode tonight... today.
        nerdOK = True
        if self.ui.check_nerdMode.isChecked():
            if self.ValidateNerdModeParams():
                featureExtractor                                =
self.ui.featureExtractionGroup.checkedButton().text()
                ad.SetFeatureExtractionParam("method",
featureExtractor)

                anomalyDetector                                 =
self.ui.anomalyDetectionGroup.checkedButton().text()
                ad.SetAnomalyDetectionParam("algorithm",
anomalyDetector)

                isWeighted                                      =
self.ui.check_isWeighted.isChecked()
                ad.SetFeatureExtractionParam("weighted",
isWeighted)

                if self.ui.line_epsilon.text() != '':
                    epsilon                                     =
float(self.ui.line_epsilon.text())
                    ad.SetAnomalyDetectionParam("epsilon",
epsilon)

                if self.ui.line_minSamp.text() != '':
                    minSamp = int(self.ui.line_minSamp.text())
                    ad.SetAnomalyDetectionParam("minsamp",
minSamp)

                if self.ui.line_neighbors.text() != '':
                    nNeighbors                                  =
int(self.ui.line_neighbors.text())
```

```
                    ad.SetAnomalyDetectionParam("neighbors",
nNeighbors)

                if self.ui.line_contamination.text() != '':
                    contaminationRate                          =
float(self.ui.line_contamination.text())

ad.SetAnomalyDetectionParam("contamination",
contaminationRate)

                if self.ui.line_estimators.text() != '':
                    nEstimators                                =
int(self.ui.line_estimators.text())
                    ad.SetAnomalyDetectionParam("estimators",
nEstimators)

                if self.ui.line_nTopics.text() != '':
                    LDAnTopic                                  =
int(self.ui.line_nTopics.text())
                    ad.SetFeatureExtractionParam("n_topics",
LDAnTopic)
                print(ad.FeatureExtractionParams)
                print(ad.AnomalyDetectionParams)
                myResult                                       =
ad.GetAnomalies(isReturnSeparate=False)
            else:
                nerdOK = False
        else:
            print(ad.FeatureExtractionParams)
            print(ad.AnomalyDetectionParams)
            myResult = ad.GetAnomalies(isReturnSeparate=False)
        if nerdOK:
            self.presentWindow = PresentWindow(
                myResult, self.ui.label_theme.text(), self)
            self.presentWindow.show()
```

```
    def ValidateNerdModeParams(self):
        # we will use the elimination method as we have learned
in that god-forsaken place.
        if not (self.ui.featureExtractionGroup.checkedButton()
and self.ui.anomalyDetectionGroup.checkedButton()):
            self.MessageFail("one or both of the radio button
groups are unchecked.")
            return False
        else:
            # in the case of LDA, make sure the nTopics is
filled.
            if
self.ui.featureExtractionGroup.checkedButton().text() == "LDA":
                if not self.ui.line_nTopics.text():
                    self.MessageFail("You doing LDA without the
number of topics")
                    return False
            else:
                # in the case of DBSCAN
                if
self.ui.anomalyDetectionGroup.checkedButton().text()         ==
"DBSCAN":
                    # make sure that epsilon and minsamp is
filled.
                    if not (self.ui.line_epsilon.text() and
self.ui.line_minSamp.text()):
                        self.MessageFail("You doing DBSCAN
without the epsilon and/or minsamp")
                        return False
                # in the case of LOF
                elif
self.ui.anomalyDetectionGroup.checkedButton().text() == "LOF":
                    if   not(self.ui.line_contamination.text()
and self.ui.line_neighbors.text()):
```

```
                        self.MessageFail("You doing LOF without
the contamination and/or n_neighbors")
                        return False
                # in the case of IF
                elif
self.ui.anomalyDetectionGroup.checkedButton().text() == "IF":
                    if    not(self.ui.line_contamination.text()
and self.ui.line_estimators.text()):
                        self.MessageFail("You doing IF without
the contamination and/or n_estimators")
                        return False
        return True

    def MessageFail(self, txt):
        self.msgBox.setIcon(qtw.QMessageBox.Icon.Warning)
        self.msgBox.setText("You dun goofed\n{}".format(txt))
        self.msgBox.show()

    def TranscribeAll(self):
        ttttt = []  # i am funny
        for row in range(self.ui.table_recordData.rowCount()):
            button  =  self.ui.table_recordData.cellWidget(row,
3)
            if button.objectName() != "":  # goofy condition to
stand-in for "does this object have an audio file path"
                # i'm about to get even funnier
                ttttt.append((row, button.objectName(),

self.ui.table_recordData.item(row, 5).text()))
        print("the list contains : {}".format(ttttt))
        # pass the value over to a TTTThread then let it run.
        self.tttt = TurnToTextinatorThread()
        self.tttt.setFilePath(ttttt)

self.tttt.transcribe_signal.connect(self.GetTranscript)
```

```
        self.tttt.start()
        # to prevent unwanted consequences...
        self.ui.button_back.setDisabled(True)
        self.ui.button_process.setDisabled(True)
        self.ui.button_transcribe_all.setDisabled(True)

    # TranscribeAll's thread will run this after transcription
is finished.
    def GetTranscript(self, transcriptResult: list):
        print("im here now??")
        print(transcriptResult)
        # display it and write to DB and/or CSV if needed.
        for row in range(len(transcriptResult)):
            self.ui.table_recordData.setItem(
                int(transcriptResult[row][0]),                4,
qtw.QTableWidgetItem(transcriptResult[row][2]))
            if
self.ui.check_saveTranscriptToDatabase.isChecked():
                print("we are updating the db with : {} ||
{}".format(
                    self.ui.table_recordData.item(row,
0).text(), transcriptResult[row][2]))

cursor.update_recordData_text(ID=int(self.ui.table_recordData.
item(transcriptResult[row][0], 0).text()), text=str(
                    transcriptResult[row][2]))  # at times like
this i miss GORM.

        self.ui.table_recordData.resizeRowsToContents()

self.ui.table_recordData.horizontalHeader().setSectionResizeMo
de(
            1, qtw.QHeaderView.ResizeMode.Stretch)
```

```
self.ui.table_recordData.horizontalHeader().setSectionResizeMo
de(
            4, qtw.QHeaderView.ResizeMode.Stretch)
        self.ui.button_back.setDisabled(False)  # unfreeze
        self.ui.button_process.setDisabled(False)
        self.ui.button_transcribe_all.setDisabled(False)

    def TogglePlayRecord(self, filePath):
        sender = self.sender()
        if sender.isChecked():

self.audioPlayer.setSource(qtc.QUrl.fromLocalFile(filePath))
            self.audioPlayer.play()
            sender.setText("■")
        else:
            self.audioPlayer.stop()
            sender.setText("▶")

    def closeEvent(self, event):
        if self.presentWindow:
            self.presentWindow.close()
```

Berikut tabel yang berisi fungsi-fungsi yang ada dalam Class ProcessWindow beserta fungsinya.

Tabel 4.5 Mapping fungsi class ProcessWindow

Fungsi	Input	Keterangan
`GoBack()`	-	Dihubungkan dengan tombol "Back". Berfungsi untuk kembali ke MainMenuWindow.
`LoadComboBox()`	Obyek `self.QComboBox`	Mengambil data *event* dari *database* dan

		memasukkannya dalam *combo box* yang bisa dipilih oleh pengguna.
`LoadTables()`	Obyek `self.QTableView`, ID *event* yang didapatkan dari *combo box* berupa *integer*.	Mengambil ID yang didapatkan dari *combo box*, dan memerintahkan `DatabaseHandler` untuk melakukan *query* dan mendapatkan tabel yang berisi rekor-rekor data dalam sesi yang ditentukan oleh *event ID*.
`ChangeEvent()`	-	Mengganti data *title* dan *date* sesi yang sedang dipilih.
`ToggleNerdMode()`	-	Menyalakan atau mematikan parameter-parameter *Nerd Mode*.
`StartProcessing()`	-	Memulai proses *anomaly detection* pada rekor-rekor data yang dipilih, dengan komponen *object* dari *class* `AnomalyDetector` yang telah dibuat. Jika pilihan "Nerd Mode" aktif, parameter-parameter yang diisi dalam bagian "Nerd Corner" akan dijadikan parameter *anomaly detection*. Jika pilihan tidak aktif, akan dilakukan *anomaly detection* dengan parameter default.

`ValidateNerdModeParams()`	-	Melakukan validasi pada parameter-parameter yang ada di "Nerd Corner" untuk keperluan penelitian.
`MessageFail()`	*error message* dalam bentuk string	Menunjukkan error message ketika `ValidateNerdModeParams()` menemukan sebuah error.
`TranscribeAll()`	-	Melakukan proses transcribing dan translating pada seluruh rekor data yang dipilih. Proses *transcribing* dijalankan secara *asynchronous* oleh obyek TurnToTextinatorThread dan akan memanggil fungsi self.GetTranscript(self, transcriptResult:list) ketika proses *transcribing* selesai.
`GetTranscript()`	Hasil dari transkripsi yang dilakukan oleh obyek `TurnToTextinatorThread`, berupa *list of strings*.	Fungsi yang dipanggil ketika proses *transcribing* selesai. Melakukan *update* pada setiap rekor data untuk mengisi transkrip teks-nya, dan memasukkan data transkrip teks dalam tabel yang sudah disediakan.
`TogglePlayRecord()`	*File path* dari transkrip suara yang akan dimainkan atau dihentikan.	Setiap rekor data pada tabel dihubungkan pada fungsi ini. Ketika tombol dalam sebuah baris tabel ditekan, program

		akan melakukan *playback file* rekaman yang terkait.
`closeEvent()`	-	Menutup *window* ini jika *PresentWindow* ditutup, untuk menghindari desinkronisasi.

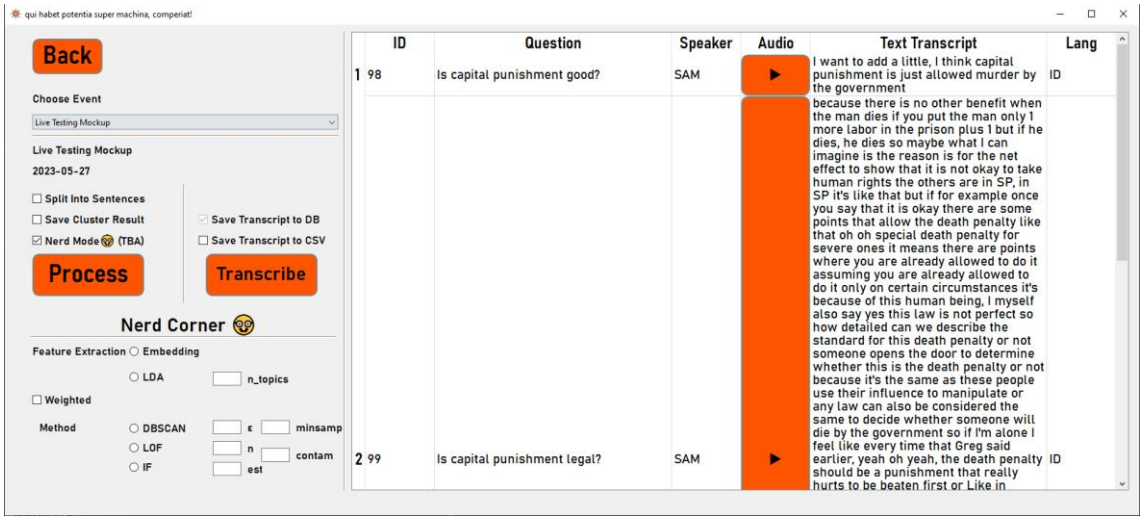

Gambar 4.11 PresentWindow yang sedang menampilkan data sebuah sesi

4.3.2.4. PresentWindow

PresentWindow adalah Window dimana hasil *anomaly detection* ditampilkan. Pengguna dapat melihat hasil proses *anomaly detection* dengan parameter yang ditentukan, berupa tabel rekor data. Rekor data yang terdeteksi sebagai anomali akan diberikan warna merah. Terdapat juga fungsi untuk menyimpan hasil deteksi anomali ke dalam sebuah *file*.

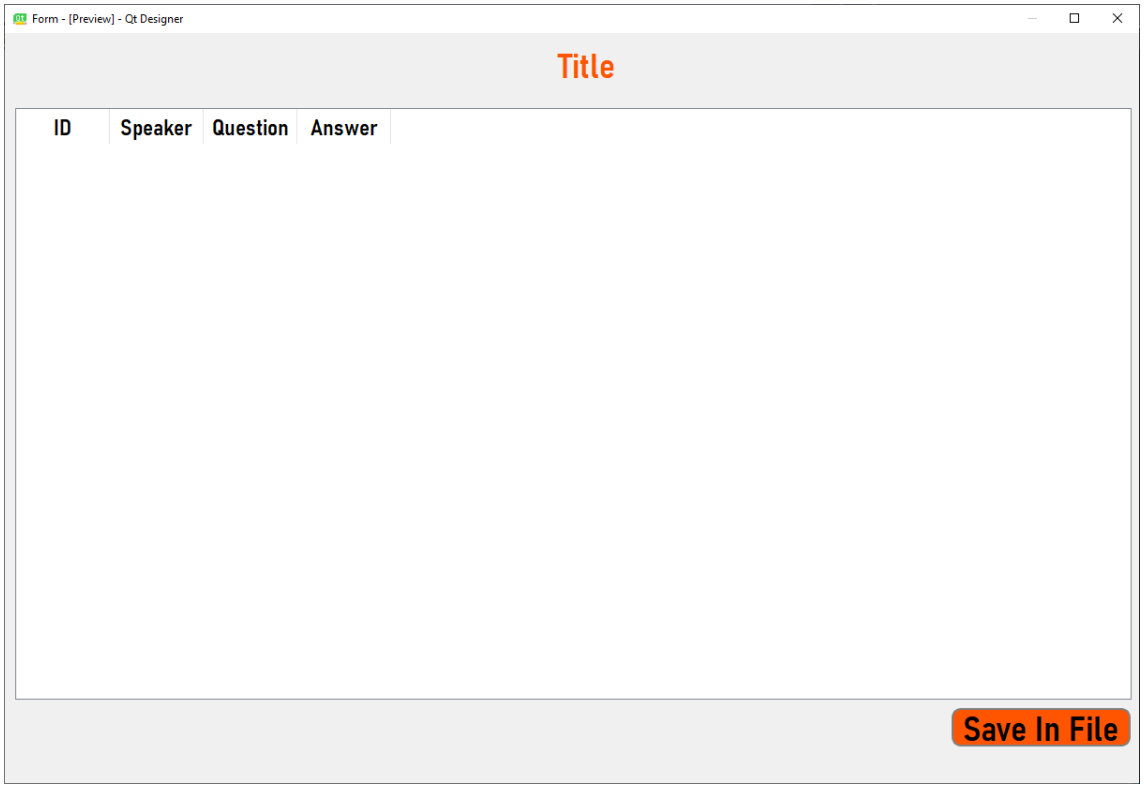

Gambar 4.12 Desain PresentWindow pada Qt Designer

File PresentWindow.ui yang dihasilkan dikonversi menjadi code dalam bahasa Python dengan perintah *command line* berikut ini :

Segmen Kode 4.27 Konversi PresentWindow.ui ke presentwindow.py

```
pyuic6 ui/PresentWindow.ui -x -o objects/presentwindow.py
```

Segmen Kode 4.28 presentwindow.py

```
# Form implementation generated from reading ui file
'ui/PresentWindow.ui'
#
# Created by: PyQt6 UI code generator 6.5.0
#
# WARNING: Any manual changes made to this file will be lost
when pyuic6 is
# run again.  Do not edit this file unless you know what you are
doing.
```

```
from PyQt6 import QtCore, QtGui, QtWidgets



class Ui_Form(object):
    def setupUi(self, Form):
        Form.setObjectName("Form")
        Form.resize(1210, 800)
        Form.setStyleSheet("QLabel#label_title,
#label_subtitle{ \n"
"    \n"
"    font: 63 28pt \"Bahnschrift SemiBold SemiConden\";\n"
"    color:rgb(255, 85, 0);\n"
"}\n"
"\n"
"QPushButton{\n"
"    font: 63 28pt \"Bahnschrift SemiBold SemiConden\";\n"
"    background:rgb(255, 85, 0);\n"
"    border: 2px solid gray;\n"
"      border-radius: 10px;\n"
"     padding: 0 8px;\n"
"}\n"
"\n"
"QPushButton#button_addSpeaker,    QPushButton#button_addEvent,
QPushButton#button_toggle_widget{\n"
"    font: 63 20pt \"Bahnschrift SemiBold SemiConden\";\n"
"}\n"
"QPushButton:hover{\n"
"    background:rgb(255, 140, 0);\n"
"}\n"
"\n"
"QPushButton:pressed{\n"
"    background: rgb(255, 170, 0);\n"
"}\n"
"\n"
"QPushButton:disabled{\n"
```

```
"    background: rgb(150, 150, 150);\n"
"}\n"
"\n"
"QLabel{\n"
"    font: 63 16pt \"Bahnschrift SemiBold\";\n"
"}    \n"
"\n"
"QLabel{\n"
"    \n"
"    font: 63 12pt \"Bahnschrift SemiBold\";\n"
"}\n"
"\n"
"QCheckBox{\n"
"    font: 63 12pt \"Bahnschrift SemiBold\";\n"
"}\n"
"\n"
"QTableWidget{\n"
"    font: 14pt \"Bahnschrift\";\n"
"}\n"
"\n"
"QHeaderView{\n"
"    font: 63 18pt \"Bahnschrift SemiBold SemiConden\";\n"
"}")
        self.button_saveInFile                                    =
QtWidgets.QPushButton(parent=Form)
        self.button_saveInFile.setGeometry(QtCore.QRect(1010,
720, 191, 41))

self.button_saveInFile.setObjectName("button_saveInFile")
        self.label_title = QtWidgets.QLabel(parent=Form)
        self.label_title.setGeometry(QtCore.QRect(21, 11, 1200,
45))
        sizePolicy                                                =
QtWidgets.QSizePolicy(QtWidgets.QSizePolicy.Policy.Preferred,
QtWidgets.QSizePolicy.Policy.Minimum)
```

```
        sizePolicy.setHorizontalStretch(0)
        sizePolicy.setVerticalStretch(0)

sizePolicy.setHeightForWidth(self.label_title.sizePolicy().has
HeightForWidth())
        self.label_title.setSizePolicy(sizePolicy)

self.label_title.setAlignment(QtCore.Qt.AlignmentFlag.AlignCen
ter)
        self.label_title.setObjectName("label_title")
        self.tableWidget = QtWidgets.QTableWidget(parent=Form)
        self.tableWidget.setGeometry(QtCore.QRect(11, 80, 1191,
631))
        sizePolicy                                          =
QtWidgets.QSizePolicy(QtWidgets.QSizePolicy.Policy.Minimum,
QtWidgets.QSizePolicy.Policy.Minimum)
        sizePolicy.setHorizontalStretch(0)
        sizePolicy.setVerticalStretch(0)

sizePolicy.setHeightForWidth(self.tableWidget.sizePolicy().has
HeightForWidth())
        self.tableWidget.setSizePolicy(sizePolicy)
        self.tableWidget.setObjectName("tableWidget")
        self.tableWidget.setColumnCount(4)
        self.tableWidget.setRowCount(0)
        item = QtWidgets.QTableWidgetItem()
        self.tableWidget.setHorizontalHeaderItem(0, item)
        item = QtWidgets.QTableWidgetItem()
        self.tableWidget.setHorizontalHeaderItem(1, item)
        item = QtWidgets.QTableWidgetItem()
        self.tableWidget.setHorizontalHeaderItem(2, item)
        item = QtWidgets.QTableWidgetItem()
        self.tableWidget.setHorizontalHeaderItem(3, item)

        self.retranslateUi(Form)
```

```
        QtCore.QMetaObject.connectSlotsByName(Form)

    def retranslateUi(self, Form):
        _translate = QtCore.QCoreApplication.translate
        Form.setWindowTitle(_translate("Form", "Form"))
        self.button_saveInFile.setText(_translate("Form",
"Save In File"))
        self.label_title.setText(_translate("Form", "Title"))
        item = self.tableWidget.horizontalHeaderItem(0)
        item.setText(_translate("Form", "ID"))
        item = self.tableWidget.horizontalHeaderItem(1)
        item.setText(_translate("Form", "Speaker"))
        item = self.tableWidget.horizontalHeaderItem(2)
        item.setText(_translate("Form", "Question"))
        item = self.tableWidget.horizontalHeaderItem(3)
        item.setText(_translate("Form", "Answer"))


if __name__ == "__main__":
    import sys
    app = QtWidgets.QApplication(sys.argv)
    Form = QtWidgets.QWidget()
    ui = Ui_Form()
    ui.setupUi(Form)
    Form.show()
    sys.exit(app.exec())
```

Class `PresentWindow` pada app.py merupakan *inheritance* dari *file* presentwindow.py, dimana dibuat fungsi-fungsi yang berinteraksi dengan elemen-elemen GUI.

Segmen Kode 4.29 Class PresentWindow

```
class PresentWindow(qtw.QWidget):
    def __init__(self, df: db.pd.DataFrame, eventTitle: str,
processWindow: ProcessWindow) -> None:
        super().__init__()
        # the processwindow here
```

```
        self.processWindow = processWindow

        # set stuff here
        self.ui = prw.Ui_Form()
        self.ui.setupUi(self)
        self.df = df
        self.ui.label_title.setText(eventTitle)

self.setWindowIcon(qtg.QIcon("asset/images/Solaire.png"))
        self.setWindowTitle("Qui    habet    oculi    vidiendi,
videat!")
        # connect stuff here
        self.LoadTable(self.df)

self.ui.button_saveInFile.clicked.connect(self.SaveInFile)

    # functions
    def SaveInFile(self):
        print("saving to file.")

    def LoadTable(self, df: db.pd.DataFrame):

self.ui.tableWidget.verticalScrollBar().setSingleStep(1)
        self.ui.tableWidget.setRowCount(0)
        for i in range(len(self.df.index)):
            self.ui.tableWidget.insertRow(i)
            self.ui.tableWidget.setItem(
                i,                                              0,
qtw.QTableWidgetItem(str(self.df.loc[i]["id"])))
            self.ui.tableWidget.setItem(
                i,                                              1,
qtw.QTableWidgetItem(str(self.df.loc[i]["speaker"])))
            self.ui.tableWidget.setItem(
                i,                                              2,
qtw.QTableWidgetItem(str(self.df.loc[i]["question"])))
```

```
            self.ui.tableWidget.setItem(
                i,                                              3,
qtw.QTableWidgetItem(str(self.df.loc[i]["answer"])))
            # if outlier, color red
            if self.df.loc[i]["Cluster Assignment"] == -1:
                for                     j                       in
range(self.ui.tableWidget.columnCount()):
                    self.ui.tableWidget.item(i,
j).setBackground(
                        qtg.QColor(232, 52, 39, 255))
        # resize

self.ui.tableWidget.horizontalHeader().setSectionResizeMode(
            3, qtw.QHeaderView.ResizeMode.Stretch)

self.ui.tableWidget.horizontalHeader().setSectionResizeMode(
            2, qtw.QHeaderView.ResizeMode.Stretch)
        self.ui.tableWidget.resizeRowsToContents()   # do this
AFTER stretching.
        # do this AFTER stretching.
        self.ui.tableWidget.resizeColumnsToContents()
        # fix the scrollbar
        self.ui.tableWidget.setVerticalScrollMode(
            qtw.QAbstractItemView.ScrollMode.ScrollPerPixel)

self.ui.tableWidget.verticalScrollBar().setSingleStep(5)
        # self.ui.tableWidget()
```

Berikut tabel fungsi-fungsi yang ada dalam class `PresentWindow` dan fungsinya.

Tabel 4.6 Mapping fungsi class PresentWindow

Fungsi	Input	Keterangan
`SaveInFile()`	-	Menyimpan data *outlier* dalam sebuah *file* CSV.

`LoadTable()`	Rekor data dan keterangan anomalinya dalam bentuk `DataFrame`.	Menyajikan data dalam tabel yang telah disediakan. Rekor data yang menjadi anomali diberi warna merah.

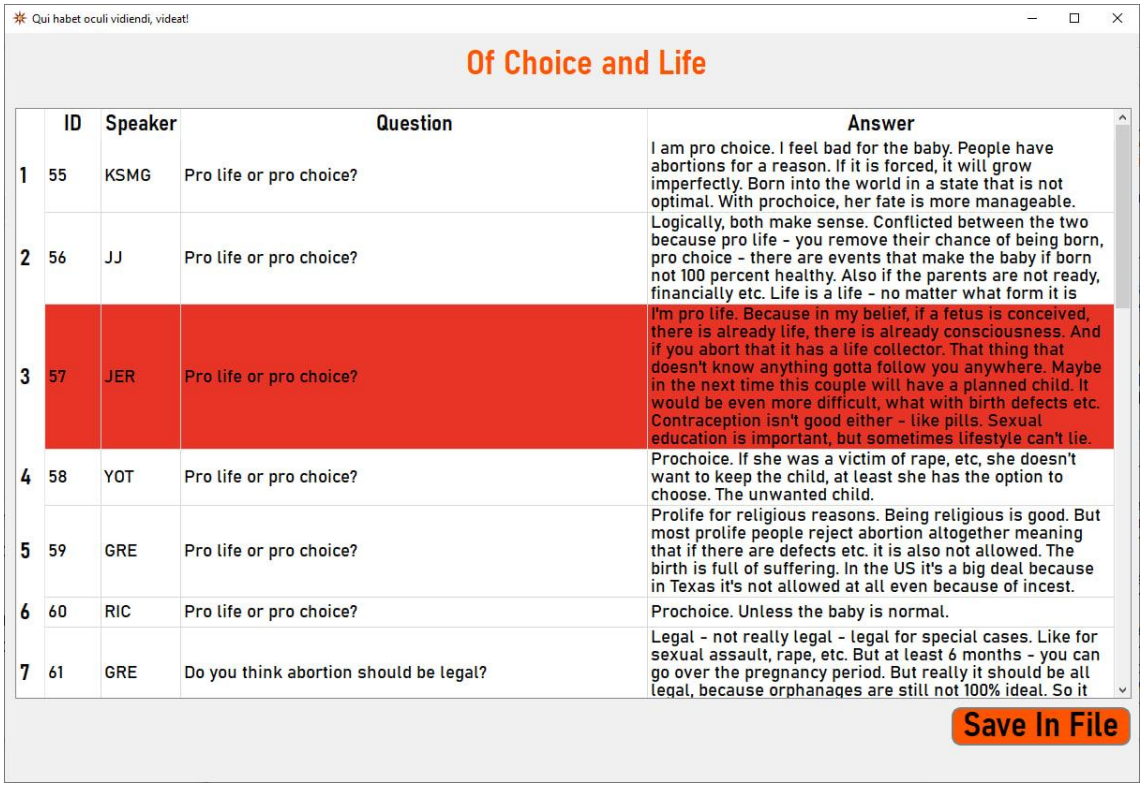

Gambar 4.13 Tampilan PresentWindow dengan satu *outlier* dalam data (merah)

4.3.3. Skema Database

Untuk menyimpan data rekaman, pembicara, dan sesi diskusi, dibuat skema *database* berikut:

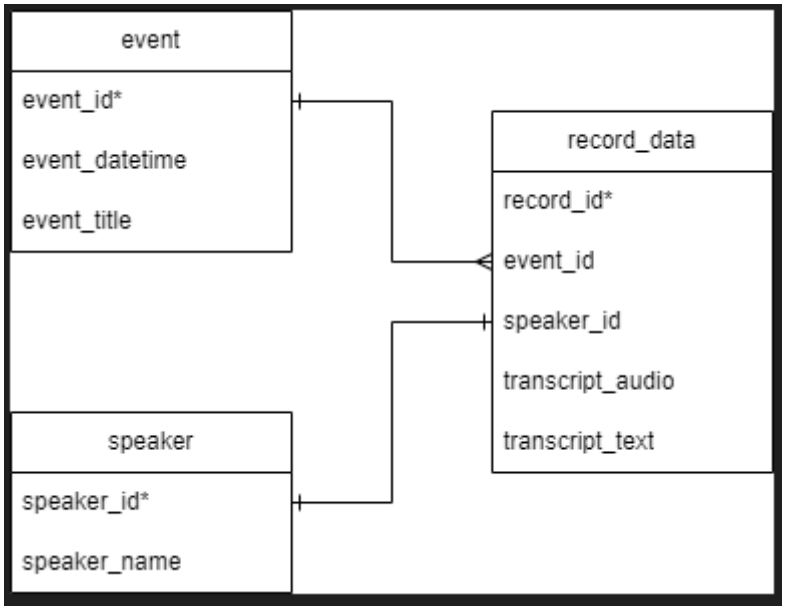

Gambar 4.14 Skema *database* untuk program

Skema *database* ini digunakan baik dalam proses eksperimen maupun program. *Database* dibuat dengan `sqlite3`, *library* Python yang memungkinkan koneksi dan operasi-operasi data dengan database SQLite. Untuk kepentingan eksperimen dan program, dibuat sebuah *class* untuk *database handling*, yang dinamakan `DatabaseHandler`. *Class* ini dimuat dalam *file* db.py.

Segmen Kode 4.30 Class DatabaseHandler dalam file db.py

```
import sqlite3
import pandas as pd
import os


class DatabaseHandler():
    def __init__(self, dbName, keepSchema: bool = True):
        self.cursor = sqlite3.connect(dbName)
        if not keepSchema:
            print('ya schema empty, yeet')
            self.create_tables()

    # create
    def create_tables(self):
        self.cursor.execute("""
```

```
            CREATE TABLE IF NOT EXISTS speakers (
                id INTEGER PRIMARY KEY AUTOINCREMENT,
                name TEXT NOT NULL,
                code TEXT NOT NULL
            );
        """)

        self.cursor.execute("""
                CREATE TABLE IF NOT EXISTS events (
                id INTEGER PRIMARY KEY AUTOINCREMENT,
                title TEXT NOT NULL,
                datetime TEXT NOT NULL
            );
        """)
        # self.cursor.execute("DROP TABLE record_data") # the
sacred seal of the nine tails. Do not open
        self.cursor.execute("""
                CREATE TABLE IF NOT EXISTS record_data (
                id INTEGER PRIMARY KEY AUTOINCREMENT,
                event_id INTEGER,
                speaker_id INTEGER,
                question_text NOT NULL,
                transcript_audio TEXT NOT NULL,
                transcript_text TEXT NOT NULL,
                transcribe_lang TEXT NOT NULL
            );
        """)

    def create_speaker(self, speakerName, speakerCode):
        self.cursor.execute("""
                INSERT INTO speakers (name, code)
                VALUES (?, ?)
        """, (speakerName, speakerCode))
        self.cursor.commit()
```

```
    def create_event(self, eventTitle, eventDate):
        id = self.cursor.execute("""
                INSERT INTO events (title, datetime)
                VALUES (?, ?)
        """, (eventTitle, eventDate)).lastrowid
        self.cursor.commit()
        print("Current event is at {}".format(id))

        # create the directory.
        os.mkdir("records/event{}".format(id))

    def create_record_audio(self, event_id, speaker_id,
question, audio_path, transcribe_lang):
        self.cursor.execute("""
                INSERT INTO record_data (event_id, speaker_id,
question_text,        transcript_audio,        transcript_text,
transcribe_lang)
                VALUES (?, ?, ?, ?, "", ?)
        """,  (event_id,  speaker_id,  question,  audio_path,
transcribe_lang))
        self.cursor.commit()

    def create_record_text(self, event_id, speaker_id,
question, text):
        self.cursor.execute("""
                INSERT INTO record_data (event_id, speaker_id,
question_text,        transcript_audio,        transcript_text,
transcribe_lang)
                VALUES (?, ?, ?, "", ?, "")
        """, (event_id, speaker_id, question, text))
        self.cursor.commit()

    # read
    def get_speaker(self, selector, ID):
        return self.cursor.execute("""
```

```
                SELECT * FROM speakers
                WHERE {} = ?
        """.format(selector), (ID,)).fetchone()

    def get_event(self, selector,  ID):
        return self.cursor.execute("""
                SELECT * FROM events
                WHERE {} = ?
        """.format(selector), (ID,)).fetchone()

    def get_recordData(self, selector, ID):
        query = """
                SELECT * FROM record_data
                WHERE {} = ?
        """.format(selector)
        self.cursor.execute(query, (ID,)).fetchall()

    # list

    def list_speakers(self):
        return self.cursor.execute("""
                SELECT * FROM speakers
        """).fetchall()

    def list_events(self):
        return self.cursor.execute("""
                SELECT * FROM events
        """).fetchall()

    def list_recordData(self):
        return self.cursor.execute("""
                SELECT * FROM record_data
        """).fetchall()

    # definitive record data
```

```
    def list_recordData_complete(self):
        pass

    # update
    def update_recordData_text(self, ID, text):
        self.cursor.execute("""
                UPDATE record_data
                SET transcript_text = ?
                WHERE id = ?
        """, (text, ID))
        self.cursor.commit()

    # delete
    def clear_table(self, table):
        self.cursor.execute("""
                DELETE FROM {};
        """.format(table))
        self.cursor.commit()

    def delete_by_id(self, table:str, id:int):
        self.cursor.execute("""
            DELETE FROM {}
            WHERE ID = ?
        """.format(table), (id))
        self.cursor.commit()

    # goofy ahh functions
    def get_recordCountByEventID(self, eventID):
        return len(self.get_recordData("event_id", eventID))

    def loop_create_speaker(self):
        # # create speakers
        while True:
            name = input("Name : ")
            if name == "stop":
```

```
                break
            code = input("Code : ")
            self.create_speaker(name, code)

    def create_recordDataFromExcel(self, filePath, sheetName,
eventID):
        df = pd.read_excel(filePath, sheet_name=sheetName)
        for i in df.index:
            print("-" * 80)
            speakerCode = df.loc[i]["Speaker"]
            print(speakerCode)
            speakerData = self.get_speaker("code", speakerCode)
            speakerID = speakerData[0]

            self.create_record_text(event_id=eventID,
speaker_id=speakerID,

question=df.loc[i]["Question"], text=df.loc[i]["Answer"])
            print("-" * 80)

    def get_recordDataJoined(self, selector, ID):
        query = """
                SELECT record_data.id as id, events.title as
event_title, events.datetime as date, speakers.code as
speaker_code, question_text, transcript_audio, transcript_text,
transcribe_lang
                FROM record_data
                INNER JOIN events
                ON record_data.event_id = events.id
                INNER JOIN speakers
                ON record_data.speaker_id = speakers.id
                WHERE record_data.{} = ?
        """.format(selector)
        return self.cursor.execute(query, (ID,)).fetchall()
```

```
    def get_recordDataJoinedDF(self, selector, ID):
        query = """
                SELECT record_data.id as id, events.title as
event_title, speakers.code as speaker, question_text as
question, transcript_text as answer
                FROM record_data
                INNER JOIN events
                ON record_data.event_id = events.id
                INNER JOIN speakers
                ON record_data.speaker_id = speakers.id
                WHERE record_data.{} = {}
        """.format(selector, ID)
        df = pd.read_sql_query(query, self.cursor)
        return df
```

Berikut fungsi-fungsi yang ada dalam class `DatabaseHandler` dan kegunaannya.

Segmen Kode 4.31 *Mapping* fungsi class DatabaseHandler

Fungsi	Input	Keterangan
`create_tables()`	-	Membuat skema *database* sebagaimana ditentukan oleh ERD sebagai inisialisasi.
`create_speaker()`	Nama dan kode pembicara, dalam bentuk *string*.	Membuat rekor data pembicara pada tabel `speakers`.
`create_event()`	Nama dan tanggal event, dalam format *string*.	Membuat rekor data sesi diskusi pada tabel `events`.
`create_record_audio()`	- ID Event : integer - ID pembicara : integer	Membuat rekor data rekaman, dengan isi data berupa *file path* rekaman audio. File audio akan direkam dan diisi oleh program dengan fungsi

	- Pertanyaan : string - File path audio : string - Bahasa transkripsi : string	`ListenWindow.ToggleRecord()`. Parameter `transcribeLang` menyatakan bahasa transkripsi, untuk menjaga kualitas transkripsi jika menggunakan bahasa Inggris saja.
`create_record_text`	- ID Event : integer - ID pembicara : integer - Pertanyaan : string - Teks : string - Bahasa transkripsi : string	Membuat rekor data rekaman dengan isi data berupa teks secara langsung. Digunakan untuk mengimpor data dari file .xlsx.
`get_speaker()`	- ID - Selector	Mendapatkan data pembicara dengan *selector* tertentu.
`get_event()`	- ID - Selector	Mendapatkan data sesi diskusi dengan *selector* tertentu.
`get_recordData()`	- ID - Selector	Mendapatkan data rekaman dengan *selector* tertentu.
`list_speakers()`	-	Mendapatkan seluruh tabel `speakers`.
`list_events()`	-	Mendapatkan seluruh tabel `events`.

`list_recordData()`	-	Mendapatkan seluruh tabel `record_data`.
`update_recordData_text()`	- ID : integer - Text : string	Melakukan update pada sebuah data rekaman di tabel `record_data`. Digunakan ketika sudah mendapatkan hasil transkripsi dan akan menyimpannya dalam rekor data yang bersangkutan.
`get_recordDataJoinedDF()`	- ID - Selector	Mendapatkan rekor data dalam sesi yang sama (`eventID` tertentu), dan melakukan join dengan tabel `speakers` dan `events` untuk mendapatkan nama sesi dan kode pembicara. Data akan dikonversi dalam bentuk `pandas.DataFrame` untuk mempermudah operasi-operasi deteksi anomali.

4.3.4. Komponen Transcriber dan Translator

Untuk mengubah data rekaman suara pembicara menjadi teks yang bisa diolah, digunakan komponen-komponen *transcriber* dan *translator*. Komponen *transcriber* yang digunakan adalah *library* Python `whisper`, yang merupakan produk whisper.ai. Komponen ini menerima input berupa *file* audio dan parameter berupa bahasa transkripsi, dan memberikan *output* transkrip dalam bentuk teks. Jika transkrip berbahasa Indonesia, teks transkrip akan diterjemahkan oleh komponen *translator,* yaitu *library* Python `googletrans`. Implementasi komponen-komponen ini diwujudkan dalam *class* `TurnToTextinator` dalam *file* turntotextinator.py

Segmen Kode 4.32 Class TurnToTextinator dalam file turntotextinator.py

```
import whisper
import os
import googletrans as gt
```

```
# behold the most critical non-core component: the Turn-to-textinator
# it transcribes an audio file and translates to English if it isn't already.
# takes a .wav and returns a string. The saving will be done in the main app, invoking the db function.

class TurnToTextinator():
    def __init__(self) -> None:
        self.whisperModel = whisper.load_model("large")
        self.translator = gt.Translator()

    def TranslateText(self, text, src="auto", dest="en"):
        return self.translator.translate(text, src=src, dest=dest).text

    def TranscribeText(self, fileName, transcribeLang="id"):
        filenamePath = os.path.join(os.getcwd(), fileName)
        result = self.whisperModel.transcribe(filenamePath, fp16=False, language=transcribeLang)
        return result["text"]

    def TwoForOneSpecial(self, fileName, transcribeLang="id", translateLang="en"):
        text = self.TranscribeText(fileName, transcribeLang)
        return self.TranslateText(text, transcribeLang, translateLang)
```

Tabel 4.7 *Mapping* fungsi class TranslateText

Fungsi	Input	Keterangan
`TranslateText()`	Input berupa teks, bahasa asal dan bahasa tujuan dalam *string*.	Menggunakan *library* `googletrans` untuk menerjemahkan teks dari

		satu bahasa ke bahasa lainnya. Digunakan untuk menerjemahkan teks hasil transkrip bahasa Indonesia ke bahasa Inggris.
`TranscribeText()`	*File path* audio dan bahasa transkrip dalam bentuk *string*	Menggunakan *library* `whisper` untuk melakukan transkripsi audio ke teks. Jika input dalam bahasa Inggris, akan langsung dilakukan transkripsi dalam bahasa Inggris.
`TwoForOneSpecial()`	*File path* audio, bahasa asal dan bahasa tujuan dalam *string*.	Melakukan transkripsi dalam bahasa Indonesia dengan fungsi `TranscribeText()`, lalu menerjemahkan hasil transkripsi ke bahasa Inggris dengan `TranslateText()`.

Class `TurnToTextinator` dimanfaatkan dalam program untuk melakukan transkripsi *file* audio. Fungsi ini harus dijalankan secara *asynchronous* agar *loop* UI program tidak terinterupsi. Fungsi *asynchronous* diimplementasikan dengan cara menggunakan *class* `QThread` yang disediakan oleh *library* `PyQt6`. Oleh karena itu, *class* ini diimplementasikan sebagai *inheritance* dari *class* `TurnToTextinatorThread`.

Segmen Kode 4.33 *Class* TurnToTextinatorThread sebagai implementasi *class* TurnToTextinator yang memanfaatkan *multithreading* dengan QThread

```
class TurnToTextinatorThread(qtc.QThread):  # tttt for short
    transcribe_signal = qtc.pyqtSignal(list)

    def __init__(self, filePathList: list = []) -> None:
        super().__init__()
```

```
        self.filePathList = filePathList

    def setFilePath(self, filePathList: list):
        self.filePathList = filePathList

    def run(self):
        filePath_transcriptList = []
        for row in range(len(self.filePathList)):
            # conditions for transcribing
            if self.filePathList[row][2].lower() == "id":
                # if indonesian, hit it with the two for one
special (transcribe as ID, then translate ID to EN)
                transcript = ttt.TwoForOneSpecial(
                    fileName=self.filePathList[row][1],
transcribeLang="id", translateLang="en")
            elif self.filePathList[row][2].lower() == "en":
                # if english, only return the transcription
                transcript = ttt.TranscribeText(
                    fileName=self.filePathList[row][1],
transcribeLang="en")
            filePath_transcriptList.append(
                (self.filePathList[row][0],
self.filePathList[row][1], transcript))
        # returns a list of (row, filePath, transcript)
        self.transcribe_signal.emit(filePath_transcriptList)
```

Object dari *class* ini akan dibuat ketika tombol "Transcribe" di `ProcessWindow` ditekan. Semua rekor data pada tabel yang memiliki *file* audio akan di-*passing* ke *object* `TurnToTextinatorThread` yang telah dibuat. Variabel `transcribe_signal` dalam *object* `TurnToTextinatorThread` akan mengirimkan sinyal ketika proses transkripsi selesai; sinyal ini dihubungkan pada fungsi `ProcessWindow.GetTranscript()` untuk kemudian disajikan dalam tabel dan disimpan dalam *database*.

4.3.5. Audio Recorder

Untuk merekam suara peserta yang sedang berbicara, digunakan *library* `pyaudio` yang langsung diimplementasikan dalam *class* `RecorderThread` yang merupakan *inheritance* dari `QThread`. Proses rekaman suara merupakan proses *asynchronous* dan harus berjalan secara paralel dengan GUI program.

Segmen Kode 4.34 Class RecorderThread

```
class RecorderThread(qtc.QThread):

    toggle_signal = qtc.pyqtSignal(str)

    def __init__(self, fileName=None):
        super().__init__()
        self.fileName = fileName
        self.is_running = True  # for toggling

    # this function will be called when QThread::start() is
called.
    def run(self):
        audio = pa.PyAudio()
        frames = []
        stream = audio.open(format=pa.paInt16, channels=1,
                            rate=44100,             input=True,
frames_per_buffer=1024)
        # apparently the point is making a separate loop while
keeping the GUI loop running.
        while self.is_running:
            data = stream.read(1024)
            frames.append(data)
        stream.close()
        wf = wave.open(self.fileName, 'wb')
        wf.setnchannels(1)
        wf.setsampwidth(audio.get_sample_size(pa.paInt16))
        wf.setframerate(44100)
        wf.writeframes(b''.join(frames))
```

```
        wf.close()

    # this here is what to do upon stopping
    def stop(self):
        self.is_running = False
        self.toggle_signal.emit(self.fileName)
```

Ketika fungsi `ListenWindow.ToggleRecord()` dijalankan, program akan memulai rekaman dengan cara membuat sebuah object `RecorderThread`. `RecorderThread` akan terus merekam audio sampai fungsi `ListenWindow.ToggleRecord()` dijalankan lagi, dimana program akan mengirimkan sinyal `stop()` pada object `RecorderThread`, dan variabel `toggle_signal` akan mengirimkan sinyal yang dihubungkan pada fungsi `ListenWindow.SaveRecording()` untuk menyimpan *file* hasil rekaman di *directory* yang telah ditentukan.

DAFTAR PUSTAKA

"Forum". (2022). Retrieved from Oxford Learner's Dictionaries.: https://www.oxfordlearnersdictionaries.com/definition/english/forum?q=forum

Aghammadzada, E. (2020). *kaggle.com*. Retrieved from Stemming vs Lemmatization NLP [Image]: https://www.kaggle.com/getting-started/186152

Blei, D., Ng, A., & Jordan, M. (2001). Latent Dirichlet Allocation. *Advances in Neural Information Processing Systems 14 (NIPS 2001).* Vancouver. Retrieved from https://proceedings.neurips.cc/paper/2001/file/296472c9542ad4d4788d543508116cbc-Paper.pdf

Brownlee, J. (2020, April 6). *10 Clustering Algorithms With Python*. Retrieved from machinelearningmastery.com: https://machinelearningmastery.com/clustering-algorithms-with-python/

Chandola, V., Banerjee, A., & Kumar, V. (2009, July). Anomaly Detection: A Survey. *ACM Computing Surveys*, Vol 41, No. 3, Article 15. Retrieved from https://dl.acm.org/doi/10.1145/1541880.1541882

Chowdhary, K. (2020). Fundamentals of Artificial Intelligence. Springer. Retrieved from https://dokumen.pub/qdownload/fundamentals-of-artificial-intelligence-1nbsped-8132239709-9788132239703.html

Curiskis, S., & al., e. (2019). An evaluation of document clustering and topic modelling in two online social networks: Twitter and Reddit. *Information Processing and Management 57(2)*. Retrieved from https://doi.org/10.1016/j.ipm.2019.04.002

Danziger, S., Levav, J., & Avnaim-Pesso, L. (2011). Extraneous factors in judicial decisions. *Proceedings of the National Academy of Sciences*, (pp. 6889-6892). doi:10.1073/pnas.1018033108

Dictionary, C. (n.d.). *Lemmatisation.* Retrieved from https://www.collinsdictionary.com/dictionary/english/lemmatize

Ester, M., Kriegel, H., Sander, J., & Xu, X. (1996). A Density-Based Algorithm for Discovering Clusters in Large Spatial Databases with Noise. *KDD-96* (pp. 226-231). Munich: AAAI. Retrieved from https://dl.acm.org/doi/10.5555/3001460.3001507

Firdaus, A. (2019, Aug 13). *Cara Kerja Word2Vec*. Retrieved from https://medium.com/@afrizalfir/mengenal-word2vec-af4758da6b5d

Gautam, H. (2020, Mar 1). *Word Embedding: Basics*. Retrieved from https://medium.com/@hari4om/word-embedding-d816f643140

GeekForGeeks. (2022, December 11). *Removing stop words with NLTK in Python*. Retrieved from www.geeksforgeeks.org: https://www.geeksforgeeks.org/removing-stop-words-nltk-python/

Google. (2022, July 19). *Clustering Algorithms*. Retrieved from https://developers.google.com/: https://developers.google.com/machine-learning/clustering/clustering-algorithms

Hvitfeld, E., & Silge, J. (2022, May 11). *Supervised Machine Learning for Text Analysis in R*. Retrieved from https://smltar.com: https://smltar.com/tokenization.html

Jacobi, C., van Atteveldt, W., & Welbers, K. (2015). Quantitative analysis of large amounts of journalistic texts using topic modelling. *Digital Journalism*, 89–106. Retrieved from https://doi.org/10.1080/21670811.2015.1093271

Kalepalli, Y., Tasneem, S., Phani Teja, P. D., & Manne, S. (2020). Control Systems (ICICCS). *Effective Comparison of LDA with LSA for Topic Modelling*. doi:10.1109/iciccs48265.2020.9120888

Kannan, S., Gurusamy, V., Vijayarani, S., Ilamathi, J., & Nithya, M. (2014). Preprocessing Techniques for Text Mining. *International Journal of Computer Science & Communication Networks*, 7-16. Retrieved from https://www.academia.edu/35015140/Preprocessing_Techniques_for_Text_Mining

Katryn, R. (2020, September 28). *Text Preprocessing: Tahap Awal dalam Natural Language Processing (NLP)*. Retrieved from https://medium.com/: https://medium.com/mandiri-engineering/text-preprocessing-tahap-awal-dalam-natural-language-processing-nlp-bc5fbb6606a

Kienle, A., & Ritterskamp, C. (2007). Facilitating asynchronous discussions in learning communities: The impact of moderation strategies. *Behaviour and Information Technology, 26*(1), 73-80. doi:10.1080/01449290600811594

Kumar, E. (2013). *Natural Language Processing.* Retrieved from https://books.google.com/books/about/Natural_Language_Processing.html?id=FpUBFNFuKWgC

Lai, S., Liu, K., He, S., & Zhao, J. (2016). How to Generate a Good Word Embedding. *IEEE Intelligent Systems*, 5-14. Retrieved from https://arxiv.org/abs/1507.05523

Lee, J., & et.al. (2018). Ensemble Modeling for Sustainable Technology Transfer. *Sustainability, X*(7), 2278-. doi:10.3390/su10072278

Mohammed, S., & Al-augby, S. (2020). LSA & LDA Topic Modeling Classification : Comparison study on E-books. *Indonesian Journal of Electrical Engineering and Computer Science*, 353-362. Retrieved from https://ijeecs.iaescore.com/index.php/IJEECS/article/view/20547

NLTK. (2022, December 12). *Documentation*. Retrieved from https://www.nltk.org: https://www.nltk.org/howto/stem.html

Pai, A. (2020, May 26). *What is Tokenization in NLP? Here's All You Need To Know*. Retrieved from www.analyticsvidhya.com: https://www.analyticsvidhya.com/blog/2020/05/what-is-tokenization-nlp/

Porter, M. F. (1980). An algorithm for suffix stripping. *Program: electronic library and information systems*, 130-137. doi:10.1108/eb046814

Ribeiro, J. (2021, Feb 18). *What is Natural Language Processing (NLP), and why does it matter to you?* Retrieved from https://towardsdatascience.com/what-is-natural-language-processing-nlp-and-why-does-it-matter-to-you-3cc4fb003940

Salton, G., & Buckley, C. (1988). Term-weighting approaches in automatic text retrieval. *Information Processing & Management, XXIV*(5), 513-523. doi:doi:10.1016/0306-4573(88)90021-0

Scikit Learn. (n.d.). *Demo of DBSCAN clustering algorithm.* Retrieved from scikit-learn.org: https://scikit-learn.org/stable/auto_examples/cluster/plot_cluster_comparison.html

Williams, T., & Betak, J. (2019). A Comparison of LSA and LDA for the Analysis of Railroad Accident. *Journal of Ubiquitous Systems & Pervasive Networks*, 11-15. Retrieved from https://iasks.org/articles/juspn-v11-i1-pp-11-15.pdf

Witten, I. H., Frank, E., Hall, M. A., & Pal, C. J. (2016). *Data Mining: Practical Machine Learning Tools and Techniques (Morgan Kaufmann Series in Data Management Systems).* Massachusetts: Morgan Kaupfmann.

Xu, D., & Tian, Y. (2015). A Comprehensive Survey of Clustering Algorithms. *Annals of Data Science*, 165-193. Retrieved from https://link.springer.com/article/10.1007/s40745-015-0040-1